MobileDreamer：面向 GUI 智能体的生成式草图世界模型

Yilin Cao[1,2*], Yufeng Zhong[3*], Zhixiong Zeng[3†], Liming Zheng[3], Jing Huang[3], Haibo Qiu[3], Peng Shi[3], Wenji Mao[1,2†], Wan Guanglu[3]
[1] 多模态人工智能系统全国重点实验室,
中国科学院自动化研究所
[2] 中国科学院大学人工智能学院
[3] 美团
wenji.mao@ia.ac.cn, zengzhixiong@meituan.com

Abstract

移动端 GUI 智能体（GUI Agent）在真实世界的自动化和实际应用中展现出了强大的潜力。然而，大多数现有的智能体仍然是反应式的，主要基于当前屏幕做出决策，这限制了它们在长序列任务上的表现。通过重复交互构建世界模型（World Model）可以预测动作结果，从而为移动端 GUI 智能体提供更好的决策支持。这具有挑战性，因为模型必须在具备空间感知能力的同时预测动作后的状态，并且保持足够的效率以用于实际部署。本文提出了 MobileDreamer，一种基于高效世界模型的前瞻框架，通过世界模型提供的未来想象来增强 GUI 智能体。它由文本草图世界模型（Textual Sketch World Model）和面向 GUI 智能体的推演想象（Rollout Imagination）两部分组成。文本草图世界模型通过将数字图像转换为与任务相关的关键草图的学习过程来预测动作后的状态，并设计了一种新颖的顺序不变学习（Order-Invariant Learning）策略来保留 GUI 元素的空间信息。面向 GUI 智能体的推演想象策略利用世界模型的预测能力来优化动作选择过程。在 Android World 上的实验表明，MobileDreamer 达到了最先进的性能，将任务成功率提升了 5.25%。世界模型评估进一步验证了我们的文本草图建模能够准确预测关键 GUI 元素。

1 引言

移动端 GUI 智能体 (Sun et al., 2025a,b; Lu et al., 2025; Liu et al., 2025b) 旨在通过感知屏幕内容并执行点击、输入和滑动等动作来自主操作移动设备，以完成用户指定的任务。现有的移动端 GUI 智能体已在多个领域展现出巨大潜力，包括网页自动化 (Ye et al., 2025; Liu et al., 2025a)、移动应用测试 (Yoon et al., 2024; Yu et al., 2023) 和企业工作流优化 (Lin et al., 2025)。尽管进展迅速且关注度不断提高，但大多数移动端 GUI 智能体仍然主要是反应式的，仅基于当前屏幕和近期历史做出决策，而没有显式地推理下游界面变化。此外，它们仍然达不到类人操作水平，因为人类通常通过预测未来状态变化来做出决策。因此，在复杂的长序列任务中，GUI 智能体往往难以进行有效规划，并做出导致低效步骤或任务失败的短视决策。

近期世界模型的进展为移动端 GUI 智能体提供了一个有前景的方向。世界模型预测动作后状态的能力可以为 GUI 智能体提供额外的证据，以在长序列任务中选择更好的动作。一些早期研究已尝试将基于文本的世界模型与 GUI 智能体集成 (Gu et al., 2024; Chae et al., 2024; Li et al., 2025)。然而，基于文本的状态预测缺乏空间信息，而空间信息对于 GUI 环境中的准确动作规划至关重要。近期一项工作使用基于图像的世界模型 (Luo et al., 2025) 来预测下一个 GUI 截图。虽然这种方法能够捕获空间信息，但其计算开销大且包含与任务无关的视觉细节，这限制了其在多步规划中的实用性。

此外，如何有效利用预测的未来状态进行动作选择仍然探索不足。现有的 GUI 智能体主要依赖单步贪心选择 (Sun et al., 2025a,b; Li et al., 2025)。这种简单策略限制了智能体只能考虑一步可能的结果。由于缺乏多步主动行为的长期视野，GUI 智能体可能难以做出可行的未来决策。

为了应对这些挑战，我们提出了 **MobileDreamer**，一种基于高效草图世界模型的前瞻框架，赋予 GUI 智能体在执行动作前预测长期结果的能力。它由两个关键组件组成：**1) 文本草图世界模型（TSWM）**，使用结构化文本表示预测未来状态中与任务相关的信息。为了提高文本草图的视觉保真度，我们引入了一种顺序不变学习目标，通过 IoU 感知的代价优化元素匹配，使训练对元素顺序变化和微小位置偏移具有鲁棒性。**2) 面向 GUI 智能体的推演想象**，递归地将预测轨迹作为预测树（Tree-of-Prediction）反馈给 GUI 智能体，提

*同等贡献。
†通讯作者。

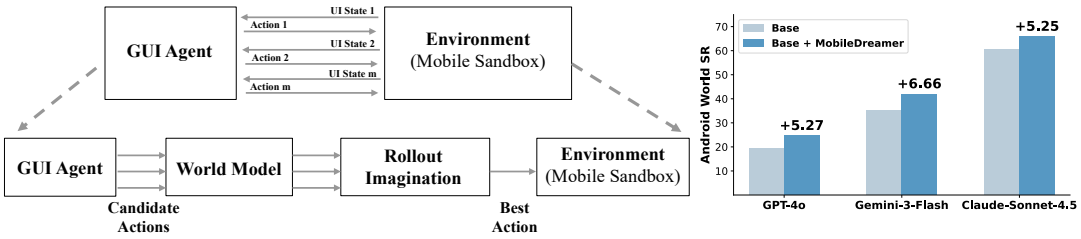

Figure 1: MobileDreamer 训练一个世界模型来预测未来的 GUI 状态，并执行推演想象来从候选动作中选择最优动作。它在 Android World 上持续提升了多种 LLM 骨干网络的性能。

供预测证据以改善动作选择过程。

在实验方面，我们在未来状态预测任务上验证了所提出的 TSWM。结果表明其在未来状态预测方面具有优异的性能。此外，我们在 Android World 基准测试 (Rawles et al., 2025) 上评估了 MobileDreamer。MobileDreamer 在预测未来状态的能力上显著超越了开源/闭源模型，并在多个基线 GUI 智能体上取得了显著提升，证明了我们框架设计的有效性 1。

本文的主要贡献总结如下：

- 为了在保留关键空间信息的同时高效表示 GUI 状态，我们提出了一种文本草图世界模型表示，采用轻量级和结构化的文本格式，并开发了顺序不变学习来预测动作后的状态。
- 我们进一步设计了面向 GUI 智能体的推演想象策略，通过设计带有预测树的多步前瞻机制，递归地反馈预测的未来轨迹以优化主动动作选择过程。
- 在 Android World 上的实验结果表明，我们的框架显著提高了 GUI 智能体的任务成功率。世界模型评估实验进一步证明了文本草图世界建模在准确预测关键 GUI 元素方面的有效性。

2 相关工作

2.1 世界模型

世界模型（World Model） (Ding et al., 2024) 是基于学习的系统，通过预测环境动态来使智能体能够预测未来状态以做出更好的决策。它们已被广泛应用于具身智能 (Cen et al., 2025; Yao et al., 2025)、自动驾驶 (Wang et al., 2025; Chen et al., 2025) 和游戏 (Hafner et al., 2025; Zhou et al., 2024)，展现出强大的预测能力。在 GUI 智能体领域，早期探索主要集中在基于文本的世界模型上，通过自然语言描述来预测界面变化。WEBDREAMER (Gu et al., 2024) 使用自然语言模拟动作结果，并使用基于 LLM 的评分进行动作选择。WMA (Chae et al., 2024) 通过以转换为中心的抽象来预测重要的状态变化。MobileWorld (Li et al., 2025) 将转换表示为自然语言三元组。虽然这些基于文本的方法计算效率高，但它们丢失了关键的空间信息，如组件位置和边界框（Bounding Box）。近期，ViMo (Luo et al., 2025) 率先引入了基于图像的世界模型，通过预测下一帧 GUI 截图来工作。然而，像素级预测带来了高昂的计算成本，且难以重建细粒度细节。此外，现有方法缺乏有效的多步前瞻机制，通常依赖单步贪心选择。

2.2 GUI 智能体

早期的 GUI 智能体依赖于结构化数据，如 HTML 或可访问性树（Accessibility Tree）(Deng et al., 2023; Gur et al., 2023; Lai et al., 2024; He et al., 2024; Yang et al., 2023)。随着多模态大语言模型（MLLM）的发展，基于视觉的方法 (Hong et al., 2024; Zhang and Zhang, 2024; Zhang et al., 2024; Huang et al., 2025) 应运而生，通过直接处理截图展现出更强的泛化能力。在此基础上，近期工作 (Qin et al., 2025; Yan et al., 2025; Zeng et al., 2025) 通过训练策略上的进一步创新达到了最先进的性能。UI-TARS (Qin et al., 2025) 引入了一种原生智能体方法，具有长期记忆和反思机制以实现迭代改进。Step-GUI (Yan et al., 2025) 提出了一种自进化训练流程，通过轨迹级校准生成高质量数据。与此同时，研究也探索了跨领域协同，如 (Han et al., 2025; Yang et al., 2025c) 将 GUI 智能体与机器人和其他模态集成。在移动端智能体领域 (Sun et al., 2025a,b)，研究者探索了多种方法来增强智能体能力。以数据为中心的方法通过合成轨迹 (Sun et al., 2025a) 或探索视频 (Sun et al., 2025b) 来扩展训练数据。尽管取得了这些进展，现有的移动端智能体仍然主要是反应式的，基于当前观测做出决策而不预测未来后果。这一局限性可以通过世界模型来解决。

3 方法

本节正式介绍所提出的 **MobileDreamer** 框架，旨在赋予 GUI 智能体在执行动作前预测长期结果的能力。如图 2所示，该框架由两个阶段组成。在第一阶段，我们构建文本草图世界模型 (TSWM)，一种基于动作条件的世界模型，以轻量级、结构化的文本格式预测动作后的 GUI 状态。在第二阶段，我们提出面向 GUI 智能体的推演想象策略。该策略将 TSWM 封装为函数，使智能体能够通过函数调用来预测动作结果。预测在多个步骤上进行，以在候选动作之间构建预测树，智能体最终根据预期后果选择动作。

3.1 文本草图世界模型

虽然先前的工作尝试使用世界模型预测来进行动作选择 (Gu et al., 2024; Chae et al., 2024; Li et al., 2025; Luo et al., 2025)，但依赖扩散模型来重建 GUI 页面会增加大量成本并引入与预测无关的细节，如纹理和装饰。这些细节可能会干扰智能体并影响决策。为了解决这一问题，我们提出了文本草图世界模型（TSWM），仅预测 GUI 智能体规划所需的最少信息。

文本草图表示 我们首先使用 PaddleOCR-VL (Cui et al., 2025) 从 GUI 页面中提取关键元素。经过此过程后，每个图标以结构化格式表示。为了在计算效率和布局清晰描述之间取得平衡，我们保留三个关键属性：标签、图标内的文本以及页面上的位置。因此，当前状态 s_t 表示为元素集合 $\mathcal{E}(s_t) = \{e_n\}_{n=1}^{N}$，其中每个元素 $e_n = (\ell_n, \tau_n, b_n)$ 包含标签 ℓ_n、文本 τ_n 和位置（边界框）b_n。以下是提取数据的示例：

```
label=image;text="Home";bbox=[35,175,347,233]
label=text;text="Totals";bbox=[50,343,285,467]
label=text;text="INCOME";bbox=[96,519,239,624]
```

基于文本草图表示，GUI 状态被编码为结构化文本。因此，一种直接的方法是以监督方式训练文本草图世界模型。具体而言，下一状态 s_{t+1} 通过在当前状态 s_t 上执行动作 a_t 获得，世界模型可以通过监督微调（SFT）的词级交叉熵损失进行训练：

$$\mathcal{L}_{\mathrm{CE}} = -\sum_{i} \log p_\theta(s_{t+1,i} \mid s_{t+1,<i},\, s_t, a_t)\,, \tag{1}$$

其中 $s_{t+1,i}$ 表示下一 GUI 状态文本草图序列中的第 i 个词元，θ 表示可训练参数。

然而，由于世界模型和 LLM 目标之间的不匹配，我们认为仅使用 SFT 可能导致次优性能。特别是，在以下两种情况下，预测对于世界模型使用可能是充分的，但仍然会产生较大的 SFT 损失：

- **元素顺序变化**。动作后的 GUI 状态本质上是一个元素集合。重新排列元素（如 $[A, B, C]$ 变为 $[B, C, A]$）不应被视为错误，但词级监督是顺序敏感的。
- **位置微移**。微小的位置偏移（如真实边界框 [100,200,300,400] 与预测边界框 [101,199,301,399]）可能导致较大的词级损失，即使几何形状几乎正确（IoU ≈ 0.98）。

顺序不变学习 由于朴素的 SFT 不太适合世界模型预训练，我们引入了元素级匹配损失。直觉上，我们将 TSWM 目标视为目标检测问题。对于每个预测的图标，我们使用最优传输将其与真实图标进行匹配，然后对齐其属性。

具体而言，给定 TSWM 的预测 $\hat{s}_{t+1}$，我们将预测的元素集合记为 $\hat{\mathcal{E}}(\hat{s}_{t+1}) = \{\hat{e}_k\}_{k=1}^{K}$，其中每个预测元素为 $\hat{e}_k = (\hat{\ell}_k, \hat{\tau}_k, \hat{b}_k)$。然后我们计算预测元素和真实元素之间的一对一集合匹配。令 Π 表示有效的一对一匹配集合；每个匹配 $\pi \in \Pi$ 是索引对的集合 $\pi \subseteq \{1, \ldots, K\} \times \{1, \ldots, N\}$，使得每个 k 和每个 n 至多出现在一个配对中。

对于预测-真实配对 $(\hat{e}_k, e_n)$，我们定义加权代价函数来衡量几何和内容不匹配：

$$\begin{aligned} C(\hat{e}_k, e_n) = {} & \lambda_{\mathrm{bbox}}\big(1 - \mathrm{IoU}(\hat{b}_k, b_n)\big) \\ & + \lambda_{\mathrm{label}}\big(-\log \hat{p}_k(\ell_n)\big) \\ & + \lambda_{\mathrm{text}}\big(1 - \cos(\phi(\hat{\tau}_k), \phi(\tau_n))\big), \end{aligned} \tag{2}$$

其中 $\hat{p}_k(\ell_n)$ 是 $\hat{e}_k$ 预测标签 ℓ_n 的概率，$\phi(\cdot)$ 将元素文本字符串映射为固定维度的文本嵌入。使用此代价函数，我们通过最小化总成对代价来计算最优传输：

$$\pi^\star = \arg\min_{\pi \in \Pi} \sum_{(k,n)\in\pi} C(\hat{e}_k, e_n). \tag{3}$$

给定最优匹配 $\pi^\star$，我们通过对匹配对的成对代价取平均来计算集合级匹配损失：

$$\mathcal{L}_{\mathrm{match}} = \frac{1}{|\pi^\star|} \sum_{(k,n)\in\pi^\star} C(\hat{e}_k, e_n). \tag{4}$$

最终，我们使用以下目标优化文本草图世界模型：

$$\mathcal{L} = \mathcal{L}_{\mathrm{match}} + \lambda_{\mathrm{CE}}\, \mathcal{L}_{\mathrm{CE}}. \tag{5}$$

该目标鼓励文本草图世界模型在基于动作条件的转换下保留元素级结构，使其预测对元素重新排序和微小的文本或边界框扰动更加鲁棒。由此产生的预测为比较候选动作提供了更清晰的信号，并支持推演想象中更可靠的前瞻规划。

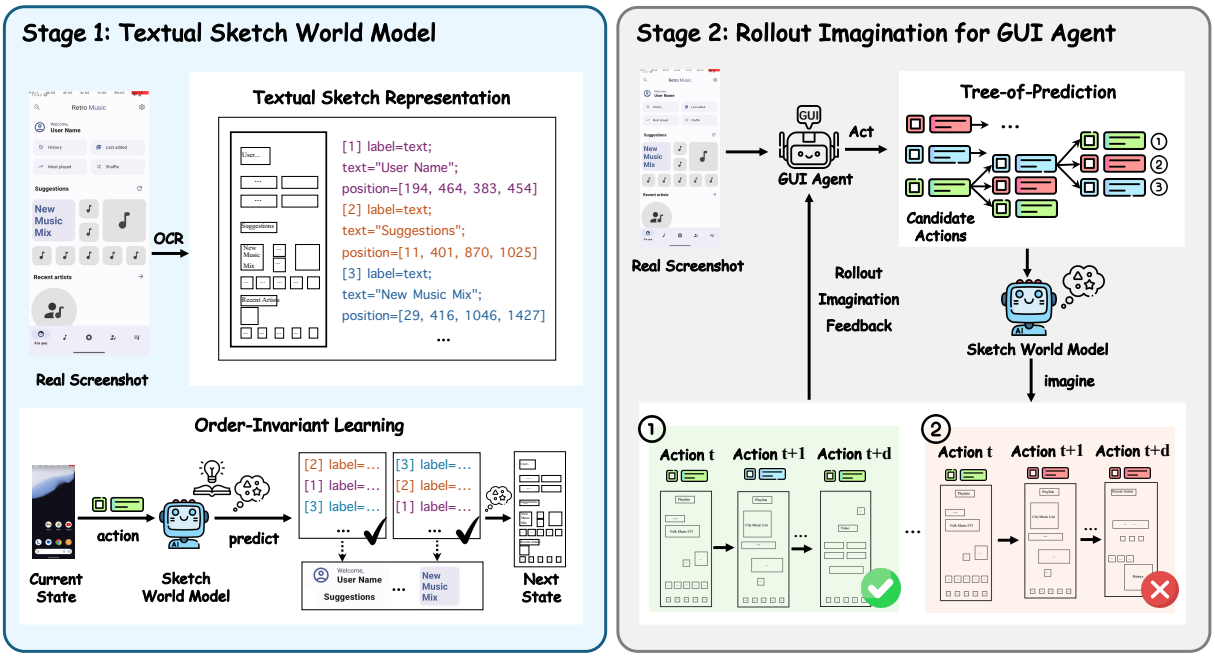

Figure 2: MobileDreamer 框架概览。在阶段 1 中，我们构建文本草图世界模型，通过顺序不变学习来预测未来状态。在阶段 2 中，我们设计推演想象策略，递归地将预测树反馈给 GUI 智能体以优化动作选择过程。

3.2 面向 GUI 智能体的推演想象

获得强大的 TSWM 后，我们提出推演想象策略，利用其预测能力来改善动作选择过程。

候选动作生成 给定任务目标 g、当前状态 s_t 和步骤指令 u_t，GUI 智能体生成 M 个候选动作的集合 $\mathcal{A}_t = \{a_t^{(1)}, \ldots, a_t^{(M)}\}$。MobileDreamer 将这些候选动作视为可选分支，通过前瞻过程进行评估。

对于每个候选动作 $a_t^{(m)}$，世界模型预测下一状态：

$$\hat{s}_{t+1}^{(m)} \sim p_\theta(s_{t+1} \mid g, s_t, a_t^{(m)}), \quad m \in \{1, \ldots, M\}. \tag{6}$$

这些预测形成了与每个候选动作对应的未来状态集合，为 GUI 智能体提供额外的上下文，帮助其根据预期的未来状态选择最佳动作。

预测树 为了建模更长期的效果，我们将单步预测扩展为深度为 d 的预测树，递归地基于预测状态生成后续候选动作并预测其未来状态。在第一次预测步骤之后，MobileDreamer 将预测状态 $\hat{\mathcal{S}}_{t+1}$ 和候选动作 $\mathcal{A}_t$ 反馈给 GUI 智能体，智能体利用预测轨迹来选择下一个预测动作 $\hat{\mathcal{A}}_{t+1}$。其中，$\mathcal{A}_t = \{a_t^{(1)}, \ldots, a_t^{(M)}\}$ 包含 M 个候选动作的集合，M 作为修剪参数控制预测树的分支因子。此过程持续进行直到树达到指定深度 d。每条从根到叶的路径表示一条短预测轨迹：

$$\mathcal{A}_t \to \hat{\mathcal{S}}_{t+1} \to \hat{\mathcal{A}}_{t+1} \to \hat{\mathcal{S}}_{t+2} \to \cdots \to \hat{\mathcal{S}}_{t+d}. \tag{7}$$

这些轨迹被汇总为深度为 d 的预测树，包括每个步骤的候选动作及其预测的动作后状态。用于向 GUI 智能体展示预测树的提示模板见附录 A.1。

世界模型对 GUI 智能体的反馈 预测完成后，MobileDreamer 将预测树作为额外上下文反馈给 GUI 智能体用于动作选择。具体而言，GUI 智能体接收真实的当前状态截图用于定位，以及预测树的文本摘要，描述每个候选动作执行后的预测未来状态。然后 GUI 智能体根据反馈选择最佳动作并在环境中执行。

预测树允许 GUI 智能体根据预期状态显式地比较可选动作。这在需要长期规划的复杂 GUI 导航任务中尤为关键。

4 实验

首先，我们在世界模型上进行实验以分析 MobileDreamer 在预测未来 GUI 状态方面的有效性。然后，我们在移动端 GUI 智能体上进行实验以分析世界模型对不同基线 GUI 智能体的增益。最后，我们进行了详细的消融研究和案例分析以提供进一步分析。

方法	mIoU	文本相似度	精确率	召回率	F1 分数
Qwen3-VL-Plus	0.6016	0.8159	0.4417	0.3893	0.4139
GPT-4.1	0.5512	0.7967	0.4272	0.3397	0.3784
Gemini-3-Flash-Preview	0.4981	0.7759	0.3792	0.1291	0.1927
Claude-Sonnet-4.5	0.4668	0.7596	0.3797	0.0980	0.1557
Qwen3-8B（基线）	0.6368	0.8224	0.4482	0.4223	0.4349
MobileDreamer	**0.8564**	**0.9428**	**0.8233**	**0.7071**	**0.7608**

Table 1: 文本草图世界模型在未来状态预测上的评估。我们报告了几何一致性（mIoU）、文本一致性（文本相似度）和元素级匹配指标（精确率/召回率/F1 分数）。

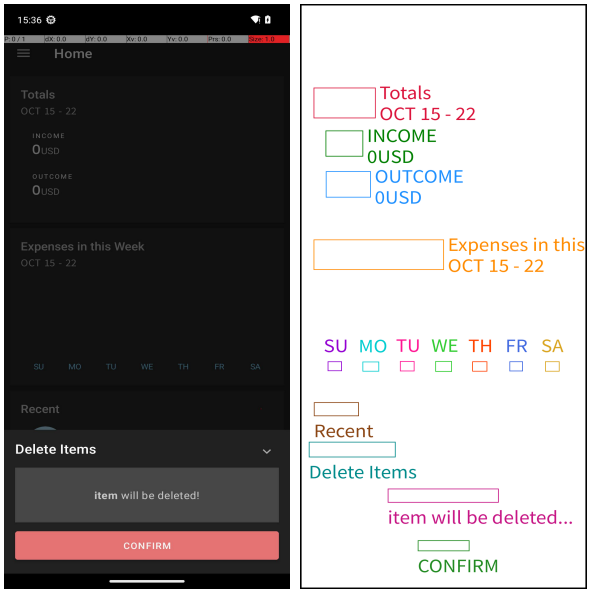

(a) 真实截图。 (b) 预测的文本草图。

Figure 3: 真实 GUI 截图与我们世界模型预测的草图之间的比较。预测的草图捕获了带有文本和位置的关键 UI 元素。为清晰起见，我们将元素文本显示在对应元素框的外部。

4.1 世界模型实验

数据集 为了训练和评估文本草图世界模型，我们从真实的移动端 GUI 轨迹中构建了状态转换样本数据集。给定一条轨迹，对于每个步骤 t，我们收集动作前的截图状态 s_t、执行的动作 a_t 和动作后的截图状态 s_{t+1}。每个结果样本是一个基于动作条件的实例 (s_t, a_t, s_{t+1})。

为了将原始截图转换为结构化的文本草图，我们使用 PaddleOCR-VL (Cui et al., 2025) 对每张截图进行标注，并将 GUI 状态表示为一组 UI 元素，每个元素关联其标签、识别的文本和位置（边界框）。此转换使文本草图世界模型能够学习执行动作后 GUI 状态的转换方式。

为了确保多样性和真实性，我们从两个来源构建样本。首先，我们利用 Android Control (Li et al., 2024) 的开源英文轨迹，获得 61.7k 个训练样本。其次，我们手动标注了额外的 50.5k 个样本。对于评估，我们从手动标注集中保留 5% 的轨迹作为测试集，确保与训练数据没有轨迹重叠。将轨迹转换为文本草图状态表示并拆分为步骤级转换后，最终数据集包含 110.1k 个训练样本和 2.1k 个测试样本。

基线 为了比较不同的 LLM 预测器与我们的草图世界模型，我们评估了几种基于提示的 LLM，包括 Qwen3-VL-Plus (Bai et al., 2025)、GPT-4.1 (OpenAI, 2025)、Gemini-3-Flash-Preview (DeepMind, 2025) 和 Claude-Sonnet-4.5 (Anthropic, 2025)。我们还使用 Qwen3-8B (Yang et al., 2025b) 作为文本草图世界模型的骨干，并报告了使用和不使用所提出的顺序不变学习目标的结果。

评估指标 我们使用 mIoU、文本相似度、精确率、召回率和 F1 分数在元素级别评估文本草图世界模型预测下一状态的性能。对于每个测试样本，我们从真实值和预测中提取动作后的状态，解析 UI 元素，并可选地基于文本对预测元素进行去重。然后在预测元素和真实元素之间执行一对一贪心匹配，匹配基于宽松的匹配准则：如果元素的位置交并比（IoU）超过阈值 θ_{iou} 或文本的归一化编辑距离低于阈值 θ_{txt}，则视为匹配。我们在评估中设置 $\theta_{\text{iou}} = 0.7$ 和 $\theta_{\text{txt}} = 0.3$。详细的评估指标见附录 A.3。

模型设置 我们在 Qwen3-8B (Yang et al., 2025a) 上构建文本草图世界模型。所有模型使用 LoRA (Hu et al., 2022) 在 NVIDIA H100 80GB GPU 集群上进行微调。我们使用 1×10^{-4} 的学习率，训练 5 个 epoch。我们采用 DeepSpeed ZERO3 风格的数据并行。

主要结果与分析 图 3比较了预测的草图状态与从截图中得出的真实草图，表明我们的草图世界模型能够准确恢复关键 UI 元素及其空间布局。表 1报告了元素级别的未来状态预测质量。我们的草图世界模型在空间和文本准确

性方面大幅超越了基于提示的 LLM 预测器和 Qwen3-8B (Yang et al., 2025b) 基线。这些结果表明，我们的草图世界模型能够可靠地预测关键的动作后元素，为预测树规划提供更高质量的预测状态。

4.2 移动端 GUI 智能体实验

数据集 为了进一步验证 MobileDreamer 在真实移动端 GUI 导航场景中的有效性，我们在 Android World 数据集 (Rawles et al., 2025) 上评估了 MobileDreamer。Android World 是一个在线基准测试，在 Android 模拟器中执行任务并支持自动化评估。它包含跨 20 个真实 Android 应用的 116 个不同导航任务。每个任务提供标准化的初始化、成功检查和清理程序，从而实现可复现的运行和基于状态的验证。任务实例通过采样任务参数生成，产生多样化的输入并减少对固定交互脚本的依赖。

在线评估 我们使用任务成功率（SR）来衡量性能。如果最终设备状态满足任务要求，则该运行视为成功，由基准检查器验证，无需修改应用源代码。

基线 我们在 Android World 上将 MobileDreamer 与两类基线进行比较，使用相同的环境设置、任务划分和评估设置。

- **使用世界模型的基线**。我们与之前整合世界模型进行规划的方法进行比较，包括 ViMo 的基于图像的世界模型 (Luo et al., 2025) 和 MobileWorld 的基于文本的世界模型 (Li et al., 2025)。
- **基础 LLM 骨干**。为了分离 MobileDreamer 的收益，我们还评估了几种骨干模型作为直接 GUI 智能体，包括 Qwen3-VL-Plus (Bai et al., 2025)、GPT-4.1 (OpenAI, 2025)、GPT-4o (Hurst et al., 2024)、Gemini-3-Flash (DeepMind, 2025) 和 Claude-Sonnet-4.5 (Anthropic, 2025)。对于每个骨干，我们在相同的提示和执行设置下报告使用和不使用 MobileDreamer 的结果。

主要结果与分析 表 2报告了 Android World 上的成功率。MobileDreamer 通过将基于草图世界模型的预测轨迹引入动作选择，一致地提升了所有评估骨干的任务成功率。它优于基础 LLM 智能体，也超越了先前整合基于文本或基于图像世界模型的基线。这些结果证明了草图世界建模和递归预测树反馈在改善 GUI 动作选择方面的有效性。总体而言，结果验证了我们的框架比反应式或单步方法能够实现更有效的长序列动作选择。

方法	Android World(SR)
先前的世界模型方法	
ViMO†	40.95
MobileWorld‡	51.30
我们的 *MobileDreamer*	
Qwen3-VL-Plus	9.57
+MobileDreamer	13.91 (+4.34)
GPT-4.1	17.11
+MobileDreamer	22.12 (+5.01)
GPT-4o	19.29
+MobileDreamer	24.56 (+5.27)
Gemini-3-Flash	35.24
+MobileDreamer	41.90 (+6.66)
Claude-Sonnet-4.5	60.53
+MobileDreamer	**65.78 (+5.25)**

Table 2: MobileDreamer 与基线方法在 Android World 上的比较。SR 表示任务成功率。† 结果引自 ViMo (Luo et al., 2025)。‡ 结果引自 MobileWorld (Li et al., 2025)。对于 MobileDreamer，我们使用深度 d=2 和候选动作数 M=3 的预测树。

草图	匹配	预测树	SR↑
✗	✗	✗	60.53
✓	✗	✗	61.94
✓	✓	✗	63.16
✓	✓	✓	65.78

Table 3: MobileDreamer 关键组件在 Android World 上的消融实验。**草图**表示在文本草图世界模型上进行 SFT。**匹配**表示顺序不变学习。**SR** 表示 Android World 上的任务成功率。

4.3 消融研究

关键组件消融研究 表 3在 Claude-Sonnet-4.5 下消融了 MobileDreamer 的关键组件。没有草图世界模型和预测树时，智能体退化为反应式基线。添加草图世界模型通过以结构化元素布局提供基于动作条件的预测状态来提升性能。顺序不变学习通过产生更鲁棒的下一状态草图来进一步提升结果，这些草图能更好地保留关键空间线索。最后，启用预测树达到了最佳性能，表明递归使用预测轨迹对长序列动作选择很重要。

文本草图世界模型消融研究 表 4表明，SFT 在基础模型上显著提升了下一状态预测性能，验证了文本草图表示为元素级状态转换提供了有效且可学习的目标。MobileDreamer 在 SFT 基础上进一步提升，表明我们设计的顺序不变

方法	mIoU	文本相似度	精确率	召回率	F1 分数
MobileDreamer	**0.8564**	**0.9428**	**0.8233**	**0.7071**	**0.7608**
不使用顺序不变学习	0.8281	0.9320	0.8039	0.6905	0.7429

Table 4: 文本草图世界模型的消融研究。我们将 MobileDreamer 与去除所提出的顺序不变学习目标的仅 SFT 变体进行比较。

深度	动作数	Android World(SR)
1	1	63.16
2	1	**64.28**
3	1	63.96
2	1	64.28
2	2	64.86
2	3	**65.78**
2	4	65.48
2	5	65.17

Table 5: 在 Claude-Sonnet-4.5 上对预测树的候选动作数和深度进行消融实验。我们改变预测深度和每个节点的候选动作数。SR 表示 Android World 上的任务成功率。

学习通过使草图预测对元素重新排序和微小空间位置噪声具有鲁棒性来增强预测。

候选动作数和深度消融研究 表 5通过改变预测深度和每个节点的候选动作数来研究预测树设置。将深度从一步增加到两步可以提升性能，因为短期推演为动作选择提供了额外的未来证据。进一步增加深度带来递减的回报且可能不够稳定，因为更深的递归反馈引入了更多嘈杂的和与任务无关的预测信息。类似地，增加候选动作数可以将性能提升到适度的分支因子，但当包含过多动作时会饱和。总体而言，适度的深度和分支因子在有用的未来证据和预测噪声之间实现了最佳折衷。

4.4 案例研究

图 4中的案例研究表明，草图世界模型通过预测未来状态提供了有用的证据，可以帮助 GUI 智能体选择与任务目标最一致的动作。给定每一步的两个候选动作，文本草图世界模型预测基于动作条件的未来状态，并以深度 2 展开预测树。预测轨迹被递归地反馈给 GUI 智能体，引导其选择最佳动作。

5 结论

本文提出了 MobileDreamer，一种面向移动端 GUI 智能体的高效草图世界模型前瞻框架。我们的框架构建了具有顺序不变学习的轻量级文本草图世界模型，并进一步设计了推演想象策略，递归地反馈预测轨迹以优化主动动作选择过程。MobileDreamer 在实验结果上表明，文本草图世界模型能够为 Android World 上的 GUI 智能体提供更有效的动作后状态预测。

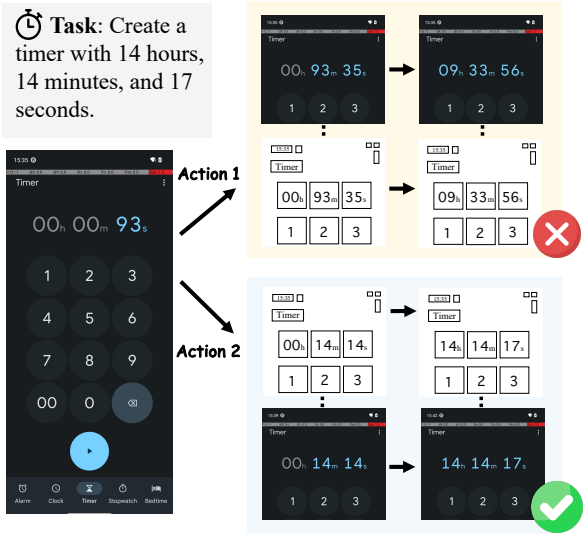

Figure 4: MobileDreamer 在计时器创建任务上的案例研究。

局限性

尽管有所改进，MobileDreamer 依赖于通过 OCR 和 UI 元素解析提取的文本草图表示。在具有大量视觉噪声、不常见字体或以图标为主且可靠文本线索有限的布局的屏幕上，预测质量可能不够稳定。虽然草图表示能够捕获大多数任务的空间布局，但对于需要细粒度视觉信号的情况（如精确的文本阅读或区分细微的 UI 外观差异），它可能信息不足。在未来的工作中，我们将改进草图提取并引入互补的视觉线索以更好地支持此类场景。

伦理考量

所有实验均在虚拟环境中进行，未访问真实用户系统。我们仅使用公开可用的数据集和合成数据，不涉及个人信息。

References

Anthropic. 2025. Claude sonnet 4.5 system card. Technical report, Anthropic. System Card.

Shuai Bai, Yuxuan Cai, Ruizhe Chen, Keqin Chen, Xionghui Chen, Zesen Cheng, Lianghao Deng, Wei Ding, Chang Gao, Chunjiang Ge, Wenbin Ge, Zhifang Guo, Qidong Huang, Jie Huang, Fei Huang, Binyuan Hui, Shutong Jiang, Zhaohai Li, Mingsheng Li, and 45 others. 2025. Qwen3-vl technical report. *arXiv preprint arXiv:2511.21631*.

Jun Cen, Chaohui Yu, Hangjie Yuan, Yuming Jiang, Siteng Huang, Jiayan Guo, Xin Li, Yibing Song, Hao Luo, Fan Wang, and 1 others. 2025. Worldvla: Towards autoregressive action world model. *arXiv preprint arXiv:2506.21539*.

Hyungjoo Chae, Namyoung Kim, Kai Tzu-iunn Ong, Minju Gwak, Gwanwoo Song, Jihoon Kim, Sunghwan Kim, Dongha Lee, and Jinyoung Yeo. 2024. Web agents with world models: Learning and leveraging environment dynamics in web navigation. *arXiv preprint arXiv:2410.13232*.

Yuntao Chen, Yuqi Wang, and Zhaoxiang Zhang. 2025. Drivinggpt: Unifying driving world modeling and planning with multi-modal autoregressive transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 26890–26900.

Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, and 1 others. 2025. Paddleocr-vl: Boosting multilingual document parsing via a 0.9 b ultra-compact vision-language model. *arXiv preprint arXiv:2510.14528*.

Google DeepMind. 2025. Gemini 3 flash model card. Technical report, Google. Model Card.

Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Sam Stevens, Boshi Wang, Huan Sun, and Yu Su. 2023. Mind2web: Towards a generalist agent for the web. *Advances in Neural Information Processing Systems*, 36:28091–28114.

Jingtao Ding, Yunke Zhang, Yu Shang, Yuheng Zhang, Zefang Zong, Jie Feng, Yuan Yuan, Hongyuan Su, Nian Li, Nicholas Sukiennik, and 1 others. 2024. Understanding world or predicting future? a comprehensive survey of world models. *ACM Computing Surveys*.

Yu Gu, Kai Zhang, Yuting Ning, Boyuan Zheng, Boyu Gou, Tianci Xue, Cheng Chang, Sanjari Srivastava, Yanan Xie, Peng Qi, and 1 others. 2024. Is your llm secretly a world model of the internet? model-based planning for web agents. *arXiv preprint arXiv:2411.06559*.

Izzeddin Gur, Hiroki Furuta, Austin Huang, Mustafa Safdari, Yutaka Matsuo, Douglas Eck, and Aleksandra Faust. 2023. A real-world webagent with planning, long context understanding, and program synthesis. *arXiv preprint arXiv:2307.12856*.

Danijar Hafner, Wilson Yan, and Timothy Lillicrap. 2025. Training agents inside of scalable world models. *arXiv preprint arXiv:2509.24527*.

Wenkang Han, Zhixiong Zeng, Jing Huang, Shu Jiang, Liming Zheng, Longrong Yang, Haibo Qiu, Chang Yao, Jingyuan Chen, and Lin Ma. 2025. Uitron-speech: Towards automated gui agents based on speech instructions. *arXiv preprint arXiv:2506.11127*.

Hongliang He, Wenlin Yao, Kaixin Ma, Wenhao Yu, Yong Dai, Hongming Zhang, Zhenzhong Lan, and Dong Yu. 2024. Webvoyager: Building an end-to-end web agent with large multimodal models. *arXiv preprint arXiv:2401.13919*.

Wenyi Hong, Weihan Wang, Qingsong Lv, Jiazheng Xu, Wenmeng Yu, Junhui Ji, Yan Wang, Zihan Wang, Yuxiao Dong, Ming Ding, and Jie Tang. 2024. Cogagent: A visual language model for gui agents. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14281–14290.

Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, Weizhu Chen, and 1 others. 2022. Lora: Low-rank adaptation of large language models. *ICLR*, 1(2):3.

Jing Huang, Zhixiong Zeng, Wenkang Han, Yufeng Zhong, Liming Zheng, Shuai Fu, Jingyuan Chen, and Lin Ma. 2025. Scaletrack: Scaling and backtracking automated gui agents. *arXiv preprint arXiv:2505.00416*.

Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, and 1 others. 2024. Gpt-4o system card. *arXiv preprint arXiv:2410.21276*.

Hanyu Lai, Xiao Liu, Iat Long Iong, Shuntian Yao, Yuxuan Chen, Pengbo Shen, Hao Yu, Hanchen Zhang, Xiaohan Zhang, Yuxiao Dong, and 1 others. 2024. Autowebglm: A large language model-based web navigating agent. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pages 5295–5306.

Shufan Li, Konstantinos Kallidromitis, Akash Gokul, Yusuke Kato, Kazuki Kozuka, and Aditya Grover. 2025. Mobileworldbench: Towards semantic world modeling for mobile agents. *arXiv preprint arXiv:2512.14014*.

Wei Li, William E Bishop, Alice Li, Christopher Rawles, Folawiyo Campbell-Ajala, Divya Tyamagundlu, and Oriana Riva. 2024. On the effects of data scale on UI control agents. In *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.

Liangtao Lin, Zhaomeng Zhu, Tianwei Zhang, and Yonggang Wen. 2025. Inframind: A novel exploration-based gui agentic framework for mission-critical industrial management. *arXiv preprint arXiv:2509.13704*.

Guangyi Liu, Pengxiang Zhao, Yaozhen Liang, Liang Liu, Yaxuan Guo, Han Xiao, Weifeng Lin, Yuxiang Chai, Yue Han, Shuai Ren, and 1 others. 2025a. Llm-powered gui agents in phone automation: Surveying progress and prospects. *arXiv preprint arXiv:2504.19838*.

Yuhang Liu, Pengxiang Li, Congkai Xie, Xavier Hu, Xiaotian Han, Shengyu Zhang, Hongxia Yang, and Fei Wu. 2025b. Infigui-r1: Advancing multimodal gui agents from reactive actors to deliberative reasoners. *arXiv preprint arXiv:2504.14239*.

Zhengxi Lu, Yuxiang Chai, Yaxuan Guo, Xi Yin, Liang Liu, Hao Wang, Han Xiao, Shuai Ren, Guanjing Xiong, and Hongsheng Li. 2025. Ui-r1: Enhancing efficient action prediction of gui agents by reinforcement learning. *arXiv preprint arXiv:2503.21620*.

Dezhao Luo, Bohan Tang, Kang Li, Georgios Papoudakis, Jifei Song, Shaogang Gong, Jianye Hao, Jun Wang, and Kun Shao. 2025. Vimo: A generative visual gui world model for app agents. *arXiv preprint arXiv:2504.13936*.

OpenAI. 2025. Introducing gpt-4.1 in the api. https://openai.com/index/gpt-4-1/. Accessed: 2026-01-05.

Yujia Qin, Yining Ye, Junjie Fang, Haoming Wang, Shihao Liang, Shizuo Tian, Junda Zhang, Jiahao Li, Yunxin Li, Shijue Huang, and 1 others. 2025. Ui-tars: Pioneering automated gui interaction with native agents. *arXiv preprint arXiv:2501.12326*.

Chris Rawles, Sarah Clinckemaillie, Yifan Chang, Jonathan Waltz, Gabrielle Lau, Marybeth Fair, Alice Li, William Bishop, Wei Li, Folawiyo Campbell-Ajala, Daniel Toyama, Robert Berry, Divya Tyamagundlu, Timothy Lillicrap, and Oriana Riva. 2025. Androidworld: A dynamic benchmarking environment for autonomous agents. In *International Conference on Representation Learning*, volume 2025, pages 406–441.

Qiushi Sun, Kanzhi Cheng, Zichen Ding, Chuanyang Jin, Yian Wang, Fangzhi Xu, Zhenyu Wu, Chengyou Jia, Liheng Chen, Zhoumianze Liu, and 1 others. 2025a. Os-genesis: Automating gui agent trajectory construction via reverse task synthesis. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5555–5579.

Yuchen Sun, Shanhui Zhao, Tao Yu, Hao Wen, Samith Va, Mengwei Xu, Yuanchun Li, and Chongyang Zhang. 2025b. Gui-xplore: Empowering generalizable gui agents with one exploration. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 19477–19486.

Hang Wang, Xin Ye, Feng Tao, Chenbin Pan, Abhirup Mallik, Burhaneddin Yaman, Liu Ren, and Junshan Zhang. 2025. Adawm: Adaptive world model based planning for autonomous driving. *arXiv preprint arXiv:2501.13072*.

Haolong Yan, Jia Wang, Xin Huang, Yeqing Shen, Ziyang Meng, Zhimin Fan, Kaijun Tan, Jin Gao, Lieyu Shi, Mi Yang, Shiliang Yang, Zhirui Wang, Brian Li, Kang An, Chenyang Li, Lei Lei, Mengmeng Duan, Danxun Liang, Guodong Liu, and 78 others. 2025. Step-gui technical report. *Preprint*, arXiv:2512.15431.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, Chujie Zheng, Dayiheng Liu, Fan Zhou, Fei Huang, Feng Hu, Hao Ge, Haoran Wei, Huan Lin, Jialong Tang, and 41 others. 2025a. Qwen3 technical report. *Preprint*, arXiv:2505.09388.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, and 1 others. 2025b. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*.

Jianwei Yang, Hao Zhang, Feng Li, Xueyan Zou, Chunyuan Li, and Jianfeng Gao. 2023. Set-of-mark prompting unleashes extraordinary visual grounding in gpt-4v. *arXiv preprint arXiv:2310.11441*.

Longrong Yang, Zhixiong Zeng, Yufeng Zhong, Jing Huang, Liming Zheng, Lei Chen, Haibo Qiu, Zequn Qin, Lin Ma, and Xi Li. 2025c. Omniactor: A generalist gui and embodied agent for 2d&3d worlds. *arXiv preprint arXiv:2509.02322*.

Xuan Yao, Junyu Gao, and Changsheng Xu. 2025. Navmorph: A self-evolving world model for vision-and-language navigation in continuous environments. *arXiv preprint arXiv:2506.23468*.

Jiabo Ye, Xi Zhang, Haiyang Xu, Haowei Liu, Junyang Wang, Zhaoqing Zhu, Ziwei Zheng, Feiyu Gao, Junjie Cao, Zhengxi Lu, and 1 others. 2025. Mobile-agent-v3: Fundamental agents for gui automation. *arXiv preprint arXiv:2508.15144*.

Juyeon Yoon, Robert Feldt, and Shin Yoo. 2024. Intent-driven mobile gui testing with autonomous large language model agents. In *2024 IEEE Conference on Software Testing, Verification and Validation (ICST)*, pages 129–139. IEEE.

Shengcheng Yu, Chunrong Fang, Ziyuan Tuo, Quanjun Zhang, Chunyang Chen, Zhenyu Chen, and Zhendong Su. 2023. Vision-based mobile app gui testing: A survey. *ACM Computing Surveys*.

Zhixiong Zeng, Jing Huang, Liming Zheng, Wenkang Han, Yufeng Zhong, Lei Chen, Longrong Yang, Yingjie Chu, Yuzhi He, and Lin Ma. 2025. Uitron: Foundational gui agent with advanced perception and planning. *arXiv preprint arXiv:2508.21767*.

Jiwen Zhang, Jihao Wu, Teng Yihua, Minghui Liao, Nuo Xu, Xiao Xiao, Zhongyu Wei, and Duyu Tang. 2024. Android in the zoo: Chain-of-action-thought for gui agents. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 12016–12031.

Zhuosheng Zhang and Aston Zhang. 2024. You only look at screens: Multimodal chain-of-action agents. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 3132–3149.

Enshen Zhou, Yiran Qin, Zhenfei Yin, Yuzhou Huang, Ruimao Zhang, Lu Sheng, Yu Qiao, and Jing Shao. 2024. Minedreamer: Learning to follow instructions via chain-of-imagination for simulated-world control. *arXiv preprint arXiv:2403.12037*.

A 提示模板

A.1 预测树提示模板

MobileDreamer 中预测树的模板如表 A.1所示。

A.2 GUI 智能体指令模板

GUI 智能体任务规划器的模板如表 7所示。

A.3 世界模型评估指标

mIoU mIoU 衡量所有匹配元素对的平均 IoU，反映预测布局与真实布局之间的几何一致性。

文本相似度 文本相似度衡量匹配元素之间的文本一致性，基于 Levenshtein 编辑距离计算归一化相似度：

$$\text{TextSimilarity}(s_1, s_2) = 1 - \frac{\text{EditDistance}(s_1, s_2)}{\max(|s_1|, |s_2|)}.$$

精确率 精确率量化了在所有预测元素中正确匹配的预测元素的比例。计算公式为：

$$P = \frac{\text{TP}}{\text{TP} + \text{FP}}, \tag{8}$$

其中 TP 是真正例数量，即正确匹配到真实元素的预测元素，FP 是假正例数量，即未匹配任何真实元素的预测元素。

召回率 召回率衡量在所有真实元素中正确匹配的真实元素的比例。计算公式为：

$$R = \frac{\text{TP}}{\text{TP} + \text{FN}}, \tag{9}$$

其中 FN 是假负例数量，即未被任何预测元素匹配的真实元素。

F1 分数 F1 分数是精确率和召回率的调和平均数，提供了元素级对齐质量的平衡度量：

$$F1 = \frac{2PR}{P + R}. \tag{10}$$

该指标平衡了精确率和召回率，由于评估中使用了灵活的匹配准则，使其对位置（边界框）的微小变化和 OCR 文本噪声具有鲁棒性。

Table 6: 预测树中使用的提示模板。上方模块用于将预测树反馈给 GUI 智能体以进行动作选择。下方模块用于当深度 > 1 时，Actor 从预测的文本草图状态中生成后续候选动作。

[Reasoner] Action selection with Tree-of-Prediction (depth d=2). You are selecting the best action based on World Model prediction tree. Task: {GOAL} Current sub-task: {SUBTASK} The World Model has built a PREDICTION TREE showing what will happen for each candidate action: {TREE_TEXT} Based on the CURRENT SCREEN (shown in the image) and this prediction tree, select the best action. Consider: 1. Immediate effect (1st level prediction) 2. Long-term trajectory (2nd level predictions if available) 3. How well the predicted states align with what you see on the current screen and the task goal Reply with ONLY: <selection> Action Number: [1-{N}] Reason: [Your reasoning] </selection>
[Actor] Follow-up candidate actions from a predicted state (used when depth > 1). Based on a PREDICTED screen state (not a real screenshot), perform the next action to progress toward the task. Task: {GOAL} Current sub-task: {SUBTASK} Previous action taken: {PARENT_ACTION} [Predicted Screen State (Text Description)] {PREDICTED_STATE} Based on this predicted screen state, what would be the best next action? Generate {K} different candidate actions in JSON format. Each action should be one of: - Click: {"action": "click", "coordinate": [x, y]} - Type: {"action": "type", "text": "content"} - Scroll: {"action": "scroll", "scroll_direction": "up/down/left/right", "coordinate": [x, y]} - Wait: {"action": "wait"} Reply with {K} actions, one per line:

Table 7: Android World 中基于提示的 GUI 智能体基线所使用的规划器提示。

You are operating an Android phone as a GUI task planner. You will be given the current screenshot of the phone, together with the user instruction you need to fulfill.
Your task is to decide what operations should be performed in the following steps, based on the action history, your previous thoughts, current observation, and most importantly, your knowledge about common GUI tasks and the software you are operating.
Then, make the decision about the next sub-task starts from the current screen in natural language, together with a general multi-sub-task, long-horizon plan to accomplish the whole task. You can also provide your analyses and thoughts together with the long-horizon plan.
Your next sub-task will be executed by another assistant (i.e., actor), so you do not need to give accurate low-level actions such as clicking an element. Instead, give a general description of the next operation, such as "Go into the Hotel page, the icon on the top-left of the screen may be useful". Describe the characteristics of the element you want to operate.
Before you make decisions in each step, check whether the outcome of the last few actions has fulfilled your previous plan and operational intent. Write it down in the <reflection></reflection> section. Do not write your plan or thought here.
After making decision, briefly describe what you expect to see on the screen after your next action.
If there is information relevant to the task that you need to keep in memory on the current screen, such as a task list to be reported to the user, write it down as a note for further use. Otherwise, do not take notes.
Be aware that:
* Your next sub-task may contains several steps. If no action should be done now, use the "wait" operation.
Do not specify how to execute an action such as "click the xxx icon" or "scroll down", you just need to describe what to do, and the actor will decide how to fulfill your operation.
For example, use "select the file README.md", "see more items below the current screen" instead of "click/long press on the README.md file to select it", "scroll down to see more items".
* You may need to infer the meaning of items from both their titles and icons.
* The actor may take several steps to fulfill the operation, so if the actor has not finished your last operation, be patient for a few steps. Note that some sub-actions in an operation may not change the screen, such as clicking the input field, so please remind the actor about what it has done in the last step in this case.
Moreover, the actor may not correctly execute your next operation, or your decision may be incorrect. If you find that the result of an operation does not match your expectations, promptly revise your plan and correct any errors, or let the actor try again.
NEVER post the exact same content as your previous reply. Add a description of the actor's actions if you need to repeat the last operation.
You may navigate back to the previous page to withdraw the wrong action or take other actions to correct it.
If the task is stuck for over 3 steps, report "infeasible" to the actor. You should remind the actor the first time you find the action is stuck.
* Update your long-horizon plan and notes after each execution.
* To open an APP, simply state "Open the [APP name]" in your operation. Do not use search or manual navigation methods such as "Scroll down to open the APP drawer and find the camera icon".
Available APPs are: {APP_LIST}.
* Pay attention to the implicit meanings of text formats. For example, gray text may indicate that a task is complete in a task list, or default content in an input field. Consider these meanings when fulfilling the user instruction.
* When you want to input text, just remind the actor whether to clear the existing contents. Do not take clearing as a independent operation. Directly give the content you want to input. DO NOT use the keyboard on the screen.
* Ignore system errors (e.g., failed messages) and continue with remaining tasks.
* For scroll action: you are NOT using a natural swipe, which means the "up" direction is to view the content above the current screen, or to swipe your finger down from top to bottom, and so on for other directions.
* Avoid unnecessary steps. Always try to complete the task in the fewest possible steps.
* The user instruction might be inaccurate, so consider how humans understand this instruction.
* If you need to use the content of an image, do not use thumbnails, click to check full content of the image.
* If you think the task is successful or infeasible, respond "Ignore the screenshot, terminate the task with status 'xxx' using the terminate tool" in the next operation part.
* If the user instruction asks you to answer a question, summarize from observations and notes, then respond "Ignore the screenshot, answer with the sentence: 'xxx' using the answer tool" in the next operation part. Follow the user's format requirements strictly.
Attention: Get full information if the text related to your task is truncated (such as ending with "..." or cut off by the screen bottom).
You should reply strictly according to the following format:
<reflection>Check the outcome of previous actions here.</reflection>
<plan>Your long-horizon plan here.</plan>
<thought>Your thought about the next SINGLE step.</thought>
<operation>Your next sub-task here.</operation>
<expection>The expected screen content after operation.</expection>
<note>Write down notes here. Can be empty.</note>