DeepSeek-V4：
面向高效百万 Token 上下文智能

（原文：DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence）

DeepSeek-AI
research@deepseek.com

Abstract

我们介绍 DeepSeek-V4 系列的预览版本，其中包含两款强大的混合专家（Mixture-of-Experts，MoE）语言模型——参数量为 1.6T（激活参数 49B）的 DeepSeek-V4-Pro，以及参数量为 284B（激活参数 13B）的 DeepSeek-V4-Flash——两款模型均支持高达一百万 token 的上下文长度。DeepSeek-V4 系列在架构和优化方面引入了若干关键升级：(1) 结合压缩稀疏注意力（Compressed Sparse Attention，CSA）与重度压缩注意力（Heavily Compressed Attention，HCA）的混合注意力架构，以提升长上下文处理效率；(2) 流形约束超连接（Manifold-Constrained Hyper-Connections，mHC），用于增强传统残差连接；(3) Muon 优化器，以加速收敛并提升训练稳定性。我们在超过 32T 多样化高质量 token 上对两款模型进行预训练，随后经过全面的后训练流程，进一步释放并提升其能力。DeepSeek-V4-Pro 的最大推理模式 DeepSeek-V4-Pro-Max 重新定义了开源模型的最优水平，在核心任务上超越了其前代模型。与此同时，DeepSeek-V4 系列在长上下文场景中展现出极高的效率：在百万 token 上下文设置下，DeepSeek-V4-Pro 的单 token 推理浮点计算量（FLOPs）仅为 DeepSeek-V3.2 的 27%，KV 缓存占用仅为其 10%。这使我们能够常态化支持百万 token 上下文，从而使长程任务和进一步的推理时扩展（test-time scaling）更加可行。模型检查点可从 https://huggingface.co/collections/deepseek-ai/deepseek-v4 获取。

图 1 说明：左图为 DeepSeek-V4-Pro-Max 与同类顶尖模型（Claude-Opus-4.6-Max、GPT-5.4-xHigh、Gemini-3.1-Pro-High 等）在多项基准测试（HLE、Apex Codeforces、SWE-Verified、Terminal Bench 2.0、Toolathlon 等）上的性能对比；右图对比了 DeepSeek-V4 系列与 DeepSeek-V3.2 的单 token 推理 FLOPs 及 KV 缓存大小，DeepSeek-V4-Pro 推理 FLOPs 降低 3.7 倍，KV 缓存缩小 9.5 倍；DeepSeek-V4-Flash 推理 FLOPs 降低 9.8 倍，KV 缓存缩小 13.7 倍。

Contents

1 引言 **4**

2 架构 **5**
2.1 继承自 DeepSeek-V3 的设计 . . . 6
2.2 流形约束超连接（mHC） . . . 6
2.3 基于 CSA 和 HCA 的混合注意力 . . . 7
2.3.1 压缩稀疏注意力（CSA） . . . 7
2.3.2 重度压缩注意力（HCA） . . . 8
2.3.3 其他细节 . . . 9
2.3.4 效率分析 . . . 10
2.4 Muon 优化器 . . . 10

3 通用基础设施 **11**
3.1 专家并行中的细粒度通信计算重叠 . . . 11
3.2 基于 TileLang 的灵活高效内核开发 . . . 12
3.3 高性能批次无关且确定性的内核库 . . . 13
3.4 FP4 量化感知训练 . . . 13
3.5 训练框架 . . . 14
3.5.1 Muon 的高效实现 . . . 14
3.5.2 mHC 的低成本内存高效实现 . . . 14
3.5.3 长上下文注意力的上下文并行 . . . 15
3.5.4 用于灵活激活检查点的扩展自动微分 . . . 15
3.6 推理框架 . . . 15
3.6.1 KV 缓存结构与管理 . . . 15
3.6.2 磁盘 KV 缓存存储 . . . 16

4 预训练 **17**
4.1 数据构建 . . . 17
4.2 预训练设置 . . . 17
4.2.1 模型设置 . . . 17
4.2.2 训练设置 . . . 17
4.2.3 缓解训练不稳定性 . . . 18
4.3 评估 . . . 18
4.3.1 评估基准 . . . 18
4.3.2 评估结果 . . . 19

5 后训练 **19**
5.1 后训练流水线 . . . 19
5.1.1 领域专家训练 . . . 19
5.1.2 在线策略蒸馏 . . . 21
5.2 RL 与 OPD 基础设施 . . . 21
5.2.1 FP4 量化集成 . . . 21
5.2.2 全词汇量 OPD 的高效教师调度 . . . 21
5.2.3 可抢占且容错的 Rollout 服务 . . . 22
5.2.4 面向百万 Token 上下文扩展的 RL 框架 . . . 22
5.2.5 面向智能体 AI 的沙箱基础设施 . . . 22
5.3 标准基准评估 . . . 23
5.3.1 评估设置 . . . 23
5.3.2 评估结果 . . . 23
5.4 真实任务性能 . . . 24

5.4.1 中文写作 24
5.4.2 搜索 25
5.4.3 白领任务 25
5.4.4 代码智能体 25

6 结论、局限性与未来方向 **26**

A 作者列表与致谢 **26**
A.1 作者列表 26
A.2 致谢 27

B 评测详情 **27**

1 引言

推理模型 (DeepSeek-AI, 2025; OpenAI, 2024c) 的出现确立了推理时扩展（test-time scaling）的全新范式，为大型语言模型（Large Language Models，LLMs）带来了显著的性能提升。然而，这一扩展范式从根本上受制于原始注意力机制（Vaswani et al., 2017）的二次方计算复杂度，使其在超长上下文和推理过程中面临严重的计算瓶颈。与此同时，从复杂的智能体工作流到大规模跨文档分析，各类长程任务场景的涌现也使高效支持超长上下文成为未来发展的关键。尽管近期的开源工作 (Bai et al., 2025a; DeepSeek-AI, 2024; MiniMax, 2025; Qwen, 2025) 在通用能力上取得了显著进展，但在处理超长序列时的核心架构低效问题仍是主要障碍，制约了推理时扩展的进一步收益，也阻碍了对长程任务的深入探索。

为突破超长上下文的效率瓶颈，我们研发了 DeepSeek-V4 系列，包括参数量为 1.6T（激活参数 49B）的 DeepSeek-V4-Pro 预览版，以及参数量为 284B（激活参数 13B）的 DeepSeek-V4-Flash 预览版。通过架构创新，DeepSeek-V4 系列在超长序列的计算效率上实现了飞跃。这一突破使高效支持百万 token 上下文成为可能，开启了下一代大型语言模型的超长上下文新纪元。我们相信，高效处理超长序列的能力将解锁推理时扩展的下一个前沿领域，为深入研究长程任务铺平道路，并为探索在线学习等未来新范式奠定必要基础。

与 DeepSeek-V3 架构（DeepSeek-AI, 2024）相比，DeepSeek-V4 系列保留了 DeepSeekMoE 框架（Dai et al., 2024）和多 token 预测（Multi-Token Prediction，MTP）策略，同时在架构和优化方面引入了若干关键创新。为提升长上下文效率，我们设计了结合压缩稀疏注意力（Compressed Sparse Attention，CSA）与重度压缩注意力（Heavily Compressed Attention，HCA）的混合注意力机制。CSA 沿序列维度对 KV 缓存进行压缩，并在此基础上执行 DeepSeek 稀疏注意力（DeepSeek Sparse Attention，DSA）(DeepSeek-AI, 2025)；HCA 则对 KV 缓存进行更激进的压缩，但保持稠密注意力计算。为增强建模能力，我们引入了流形约束超连接（Manifold-Constrained Hyper-Connections，mHC）(Xie et al., 2026)，以升级传统的残差连接。此外，我们将 Muon (Jordan et al., 2024; Liu et al., 2025) 优化器引入 DeepSeek-V4 系列的训练，从而加速收敛并提升训练稳定性。

为支持 DeepSeek-V4 系列的高效训练与推理，并提升开发生产力，我们引入了若干基础设施优化。首先，我们为 MoE 模块设计并实现了单一融合内核，实现计算、通信与内存访问的完全重叠。其次，我们采用 TileLang (Wang et al., 2026)——一种领域特定语言（Domain-Specific Language，DSL）——以在开发效率和运行时性能之间取得平衡。第三，我们提供高效的批次无关（batch-invariant）且确定性的内核库，以确保训练与推理之间的逐比特可复现性。第四，我们针对 MoE 专家权重以及索引器 QK 路径引入 FP4 量化感知训练，以降低内存占用和计算量。第五，在训练框架方面，我们用张量级检查点扩展了自动微分框架，以支持细粒度的重计算控制；并通过针对 Muon 优化器的混合 ZeRO 策略、基于重计算和融合内核的高性价比 mHC 实现，以及用于管理压缩注意力的两阶段上下文并行（contextual parallelism），提升了训练效率。最后，在推理框架方面，我们设计了具备磁盘存储策略的异构 KV 缓存结构，以实现高效的共享前缀复用。

通过混合 CSA 和 HCA，并结合计算与存储的精度优化，DeepSeek-V4 系列相较于 DeepSeek-V3.2 实现了显著更低的推理 FLOPs 和大幅缩减的 KV 缓存大小，在长上下文场景下尤为突出。图 1 右部展示了 DeepSeek-V3.2 和 DeepSeek-V4 系列的单 token 推理 FLOPs 估计值及累积 KV 缓存大小。在百万 token 上下文场景下，即便是拥有更多激活参数的 DeepSeek-V4-Pro，其单 token FLOPs（以等效 FP8 FLOPs 衡量）也仅为 DeepSeek-V3.2 的 27%，KV 缓存大小仅为其 10%。此外，激活参数更少的 DeepSeek-V4-Flash 将效率进一步提升：在百万 token 上下文设置下，其单 token FLOPs 仅为 DeepSeek-V3.2 的 10%，KV 缓存大小仅为其 7%。另外，DeepSeek-V4 系列的路由专家参数采用 FP4 精度。尽管在现有硬件上 FP4×FP8 运算的峰值 FLOPs 与 FP8×FP8 相同，但理论上在未来硬件上可实现比后者高 1/3 的效率，这将进一步提升 DeepSeek-V4 系列的效率。

在预训练阶段，我们分别用 32T token 训练 DeepSeek-V4-Flash，用 33T token 训练 DeepSeek-V4-Pro。预训练完成后，这两个模型均能原生高效地支持百万 token 长度的上下文。在我们的内部评估中，DeepSeek-V4-Flash-Base 凭借其更高的参数效率设计，已在大多数基准测试上超越了 DeepSeek-V3.2-Base。DeepSeek-V4-Pro-Base 在此基础上进一步扩大优势，成为 DeepSeek 基础模型中新的性能标杆，在推理、代码、长上下文和世界知识任务上全面领先。

DeepSeek-V4 系列的后训练流程采用两阶段范式：首先独立培养各领域专家，随后通过在线策略蒸馏（on-policy distillation, Lu and Lab, 2025）实现统一模型整合。具体而言，首先针对每个目标领域（如数学、代码、智能体和指令跟随）独立训练专属专家模型：基础模型先通过在高质量领域特定数据上进行监督微调（Supervised Fine-Tuning，SFT）建立基础能力，随后利用基于组相对策略优化（Group Relative Policy Optimization，GRPO）（DeepSeek-AI, 2025）的强化学习（Reinforcement Learning，RL），以针对特定成功标准定制的奖励模型为导向，进一步优化模型的领域对齐行为。该阶段产生一组多样化的领域专家，每个专家在各自领域均表现出色。最终，为整合这些不同专长，通过在线策略蒸馏训练单一统一模型：统一模型作为学生，以教师模型为目标，优化反向 KL 散度损失。

核心评估结果摘要

- **知识(Knowledge):**在广泛世界知识的评估中,DeepSeek-V4-Pro 的最大推理模式 DeepSeek-V4-Pro-Max 在 SimpleQA (OpenAI, 2024d) 和 Chinese-SimpleQA (He et al., 2024) 基准上显著优于领先的开源模型。在教育知识方面——通过 MMLU-Pro (Wang et al., 2024b)、HLE (Phan et al., 2025) 和 GPQA (Rein et al., 2023) 进行评估——DeepSeek-V4-Pro-Max 对开源模型保有小幅领先。尽管在这些知识类评估中仍落后于领先的专有模型 Gemini-3.1-Pro，但 DeepSeek-V4-Pro-Max 已显著缩小了与之的差距。

- **推理（Reasoning）:** 通过扩展推理 token 数量，DeepSeek-V4-Pro-Max 在标准推理基准上的表现优于 GPT-5.2 和 Gemini-3.0-Pro。然而，其性能仍略逊于 GPT-5.4 和 Gemini-3.1-Pro，表明其发展轨迹落后于最前沿模型约 3 至 6 个月。此外，DeepSeek-V4-Flash-Max 在复杂推理任务上取得了与 GPT-5.2 和 Gemini-3.0-Pro 相当的性能，确立了其作为高性价比推理架构的地位。

- **智能体（Agent）:** 在公开基准上，DeepSeek-V4-Pro-Max 与 Kimi-K2.6、GLM-5.1 等领先开源模型相当，但略逊于前沿闭源模型。在我们的内部评估中，DeepSeek-V4-Pro-Max 超越了 Claude Sonnet 4.5，并接近 Opus 4.5 的水平。

- **长上下文（Long-Context）:** DeepSeek-V4-Pro-Max 在百万 token 上下文窗口的合成及真实场景测试中均表现出色，在学术基准上甚至超越了 Gemini-3.1-Pro。

- **DeepSeek-V4-Pro vs. DeepSeek-V4-Flash:** 由于参数规模较小，DeepSeek-V4-Flash-Max 在知识评估中表现稍弱。然而，在分配更大思考预算时，它在推理任务上取得了与 DeepSeek-V4-Pro-Max 相当的结果。在智能体评估中，DeepSeek-V4-Flash-Max 在若干基准上与 DeepSeek-V4-Pro-Max 性能相当，但在更复杂、高难度任务上仍落后于后者。

图 2 说明： DeepSeek-V4 系列的整体架构。注意力层采用混合 CSA（压缩稀疏注意力）和 HCA（重度压缩注意力），前馈层采用 DeepSeekMoE，并以 mHC 增强传统残差连接。

2 架构

总体而言，DeepSeek-V4 系列保留了 Transformer (Vaswani et al., 2017) 架构和多 token 预测（Multi-Token Prediction，MTP）模块 (DeepSeek-AI, 2024; Gloeckle et al., 2024)，同时在 DeepSeek-V3 基础上引入了若干关键升级：(1) 引入流形约束超连接（Manifold-Constrained Hyper-Connections，mHC）(Xie et al., 2026)，以增强传统残差连接；(2) 设计混合注意力架构，通过压缩稀疏注意力（CSA）和重度压缩注意力（HCA）大幅提升长上下文效率；(3) 采用 Muon (Jordan et al., 2024; Liu et al., 2025) 优化器。在混合专家（MoE）组件方面，我们仍沿用 DeepSeekMoE (Dai et al., 2024) 架构，相较 DeepSeek-V3 仅做了少量调整。多 token 预测（MTP）(DeepSeek-AI, 2024; Gloeckle et al., 2024; Li et al., 2024; Qi et al., 2020) 的配置与 DeepSeek-V3 完全相同。其余未特别说明的细节均沿用 DeepSeek-V3 (DeepSeek-AI, 2024) 的设定。图 2 展示了 DeepSeek-V4 的整体架构，下面将详细介绍各部分。

2.1 继承自 DeepSeek-V3 的设计

混合专家（MoE）。与前代 DeepSeek 系列模型（DeepSeek-AI, 2024）一样，DeepSeek-V4 系列在前馈网络（Feed-Forward Networks，FFNs）中采用 DeepSeekMoE 范式 (Dai et al., 2024)，设置细粒度路由专家和共享专家。与 DeepSeek-V3 不同的是，我们将计算亲和分数（affinity scores）的激活函数从 Sigmoid$(\cdot)$ 改为 $\sqrt{\mathrm{Softplus}(\cdot)}$。在负载均衡方面，同样采用无辅助损失策略 (DeepSeek-AI, 2024; Wang et al., 2024a)，并增加了轻微的序列级均衡损失，以防止单一序列内部出现极端不均衡。对于 DeepSeek-V4，我们取消了路由目标节点数量的限制，并仔细重新设计了并行策略以维持训练效率。此外，与 DeepSeek-V3 相比，我们将前几个 Transformer 块中的稠密前馈网络层替换为采用哈希路由（Hash routing）(Roller et al., 2021) 的 MoE 层。哈希路由策略根据关于输入 token ID 的预定义哈希函数，确定每个 token 的目标专家。

多 token 预测（MTP）。与 DeepSeek-V3 一样，DeepSeek-V4 系列也设置了 MTP 模块和目标函数。由于 MTP 策略已在 DeepSeek-V3 中得到验证，我们对 DeepSeek-V4 系列沿用相同策略，不做任何修改。

2.2 流形约束超连接（mHC）

如图 2 所示，DeepSeek-V4 系列引入了流形约束超连接（Manifold-Constrained Hyper-Connections，mHC）(Xie et al., 2026)，用于增强相邻 Transformer 块之间的传统残差连接。与朴素超连接（HC）(Zhu et al., 2025) 相比，mHC 的核心思想是将残差映射约束到特定流形上，从而在保持模型表达能力的同时，增强跨层信号传播的稳定性。本节简要介绍标准 HC，并描述我们如何为稳定训练设计 mHC。

标准超连接（Standard Hyper-Connections）。标准 HC 将残差流的宽度扩展 n_{hc} 倍。具体而言，残差流的形状从 $\mathbb{R}^d$ 扩展到 $\mathbb{R}^{n_{\mathrm{hc}}\times d}$，其中 d 是实际层输入的隐藏维度。设 $X_l = [x_{l,1};\ldots;x_{l,n_{\mathrm{hc}}}]^T \in \mathbb{R}^{n_{\mathrm{hc}}\times d}$ 为第 l 层之前的残差状态。HC 引入三个线性映射：输入映射 $A_l \in \mathbb{R}^{1\times n_{\mathrm{hc}}}$、残差变换 $B_l \in \mathbb{R}^{n_{\mathrm{hc}}\times n_{\mathrm{hc}}}$ 和输出映射 $C_l \in \mathbb{R}^{n_{\mathrm{hc}}\times 1}$。残差状态的更新公式为：

$$X_{l+1} = B_l X_l + C_l F_l(A_l X_l), \tag{1}$$

其中 F_l 表示第 l 层（例如 MoE 层），其输入和输出形状均为 $\mathbb{R}^d$。注意，实际层输入 $A_l X_l \in \mathbb{R}^d$ 也是 d 维的，因此扩展后的残差宽度不影响内部层的设计。HC 将残差宽度与实际隐藏维度解耦，以较小的计算开销提供了一个互补的扩展轴（通常 n_{hc} 远小于隐藏维度 d）。然而，尽管 HC 展现出提升模型性能的潜力，我们发现在堆叠多层时训练常常出现数值不稳定性，这阻碍了 HC 的规模扩展。

流形约束残差映射（Manifold-Constrained Residual Mapping）。 mHC 的核心创新是将残差映射矩阵 B_l 约束到双随机矩阵的流形（Birkhoff 多面体）$\mathcal{M}$ 上，从而增强跨层信号传播的稳定性：

$$B_l \in \mathcal{M} := \{M \in \mathbb{R}^{n\times n} \mid M\mathbf{1}_n = \mathbf{1}_n,\ \mathbf{1}_n^T M = \mathbf{1}_n^T,\ M \geq 0\}. \tag{2}$$

该约束确保映射矩阵的谱范数 $\|B_l\|_2$ 有界于 1，使残差变换成为非扩张的，从而提高前向传播和反向传播过程中的数值稳定性。此外，集合 $\mathcal{M}$ 在乘法下封闭，保证了深层 mHC 堆叠时的稳定性。输入变换 A_l 和输出变换 C_l 也被约束为非负且通过 Sigmoid 函数有界，以避免信号抵消的风险。

动态参数化（Dynamic Parameterization）。三个线性映射的参数是动态生成的，被分解为动态（输入相关）分量和静态（输入无关）分量。给定输入 $X_l \in \mathbb{R}^{n_{\mathrm{hc}}\times d}$，首先将其展平并归一化：$\hat{X}_l = \mathrm{RMSNorm}(\mathrm{vec}(X_l)) \in \mathbb{R}^{1\times n_{\mathrm{hc}}d}$。然后沿用传统 HC 生成无约束原始参数 $\tilde{A}_l \in \mathbb{R}^{1\times n_{\mathrm{hc}}}$，$\tilde{B}_l \in \mathbb{R}^{n_{\mathrm{hc}}\times n_{\mathrm{hc}}}$，$\tilde{C}_l \in \mathbb{R}^{n_{\mathrm{hc}}\times 1}$：

$$\tilde{A}_l = \alpha_l^{\mathrm{pre}} \cdot (\hat{X}_l W_l^{\mathrm{pre}}) + S_l^{\mathrm{pre}}, \tag{3}$$

$$\tilde{B}_l = \alpha_l^{\mathrm{res}} \cdot \mathrm{Mat}(\hat{X}_l W_l^{\mathrm{res}}) + S_l^{\mathrm{res}}, \tag{4}$$

$$\tilde{C}_l = \alpha_l^{\mathrm{post}} \cdot (\hat{X}_l W_l^{\mathrm{post}}) + S_l^{\mathrm{post}}, \tag{5}$$

其中 $W_l^{\text{pre}}, W_l^{\text{post}} \in \mathbb{R}^{n_{\text{hc}} d \times n_{\text{hc}}}$ 和 $W_l^{\text{res}} \in \mathbb{R}^{n_{\text{hc}} d \times n_{\text{hc}}^2}$ 是生成动态分量的可学习参数；$\text{Mat}(\cdot)$ 将大小为 $1 \times n_{\text{hc}}^2$ 的向量重塑为 $n_{\text{hc}} \times n_{\text{hc}}$ 的矩阵；$S_l^{\text{pre}} \in \mathbb{R}^{1 \times n_{\text{hc}}}$，$S_l^{\text{post}} \in \mathbb{R}^{n_{\text{hc}} \times 1}$，$S_l^{\text{res}} \in \mathbb{R}^{n_{\text{hc}} \times n_{\text{hc}}}$ 是可学习的静态偏置；$\alpha_l^{\text{pre}}, \alpha_l^{\text{res}}, \alpha_l^{\text{post}}$ 是初始化为小值的可学习门控因子。

施加参数约束（Applying Parameter Constraints）。获得无约束原始参数 $\tilde{A}_l, \tilde{B}_l, \tilde{C}_l$ 后，对其施加约束以增强数值稳定性。具体而言，对输入和输出映射采用 Sigmoid 函数 $\sigma(\cdot)$ 以确保非负性和有界性：

$$A_l = \sigma(\tilde{A}_l), \tag{6}$$

$$C_l = 2\sigma(\tilde{C}_l). \tag{7}$$

对于残差映射 $\tilde{B}_l$，将其投影到双随机矩阵流形 $\mathcal{M}$ 上。具体通过 Sinkhorn-Knopp 算法实现：首先对 $\tilde{B}_l$ 取指数函数以保证正性，得 $M^{(0)} = \exp(\tilde{B}_l)$，然后迭代执行列和行归一化：

$$M^{(t)} = T_r(T_c(M^{(t-1)})), \tag{8}$$

其中 T_r 和 T_c 分别表示行归一化和列归一化。迭代收敛后得到约束双随机矩阵 $B_l = M^{(t_{\max})}$，实践中取 $t_{\max} = 20$。

图 3 说明： CSA 的核心架构。CSA 将 KV 条目压缩为原来的 $\frac{1}{m}$，然后应用 DeepSeek 稀疏注意力进行进一步加速。此外，结合少量滑动窗口 KV 条目与已选择的压缩 KV 条目，以增强局部细粒度依赖关系的建模。

2.3 基于 CSA 和 HCA 的混合注意力

当上下文长度达到极端规模时，注意力机制成为模型中占主导地位的计算瓶颈。对于 DeepSeek-V4，我们设计了两种高效注意力架构——压缩稀疏注意力（Compressed Sparse Attention，CSA）和重度压缩注意力（Heavily Compressed Attention，HCA）——并采用二者交错的混合配置，从而在长文本场景中大幅降低注意力的计算开销。CSA 融合了压缩和稀疏注意力策略：首先将每 m 个 token 的键值（Key-Value，KV）缓存压缩为一个条目，然后应用 DeepSeek 稀疏注意力（DeepSeek Sparse Attention，DSA）(DeepSeek-AI, 2025)，使每个查询 token 仅关注 k 个压缩 KV 条目。HCA 追求极致压缩，将每 m' ($\gg m$) 个 token 的 KV 缓存合并为单个条目。CSA 和 HCA 的混合架构显著提升了 DeepSeek-V4 系列的长上下文效率，使百万 token 的上下文在实践中成为可能。本节描述我们混合注意力架构的核心技术，并提供了开源实现以明确更多细节。

2.3.1 压缩稀疏注意力（CSA）

CSA 的核心架构如图 3 所示。CSA 首先将每 m 个 token 的 KV 缓存压缩为一个条目，然后应用 DeepSeek 稀疏注意力进一步加速。

压缩键值条目（Compressed Key-Value Entries）。设 $H \in \mathbb{R}^{n \times d}$ 为输入隐藏状态序列，其中 n 为序列长度，d 为隐藏维度。CSA 首先计算两组 KV 条目 $C^a, C^b \in \mathbb{R}^{n \times c}$ 及其对应的压缩权重 $Z^a, Z^b \in \mathbb{R}^{n \times c}$，其中 c 为头维度：

$$C^a = H \cdot W^{aKV}, \quad C^b = H \cdot W^{bKV}, \tag{9}$$

$$Z^a = H \cdot W^{aZ}, \quad Z^b = H \cdot W^{bZ}, \tag{10}$$

其中 $W^{aKV}, W^{bKV}, W^{aZ}, W^{bZ} \in \mathbb{R}^{d \times c}$ 为可训练参数。接下来，C^a 和 C^b 中每 m 个 KV 条目将根据压缩权重和可学习位置偏置 $B^a, B^b \in \mathbb{R}^{m \times c}$ 压缩为一个条目，产生 $C^{\text{Comp}} \in \mathbb{R}^{n/m \times c}$。每个压缩条目 $C_i^{\text{Comp}} \in \mathbb{R}^c$ 通过以下方式计算：

$$[S^a_{mi:m(i+1)-1}; S^b_{m(i-1):mi-1}] = \text{Softmax}_{\text{row}}([Z^a_{mi:m(i+1)-1} + B^a; Z^b_{m(i-1):mi-1} + B^b]), \tag{11}$$

$$C_i^{\text{Comp}} = \sum_{j=mi}^{m(i+1)-1} S_j^a \odot C_j^a + \sum_{j=m(i-1)}^{mi-1} S_j^b \odot C_j^b, \tag{12}$$

其中 $\odot$ 表示 Hadamard 乘积；$\mathrm{Softmax}_{\mathrm{row}}(\cdot)$ 表示沿行维度的 softmax 操作，对来自 Z^a 和 Z^b 的总共 $2m$ 个元素进行归一化。当 $i=0$ 时，$Z^b_{m(i-1):mi-1}$ 用负无穷填充，$C^b_{m(i-1):mi-1}$ 用零填充。注意每个 C^{Comp}_i 来自 $2m$ 个 KV 条目，但 C^b 用于 C^{Comp}_i 的索引与 C^a 用于 C^{Comp}_{i-1} 的索引有重叠。因此，CSA 实际上将序列长度压缩为原来的 $\frac{1}{m}$。

闪电索引器（Lightning Indexer）的稀疏选择。得到压缩 KV 条目 C^{Comp} 后，CSA 应用 DSA 策略选择 top-k 压缩 KV 条目进行核心注意力计算。首先，CSA 用相同的压缩操作得到压缩索引键 $K^{I\mathrm{Comp}} \in \mathbb{R}^{n/m \times c_I}$，其中 c_I 为索引头维度。然后，对于查询 token t，以低秩方式生成索引查询 $\{q^{I,1}_t; q^{I,2}_t; \ldots; q^{I,n^I_h}_t\}$：

$$c^Q_t = h_t \cdot W^{DQ}, \tag{13}$$

$$q^I_t = [q^{I,1}_t; \ldots; q^{I,n^I_h}_t] = c^Q_t \cdot W^{IUQ}, \tag{14}$$

其中 $h_t \in \mathbb{R}^d$ 为查询 token t 的输入隐藏状态；$c^Q_t \in \mathbb{R}^{d_c}$ 为查询的压缩潜向量；d_c 为查询压缩维度；n^I_h 为索引查询头数；$W^{DQ} \in \mathbb{R}^{d \times d_c}$ 和 $W^{IUQ} \in \mathbb{R}^{d_c \times c_I n^I_h}$ 分别为索引查询的下投影和上投影矩阵。查询 token t 与前驱压缩块 s（$s < \lfloor t/m \rfloor$）之间的索引分数 $I_{t,s} \in \mathbb{R}$ 计算如下：

$$w^I_t = [w^{I,1}_t; \ldots; w^{I,n^I_h}_t] = h_t \cdot W^w, \tag{15}$$

$$I_{t,s} = \sum_{h=1}^{n^I_h} w^{I,h}_t \cdot \mathrm{ReLU}(q^{I,h}_t \cdot K^{I\mathrm{Comp}}_s), \tag{16}$$

其中 $W^w \in \mathbb{R}^{d \times n^I_h}$ 为可学习矩阵；$w^{I,h}_t \in \mathbb{R}$ 为第 h 个索引头的权重。对于查询 token t，根据索引分数 $I_{t,:}$，采用 top-k 选择器保留压缩 KV 条目的子集 $\mathcal{C}^{\mathrm{SprsComp}}_t$ 用于后续核心注意力：

$$\mathcal{C}^{\mathrm{SprsComp}}_t = \{C^{\mathrm{Comp}}_s \mid I_{t,s} \in \mathrm{Top}\text{-}k(I_{t,:})\}. \tag{17}$$

共享键值多查询注意力（Shared Key-Value MQA）。选出稀疏 KV 条目后，CSA 以多查询注意力（Multi-Query Attention，MQA）(Shazeer, 2019) 方式执行核心注意力，其中 $\mathcal{C}^{\mathrm{SprsComp}}_t$ 中的每个压缩 KV 条目同时作为注意力键和值。具体而言，对于查询 token t，首先从压缩潜向量 c^Q_t 生成注意力查询 $\{q_{t,1}; \ldots; q_{t,n_h}\}$：

$$q_t = [q_{t,1}; \ldots; q_{t,n_h}] = c^Q_t \cdot W^{UQ}, \tag{18}$$

其中 n_h 为查询头数；$W^{UQ} \in \mathbb{R}^{d_c \times cn_h}$ 为查询的上投影矩阵。注意潜在查询向量 c^Q_t 与索引查询共享。然后对 $\{q_{t,i}\}$ 和 $\mathcal{C}^{\mathrm{SprsComp}}_t$ 执行 MQA：

$$o_{t,i} = \mathrm{CoreAttn}(\mathrm{query} = q_{t,i},\ \mathrm{key} = \mathcal{C}^{\mathrm{SprsComp}}_t,\ \mathrm{value} = \mathcal{C}^{\mathrm{SprsComp}}_t), \tag{19}$$

其中 $o_{t,i} \in \mathbb{R}^c$ 为第 t 个 token 第 i 个头的核心注意力输出；$\mathrm{CoreAttn}(\cdot)$ 表示核心注意力操作。

分组输出投影（Grouped Output Projection）。在 DeepSeek-V4 的配置中，cn_h 相当大。因此，直接将核心注意力输出 $o_t = [o_{t,1}; \ldots; o_{t,n_h}] \in \mathbb{R}^{cn_h}$ 投影到 d 维隐藏状态将带来巨大的计算负担。为降低此代价，我们设计了分组输出投影策略：首先将 n_h 个输出划分为 g 组，然后对每组输出 $o^G_{t,i} \in \mathbb{R}^{cn_h/g}$ 投影到 d_g 维中间输出 $o'^G_{t,i} \in \mathbb{R}^{d_g}$（其中 $d_g < cn_h/g$）。最终将中间输出 $[o'^G_{t,1}; \ldots; o'^G_{t,g}] \in \mathbb{R}^{d_g g}$ 投影到最终注意力输出 $\hat{o}_t \in \mathbb{R}^d$。

2.3.2 重度压缩注意力（HCA）

HCA 的核心架构如图 4 所示，其以更重度的方式压缩 KV 缓存，但不采用稀疏注意力。

图 4 说明： HCA 的核心架构。HCA 执行更重度的压缩，将 m'（$\gg m$）个 token 的 KV 条目合并为一个。同样引入少量滑动窗口 KV 条目以增强局部细粒度依赖关系。

压缩键值条目。总体而言，HCA 的压缩策略与 CSA 类似，但采用更大的压缩率 m'（$\gg m$），且不执行重叠压缩。设 $H \in \mathbb{R}^{n\times d}$ 为输入隐藏状态序列，HCA 首先计算原始 KV 条目 $C \in \mathbb{R}^{n\times c}$ 及其压缩权重 $Z \in \mathbb{R}^{n\times c}$：

$$C = H \cdot W^{KV}, \tag{20}$$

$$Z = H \cdot W^{Z}, \tag{21}$$

其中 $W^{KV}, W^{Z} \in \mathbb{R}^{d\times c}$ 为可训练参数。接下来，C 中每 m' 个 KV 条目将根据压缩权重和可学习位置偏置 $B \in \mathbb{R}^{m'\times c}$ 压缩为一个条目，产生 $C^{\mathrm{Comp}} \in \mathbb{R}^{n/m'\times c}$。每个压缩条目 $C_i^{\mathrm{Comp}} \in \mathbb{R}^{c}$ 计算方式如下：

$$S_{m'i:m'(i+1)-1} = \mathrm{Softmax}_{\mathrm{row}}(Z_{m'i:m'(i+1)-1} + B), \tag{22}$$

$$C_i^{\mathrm{Comp}} = \sum_{j=m'i}^{m'(i+1)-1} S_j \odot C_j. \tag{23}$$

通过此压缩操作，HCA 将序列长度压缩为原来的 $\frac{1}{m'}$。

共享键值 MQA 与分组输出投影。HCA 同样采用与 CSA 相同的共享 KV MQA 和分组输出投影策略。KV 压缩后，对于查询 token t，HCA 以低秩方式生成注意力查询 $\{q_{t,1}; \ldots; q_{t,n_h}\}$：

$$c_t^{Q} = h_t \cdot W^{DQ}, \tag{24}$$

$$q_t = [q_{t,1}; \ldots; q_{t,n_h}] = c_t^{Q} \cdot W^{UQ}, \tag{25}$$

其中 $h_t \in \mathbb{R}^{d}$ 为查询 token t 的输入隐藏状态；n_h 为查询头数；$W^{DQ} \in \mathbb{R}^{d\times d_c}$ 和 $W^{UQ} \in \mathbb{R}^{d_c\times cn_h}$ 分别为查询的下投影和上投影矩阵。然后对 $\{q_{t,i}\}$ 和 C^{Comp} 执行 MQA：

$$o_{t,i} = \mathrm{CoreAttn}(\mathrm{query} = q_{t,i},\ \mathrm{key} = C^{\mathrm{Comp}},\ \mathrm{value} = C^{\mathrm{Comp}}). \tag{26}$$

与 CSA 类似，HCA 将 n_h 个输出分为 g 组，对每组输出 $o_{t,i}^{G} \in \mathbb{R}^{cn_h/g}$ 投影到 d_g 维中间输出 $o_{t,i}'^{G} \in \mathbb{R}^{d_g}$，最终投影到注意力输出 $\hat{o}_t \in \mathbb{R}^{d}$。

2.3.3 其他细节

除上述 CSA 和 HCA 的核心架构外，我们的混合注意力还融入了若干其他技术。为保持行文简洁，上述介绍中略去了这些补充技术，本节将简要说明。另外，本节仅关注其核心思想，为简洁起见可能省略部分细节，读者可参考我们的开源实现获取完整信息。

查询和键值条目归一化（Query and Key-Value Entry Normalization）。对于 CSA 和 HCA，我们在核心注意力操作之前，对每个头的查询和压缩 KV 条目的唯一头额外执行 RMSNorm 操作。此归一化可避免注意力 logit 爆炸，并有助于提升训练稳定性。

部分旋转位置编码（Partial Rotary Positional Embedding）。对于 CSA 和 HCA，我们在注意力查询、KV 条目以及核心注意力输出中部分采用旋转位置编码（Rotary Positional Embedding，RoPE）(Su et al., 2024)。具体而言，对于 CSA 和 HCA 中每个查询向量和 KV 条目向量，我们对其最后 64 个维度应用 RoPE。由于 KV 条目同时充当注意力键和值，朴素核心注意力输出 $\{o_{t,i}\}$ 将携带绝对位置嵌入（来自 KV 条目的加权求和）。作为补偿，我们还对每个 $o_{t,i}$ 的最后 64 个维度应用位置为 $-i$ 的 RoPE。这样，核心注意力的输出也将携带相对位置嵌入——每个 KV 条目对核心注意力输出的贡献也与查询和 KV 条目之间的距离相关。

滑动窗口注意力附加分支（Additional Branch of Sliding Window Attention）。为严格保持 CSA 和 HCA 中的因果性，每个查询仅关注前驱的压缩 KV 块。因此，查询无法访问其所在压缩块内其他 token 的信息。与此同时，最近的 token 在语言建模中通常与查询 token 具有更强的相关性。为此，我们为 CSA 和 HCA 引入了一个以滑动窗口方式工作的辅助注意力分支，以更好地建模局部依赖关系。具体而言，对每个查询 token，额外生成对应最近 n_{win} 个 token 的 n_{win} 个未压缩 KV 条目。在 CSA 和 HCA 的核心注意力中，这些滑动窗口 KV 条目将与压缩 KV 条目一起使用。

注意力汇（Attention Sink）。在 CSA 和 HCA 的核心注意力中，我们采用注意力汇技巧 (OpenAI, 2025; Xiao et al., 2024)。具体而言，设置一组可学习的汇 logit $\{z'_1, z'_2, \ldots, z'_{n_h}\}$。对于第 h 个注意力头，$\exp(z'_h)$ 将被加到注意力分数的分母：

$$s_{h,i,j} = \frac{\exp(z_{h,i,j})}{\sum_k \exp(z_{h,i,k}) + \exp(z'_h)}, \tag{27}$$

其中 $s_{h,i,j}, z_{h,i,j} \in \mathbb{R}$ 分别为第 h 个注意力头中第 i 个查询 token 与第 j 个前驱 token 或压缩块之间的注意力分数和 logit。此技术允许每个查询头将其总注意力分数调整为不等于 1，甚至接近 0。

2.3.4 效率分析

由于混合采用 CSA 和 HCA，结合低精度计算和存储，DeepSeek-V4 系列的注意力模块在注意力 FLOPs 和 KV 缓存大小方面均实现了卓越的效率，在长上下文场景下尤为突出。首先，我们对 KV 条目采用混合存储格式：旋转位置编码（RoPE）维度使用 BF16 精度，其余维度使用 FP8 精度。与纯 BF16 存储相比，这种混合表示将 KV 缓存大小减少了近一半。其次，闪电索引器中的注意力计算以 FP4 精度进行，在极长上下文下加速注意力操作。第三，相较 DeepSeek-V3.2，DeepSeek-V4 系列选择了更小的注意力 top-k，从而提升模型在短中等长度文本上的效率。最后也是最重要的是，压缩注意力和混合注意力技术大幅降低了 KV 缓存大小和计算 FLOPs。

以头维度为 128 的 BF16 GQA8 (Ainslie et al., 2023) 作为基准——这是大型语言模型注意力的常见配置之一——在百万 token 上下文设置下，DeepSeek-V4 系列的 KV 缓存大小可显著降低至该基准的约 2%。即使与 DeepSeek-V3.2 (DeepSeek-AI, 2025)——已是高效基准——相比，DeepSeek-V4 系列在效率方面仍具有显著优势。两者推理 FLOPs 和 KV 缓存大小的对比见图 1 右部。

2.4 Muon 优化器

我们对 DeepSeek-V4 系列中的大多数模块采用 Muon (Jordan et al., 2024; Liu et al., 2025) 优化器，因其具有更快的收敛速度和更好的训练稳定性。我们的 Muon 优化完整算法如算法 1 所示。

算法 1 DeepSeek-V4 的 Muon 优化器

输入： 学习率 η，动量 μ，权重衰减 λ，更新缩放因子 γ

for 每个训练步骤 t **do**

for 每个逻辑独立权重 $W \in \mathbb{R}^{n \times m}$ **do**

$G_t = \nabla_W \mathcal{L}_t(W_{t-1})$ ▷ 计算梯度

$M_t = \mu M_{t-1} + G_t$ ▷ 积累动量缓冲区

$O'_t = \mathrm{HybridNewtonSchulz}(\mu M_t + G_t)$ ▷ Nesterov 技巧和混合 Newton-Schulz

$O_t = O'_t \cdot \sqrt{\max(n, m)} \cdot \gamma$ ▷ 缩放更新 RMS

$W_t = W_{t-1} \cdot (1 - \eta\lambda) - \eta O_t$ ▷ 执行权重衰减和更新

end for

end for

基本配置（Basic Configurations）。我们对嵌入模块、预测头模块、mHC 模块的静态偏置和门控因子，以及所有 RMSNorm 模块的权重保留 AdamW (Loshchilov and Hutter, 2017) 优化器，其余所有模块使用 Muon 更新。遵循 Liu et al. (2025)，我们对 Muon 参数同样施加权重衰减，使用 Nesterov (Jordan et al., 2024; Nesterov, 1983) 技巧，并对更新矩阵的均方根（Root Mean Square，RMS）进行缩放，以复用 AdamW 超参数。与其不同的是，我们使用混合 Newton-Schulz 迭代进行正交化。

混合 Newton-Schulz 迭代（Hybrid Newton-Schulz Iterations）。对于给定矩阵 M，设其奇异值分解（SVD）为 $M = U\Sigma V^T$。Newton-Schulz 迭代旨在将 M 近似正交化为 UV^T。通常先将 M 归一化为 $M_0 = M/\|M\|_F$ 以确保其最大奇异值不超过 1，然后每次迭代执行：

$$M_k = aM_{k-1} + b(M_{k-1}M_{k-1}^T)M_{k-1} + c(M_{k-1}M_{k-1}^T)^2 M_{k-1}. \tag{28}$$

我们的混合 Newton-Schulz 在两个不同阶段共执行 10 次迭代：前 8 步使用系数 $(a, b, c) = (3.4445, -4.7750, 2.0315)$ 驱动快速收敛，使奇异值趋近于 1；最后 2 步切换到系数 $(a, b, c) = (2, -1.5, 0.5)$，使奇异值精确稳定在 1。

避免注意力 Logit 爆炸（Avoiding Exploding Attention Logits）。DeepSeek-V4 系列的注意力架构允许直接在注意力查询和 KV 条目上应用 RMSNorm，有效防止注意力 logit 爆炸。因此，我们在 Muon 优化器中不采用 QK-Clip 技术 (Liu et al., 2025)。

3 通用基础设施

3.1 专家并行中的细粒度通信计算重叠

混合专家（MoE）模型可以通过专家并行（Expert Parallelism，EP）进行加速。然而，EP 需要复杂的节点间通信，对互连带宽和延迟提出了较高要求。为缓解 EP 中的通信瓶颈、在较低互连带宽要求下实现更高的端到端性能，我们提出了一种细粒度 EP 方案，将通信与计算融合到单个流水线内核中，实现通信与计算的重叠。

通信延迟可以被隐藏。我们 EP 方案的核心洞察是：在 MoE 层中，通信延迟可以有效地被隐藏于计算之下。如图 5 所示，在 DeepSeek-V4 系列中，每个 MoE 层主要可分解为四个阶段：两个通信受限阶段 Dispatch（分发）和 Combine（合并），以及两个计算受限阶段 Linear-1 和 Linear-2。我们的分析显示，在单个 MoE 层中，通信总时间少于计算总时间。因此，将通信与计算融合到统一流水线后，计算仍然是主要瓶颈，这意味着系统可以在不降低端到端性能的情况下容忍更低的互连带宽。

图 5 说明：我们的 EP 方案与相关工作的对比示意图。Comet (Zhang et al., 2025b) 分别将 Dispatch 与 Linear-1、Linear-2 与 Combine 重叠。我们的 EP 方案通过将专家分割调度成波次，实现了更细粒度的重叠。理论加速比在 DeepSeek-V4-Flash 架构配置下评估（理论加速比 1.92×）。

细粒度 EP 方案（Fine-Grained EP Scheme）。为进一步降低互连带宽需求并放大重叠收益，我们引入了更细粒度的专家分区方案。受众多相关工作 (Aimuyo et al., 2025; Zhang et al., 2025b) 启发，我们将专家分割调度为若干波次（waves），每个波次包含一小部分专家。某一波次内所有专家完成通信后，计算即可立刻开始，无需等待其他专家。在稳定状态下，当前波次的计算、下一波次的 token 传输，以及已完成专家的结果发送同步进行，如图 5 所示。这在专家间形成了细粒度流水线，使计算和通信在整个波次中保持持续进行。基于波次的调度还加速了极端情况下的性能，例如强化学习（RL）rollout——通常遇到长尾小批量问题。

性能与开源巨内核（Performance and Open-Sourced Mega-Kernel）。我们在 NVIDIA GPU 和华为 Ascend NPU 平台上均验证了细粒度 EP 方案。与强力的非融合基准相比，对于一般推理负载可实现 $1.50 \sim 1.73\times$ 加速，在 RL rollout 和高速智能体服务等延迟敏感场景下可达到 $1.96\times$ 加速。我们已将基于 CUDA 的巨内核实现 MegaMoE 作为 DeepGEMM 的组件开源。

观察与建议（Observations and Proposals）。我们分享了内核开发中的观察和经验，并向硬件厂商提出若干建议，希望有助于高效硬件设计并实现更好的软硬件协同设计：

- **计算通信比（Computation-Communication Ratio）**。完全的通信计算重叠取决于计算通信比，而非单纯的带宽。设峰值计算吞吐量为 C，互连带宽为 B，当 $C/B \le V_{\text{comp}}/V_{\text{comm}}$ 时通信可被完全隐藏（V_{comp} 为计算量，V_{comm} 为通信量）。对于 DeepSeek-V4-Pro，每个 token-专家对需要 $6hd$ FLOPs（SwiGLU 门控、上投影和下投影），但仅需 $3h$ 字节通信（FP8 Dispatch + BF16 Combine），简化为 $C/B \le 2d = 6144$ FLOPs/Byte。即每 GBps 互连带宽足以隐藏 6.1 TFLOP/s 算力的通信。一旦带宽达到该阈值，便不再是瓶颈，进一步扩展带宽的回报递减。我们建议未来硬件设计以此类平衡点为目标，而非无条件扩展带宽。

- **功耗预算（Power Budget）**。极致的内核融合使计算、内存和网络同时处于高负载，使功率节流成为关键性能限制因素。建议未来硬件设计为此类完全并发负载提供充足的功耗余量。

- **通信原语（Communication Primitives）**。我们采用基于拉取（pull-based）的方式，由每个 GPU 主动从远端 GPU 读取数据，避免了细粒度推送所带来的高通知延迟。具有更低延迟跨 GPU 信令的未来硬件将使推送（push）方式可行，并支持更自然的通信模式。

- **激活函数（Activation Function）**。我们建议用低代价的逐元素激活函数替换 SwiGLU，该函数不涉及指数或除法运算。这直接减轻了 GEMM 后处理负担，在相同参数预算下，去除门控投影可扩大中间维度 d，进一步降低带宽需求。

3.2 基于 TileLang 的灵活高效内核开发

在实践中，我们精心设计的模型架构本可产生数百个细粒度的 Torch ATen 算子。我们采用 TileLang (Wang et al., 2026) 开发一组融合内核，以最小的代价替换其中绝大部分，实现最优性能。TileLang 还使我们能在验证期间快速原型化注意力变体等算子。这些内核在模型架构开发、大规模训练以及最终的推理服务生产部署中发挥关键作用。作为一种领域特定语言（Domain-Specific Language，DSL），TileLang 在开发效率与运行时性能之间取得平衡，支持快速开发的同时，在同一代码库内支持深度的迭代优化。此外，我们与 TileLang 社区密切合作，推动更敏捷、高效且稳定的内核开发工作流。

通过 Host Codegen 减少调用开销（Reducing Invocation Overhead with Host Codegen）。随着加速器性能的持续提升，CPU 侧的编排开销日益突出。对于小型、高度优化的内核，此类固定的主机开销可能严重限制利用率和吞吐量。此类开销的常见来源是，主机侧逻辑（如运行时契约检查）通常以 Python 编写以保持灵活性，因而每次调用都会产生固定代价。

我们通过 Host Codegen 来缓解此开销：将大部分主机侧逻辑移入生成的主机代码。具体而言，我们首先在 IR（中间表示）层面联合生成设备内核和轻量主机启动器，将数据类型、秩/形状约束、步长/布局假设等必要元数据嵌入语言前端解析的代码中。然后将启动器降低为基于 TVM-FFI (Chen et al., 2018) 框架的主机源代码，其紧凑的调用约定和零拷贝张量互操作共同降低了主机侧开销。在运行时，生成的主机代码执行验证和参数整理，将所有每次调用的检查移出 Python 执行路径。我们的测试显示，CPU 侧验证开销从数十乃至数百微秒降低至每次调用不足一微秒。

SMT 求解器辅助的形式整数分析（SMT-Solver-Assisted Formal Integer Analysis）。TileLang 内核涉及复杂的张量索引算术，需要强大的形式整数分析能力。在布局推断、内存冲突检测和边界分析等编译过程中，编译器必须验证整数表达式是否满足特定属性，以启用相应的优化。因此，更强的形式分析能力可以解锁更高级复杂的优化机会。

为此，我们将 Z3 SMT 求解器 (De Moura and Bjørner, 2008) 集成到 TileLang 的代数系统中，为张量程序中的大多数整数表达式提供形式分析能力。我们将 TileLang 整数表达式翻译为 Z3 的无量词非线性整数算术（QF_NIA），在计算开销与形式表达力之间取得平衡。基于整数线性规划（ILP）求解器，QF_NIA 无缝解决内核中常见的标准线性整数表达式；其固有的非线性推理能力还有效应对变长张量形状上的向量化等高级挑战。在合理资源限制下，Z3 在将编译时间开销控制在几秒内的同时，全面提升了优化性能。其影响体现在向量化、屏障插入和代码简化等多个编译过程。

数值精度与逐比特可复现性（Numerical Precision and Bitwise Reproducibility）。在生产环境中，数值正确性和可复现性与原始吞吐量同等重要。因此我们默认优先保证精度：在编译器层面禁用快速数学优化，仅通过显式的可选前端算子（如 `T.__exp`、`T.__log` 和 `T.__sin`）提供影响精度的近似计算。反之，当需要严格 IEEE-754 语义时，TileLang 提供具有显式舍入模式的 IEEE 兼容内置函数（如 `T.ieee_fsqrt`、`T.ieee_fdiv` 和 `T.ieee_add`），使开发者能精确指定数值行为。

我们还以逐比特可复现性为目标，以便对内核与手写 CUDA 基准进行验证。我们将 TileLang 的代数简化和降低规则与主流 CUDA 工具链（如 NVCC）对齐，以避免引入意外位级差异的变换。布局注释（如 `T.annotate_layout`）进一步允许用户固定与布局相关的降低决策，保持评估和累积顺序与参考 CUDA 实现一致，从而在需要时实现逐比特相同的输出。

我们的评估表明，这些面向精度和可复现性的设计选择不会牺牲性能：在保守的默认设置下，TileLang 内核保持竞争力，同时提供旋钮以有选择地放松数值约束以追求更高速度。

3.3 高性能批次无关且确定性的内核库

为实现高效训练和推理，我们开发了一套全面的高性能计算内核。除基本功能和最大化硬件利用率外，另一个关键设计目标是确保训练可复现性以及预训练、后训练和推理流水线之间的逐比特对齐。为此，我们以最小性能开销实现了端到端的、逐比特批次无关（batch-invariant）且确定性的内核。这些内核有助于调试、稳定性分析，以及一致的后训练行为。

批次无关性（Batch Invariance）。批次无关性确保任意给定 token 的输出在逐比特层面保持相同，无论其在批次中的位置如何。实现批次无关性的主要挑战如下：

- **注意力（Attention）**。为实现批次无关性，我们不能使用 split-KV 方法 (Dao et al., 2023)——该方法将单一序列的注意力计算分布到多个流多处理器（SM）上以平衡负载。然而，放弃该技术会导致严重的波量化（wave-quantization）问题，进而影响 GPU 利用率。为此，我们为批次无关解码开发了双内核策略：第一个内核在单个 SM 内计算整个序列的注意力输出，确保完全填充波次的高吞吐量；第二个内核使用多个 SM 处理单个序列，以最小化最后一个部分填充波次的延迟并缓解波量化。为保证两个内核的逐比特一致性，我们精心设计了第二个内核的计算路径，确保其累积顺序与第一个内核相同。此外，第二个内核利用线程块簇（thread-block clusters）内的分布式共享内存，实现跨 SM 的高速数据交换。此双内核方法有效将批次无关解码的额外开销降至可忽略不计的水平。

- **矩阵乘法（Matrix Multiplication）**。传统 cuBLAS 库 (NVIDIA Corporation, 2024) 无法实现批次无关性。因此，我们端到端地用 DeepGEMM (Zhao et al., 2025) 替换它。此外，对于极小批次大小，传统实现通常采用 split-k (Osama et al., 2023) 技术提升性能。遗憾的是，split-k 技术无法保证批次无关性，而这在 DeepSeek-V4 中至关重要。因此，我们在大多数场景中放弃 split-k，但这可能导致性能下降。为此，我们引入了一组优化，使我们的矩阵乘法实现在大多数主要场景中与标准 split-k 性能相当甚至更优。

确定性（Determinism）。确定性训练对于调试硬件或软件问题非常有益。此外，当训练出现损失峰值等异常时，确定性使研究人员能更容易地找出数值原因并进一步改进模型设计。训练中的不确定性通常源于不确定的累积顺序，往往由原子加法指令的使用引起。该问题主要发生在反向传播过程中，尤其体现在以下部分：

- **注意力反向传播（Attention Backward）**。在稀疏注意力反向传播的传统实现中，我们使用 atomicAdd 为 KV token 累积梯度。由于浮点加法的非结合性，这引入了不确定性。为解决这一问题，我们为每个 SM 分配独立的累积缓冲区，随后在所有缓冲区之间进行全局确定性求和。

- **MoE 反向传播（MoE Backward）**。当来自不同 rank 的多个 SM 并发向接收 rank 的同一缓冲区写入数据时，协商写入位置同样引入不确定性。为此，我们在每个单独 rank 内设计了 token 顺序预处理机制，结合跨多 rank 的缓冲区隔离，确保专家并行发送结果和 MoE 反向传播累积顺序的确定性。

- **mHC 中的矩阵乘法（Matrix Multiplication in mHC）**。 mHC 涉及输出维度仅为 24 的矩阵乘法。对于极小批次大小，我们不得不使用 split-k (Osama et al., 2023) 算法，其朴素实现会导致不确定性。为此，我们将每个分块部分单独输出，并在后续内核中执行确定性归约，从而同时保证性能和确定性。

3.4 FP4 量化感知训练

为在部署时实现推理加速和内存节省,我们在后训练阶段引入量化感知训练(Quantization-Aware Training，QAT）(Jacob et al., 2018)，使模型适应量化引入的精度下降。我们将 FP4（MXFP4）量化 (Rouhani et al., 2023) 应用于两个组件：(1) MoE 专家权重——GPU 内存占用的主要来源 (OpenAI, 2025)；(2) CSA 索引器中的查询-键（QK）路径——其中 QK 激活全程以 FP4 格式缓存、加载和计算，在长上下文场景下加速注意力分数的计算。此外，我们在 QAT 过程中进一

步将索引分数 $I_{:,:}$ 从 FP32 量化为 BF16，在保持 KV 条目 99.7% 召回率的同时，实现 top-k 选择器 2× 加速。

对于 MoE 专家权重，遵循 QAT 的通常做法，优化器维护的 FP32 主权重首先量化为 FP4，然后反量化回 FP8 用于计算。值得注意的是，我们的 FP4 到 FP8 反量化是无损的：FP8（E4M3）比 FP4（E2M1）多 2 个指数位，提供了更大的动态范围。因此，只要 FP8 量化块（128×128 分块）内 FP4 子块（1×32 分块）的最大与最小缩放因子之比不超过某一阈值，细粒度的缩放信息就可以被 FP8 扩展的动态范围完全吸收。我们通过实验验证当前权重满足此条件。这使整个 QAT 流水线能完全复用现有的 FP8 训练框架，无需任何修改。在反向传播中，梯度相对于前向传播中相同的 FP8 权重计算，直接传回 FP32 主权重，等价于通过量化操作应用直通估计器（Straight-Through Estimator，STE）。这也避免了对转置权重的重新量化。

在 RL 训练的推理和 rollout 阶段（不涉及反向传播），我们直接使用真实 FP4 量化权重，而非模拟量化。这确保采样时的模型行为与在线部署完全一致，同时降低实际内核内存加载以实现真实加速，并显著降低内存消耗。CSA 索引器中的 QK 路径也采用类似处理。

3.5 训练框架

我们的训练框架建立在为 DeepSeek-V3 (DeepSeek-AI, 2024) 开发的可扩展高效基础设施之上。在训练 DeepSeek-V4 时，我们继承了这一坚实基础，同时引入若干关键创新，以适应其新型架构组件——特别是 Muon 优化器、mHC 和混合注意力机制——同时保持高训练效率和稳定性。

3.5.1 Muon 的高效实现

Muon 优化器需要完整的梯度矩阵来计算参数更新，这与零冗余优化器（Zero Redundancy Optimizer，ZeRO）(Rajbhandari et al., 2020) 结合时带来挑战。传统 ZeRO 为 AdamW 等逐元素优化器设计，单个参数矩阵可以跨多个 rank 分区和更新。为解决这一冲突，我们为 Muon 设计了混合 ZeRO 桶分配策略。

对于稠密参数，我们限制 ZeRO 并行的最大规模，并采用背包算法（knapsack algorithm）将参数矩阵分配给这些 rank，确保每个 rank 管理大致均衡的负载。每个 rank 上的桶填充到所有 rank 中最大桶的大小，以便高效执行 reduce-scatter 操作。在我们的配置中，每个 rank 管理不超过五个参数矩阵，填充通常导致不到 10% 的内存开销。当数据并行的整体规模超过 ZeRO 限制时，我们在额外的数据并行组中冗余计算 Muon 更新，以计算换取总桶内存的减少。

对于 MoE 参数，我们对每个专家独立优化。首先将所有层中所有专家 SwiGLU (Shazeer, 2020) 的所有下投影矩阵展平，再依次展平上投影矩阵和门控矩阵。然后对展平向量进行填充，确保可以均匀分布到所有 rank，且不分割任何逻辑独立矩阵。由于专家数量众多，MoE 参数不限制 ZeRO 并行规模，填充开销也可忽略不计。

此外，每个 rank 上形状相同的连续参数会自动合并，使 Newton-Schulz 迭代能批量执行以提高硬件利用率。我们还观察到，Muon 中的 Newton-Schulz 迭代在使用 BF16 矩阵乘法计算时保持稳定。利用这一点，我们进一步以随机舍入方式将需要在数据并行 rank 间同步的 MoE 梯度量化为 BF16 精度，使通信量减半。为避免低精度加法器引入的累积误差，我们用两阶段方法替代传统的树形或环形 reduce-scatter 集合操作：首先通过全对全（all-to-all）操作在 rank 间交换本地梯度，然后每个 rank 以 FP32 执行本地求和。这一设计保持了数值鲁棒性。

3.5.2 mHC 的低成本内存高效实现

与传统残差连接相比，mHC 的引入增加了激活内存消耗以及流水线阶段间的通信量。为缓解这些代价，我们实施了若干优化策略。

首先，我们精心设计并实现了面向训练和推理的 mHC 融合内核。其次，我们引入了选择性检查点中间张量的重计算策略：具体地，我们重计算层间的大多数隐藏状态和所有归一化层输入，同时避免对计算密集型操作进行重计算，从而在内存节省和计算开销之间取得平衡。第三，我们调整了 DualPipe 的 1F1B 重叠方案，以适应增加的流水线通信，并使 mHC 中的某些操作能并发执行。

综合这些优化，mHC 的实际运行时间开销被控制在重叠 1F1B 流水线阶段的仅 6.7%。更多工程优化细节可参见专题 mHC 论文 (Xie et al., 2026)。

3.5.3 长上下文注意力的上下文并行

传统的上下文并行（Context Parallelism，CP）沿序列维度分区，每个 rank 维护连续的 s 个 token。这给我们的压缩注意力机制（CSA 和 HCA）带来了两个挑战：一方面，训练样本由多个序列打包而成，每个序列独立以因子 m（或 m'）压缩，不足 m 的尾部 token 被丢弃。因此，压缩后的 KV 长度通常小于 $\lceil s/m \rceil$，且在各 rank 间有所差异。另一方面，压缩需要 m 个连续 KV 条目，这些条目可能跨越相邻 CP rank 的边界。

为应对这些挑战，我们设计了两阶段通信方案。第一阶段，每个 rank i 将其最后 m 个未压缩 KV 条目发送给 rank $i+1$；然后 rank $i+1$ 将接收到的部分条目与本地 s 个未压缩 KV 条目一起压缩，产生固定长度 $\lfloor s/m \rfloor + 1$ 的压缩条目（包含一些填充条目）。第二阶段，跨所有 CP rank 执行全聚合（all-gather）操作，收集本地压缩 KV 条目；然后融合的选择-填充算子将其重组为完整的压缩 KV 条目集合，总长度为 $\text{cp_size} \cdot \lfloor s/m \rfloor$，所有填充条目置于末尾。对于 HCA 和 CSA 中的索引器，每个查询 token 可见的压缩 KV 条目范围可通过规则预计算。对于 CSA 中的稀疏注意力，top-k 选择器明确指定每个查询可见的压缩 KV 条目索引。

3.5.4 用于灵活激活检查点的扩展自动微分

传统的激活检查点实现以整个模块为粒度，决定在反向传播过程中保留还是重计算其输出激活。这种粗粒度往往导致重计算代价与激活内存占用之间的次优权衡。另一种方法是手动实现整个层的前向和反向逻辑，显式管理张量检查点状态。虽然能实现细粒度控制，但这失去了自动微分框架的便利性，大大增加了开发复杂度。

为在不牺牲编程效率的情况下实现细粒度控制，我们实现了支持自动微分的张量级激活检查点机制。借助此机制，开发者只需实现前向传播，并有选择地对单个张量进行自动检查点和重计算标注。我们的框架利用 TorchFX (Reed et al., 2022) 追踪完整计算图，对每个已标注的张量执行反向遍历，以识别重计算所需的最小子图。我们将这些最小子图定义为重计算图，并在对应梯度计算之前将其插入反向传播逻辑中。

与手动实现相比，此设计在训练时不引入额外开销。该框架中的重计算通过直接释放已标注张量的 GPU 内存，并复用重计算张量的存储指针来实现，无需任何 GPU 内存拷贝。此外，由于图追踪是具体执行模型的，我们可以追踪每个张量底层的存储指针，实现对共享存储张量（如 reshape 操作的输入和输出）重计算的自动去重。这减轻了开发者在标注重计算时需要考虑底层内存细节的负担。

3.6 推理框架

我们的推理框架大体继承自 DeepSeek-V3，在 KV 缓存管理方面有所不同。

3.6.1 KV 缓存结构与管理

为高效管理 DeepSeek-V4 混合注意力机制所产生的异构 KV 缓存，我们设计了定制化的 KV 缓存布局，如图 6 所示。

DeepSeek-V4 中的异构 KV 条目。DeepSeek-V4 系列的混合注意力机制引入了多种具有不同 KV 缓存大小和更新规则的 KV 条目类型。CSA 稀疏选择的闪电索引器引入了额外维度，其嵌入大小与主注意力不同。CSA 和 HCA 中的压缩技术分别将序列长度降低为原来的 $\frac{1}{m}$ 和 $\frac{1}{m'}$，从而减小了总体 KV 缓存大小。因此，不同层的 KV 缓存大小有所不同。此外，滑动窗口注意力（SWA）层也有不同的 KV 缓存大小以及独立的缓存命中和淘汰策略。在压缩分支中，每 m 个 token 生成一个 KV 条目；当剩余 token 数量不足以进行压缩时，所有待处理 token 及其关联的隐藏状态必须保存在缓冲区中，直到可以执行压缩操作。这些缓冲的 token 代表由位置上下文决定的序列状态，也在 KV 缓存框架内进行管理。

混合注意力 KV 缓存管理的挑战。混合注意力机制违反了 PagedAttention 及其变体背后的基本假设。尽管近期的混合 KV 缓存管理算法（如 Jenga (Zhang et al., 2025a)、Hymba (Dong et al., 2025)）面向通用混合注意力模型或特定结构，但有两个主要障碍阻止在 PagedAttention 框架下整合所有层的 KV 缓存：(1) 多样化的缓存策略，例如滑动窗口注意力所使用的策略；(2) 高性能注意力内核施加的约束，包括对齐要求。

图 6 说明： DeepSeek-V4 的 KV 缓存布局示意图。KV 缓存分为两个主要组件：用于 CSA/HCA 的经典 KV 缓存，以及用于 SWA 和 CSA/HCA 中尚未准备好压缩的 token 的状态缓存。在状态缓存中，每个请求分配一个固定大小的缓存块：SWA 段存储对应最近 n_{win} 个 token 的 KV 条目，CSA/HCA 段存储尚未准备好压缩的未压缩尾部状态。在经典 KV 缓存中，每个请求分配多个块，每个缓存块覆盖 $\text{lcm}(m, m')$ 个原始 token，产生 $k_1 = \text{lcm}(m, m')/m$ 个 CSA 压缩 token 和 $k_2 = \text{lcm}(m, m')/m'$ 个 HCA 压缩 token。

为高效管理 DeepSeek-V4 的 KV 缓存，我们设计了相应策略以克服上述两个挑战。

SWA 和未压缩尾部 token 的状态缓存（State Cache）。针对第一个障碍，我们采用了替代缓存管理机制。由于 SWA 旨在有限 KV 缓存大小下提升性能，合理的做法是将其与压缩分支中未压缩的尾部 token 一同视为状态空间模型，相应的 KV 缓存可视为仅取决于当前位置的序列特定状态。为此，我们预先分配固定且有限大小的状态缓存池，动态分配给每个序列。

稀疏注意力内核协同设计（Sparse Attention Kernel Co-Design）。针对第二个障碍，传统高性能注意力内核通常假设每块有固定数量 B 个 token 以优化性能，对应 CSA 中 $B \cdot m$ 个原始 token 和 HCA 中 $B \cdot m'$ 个原始 token。通过采用高性能稀疏注意力内核，不同层可在不降低性能的情况下容纳每块可变 token 数。实现这一点需要对 KV 缓存布局和稀疏注意力内核进行协同设计。例如，将块填充到与缓存行对齐可提升性能。因此，对于压缩率为 m 的 CSA 和压缩率为 m' 的 HCA，每块原始 token 数可以是 $\text{lcm}(m, m')$（两个压缩率的最小公倍数）的任意倍数。

3.6.2 磁盘 KV 缓存存储

在部署 DeepSeek-V4 时，我们利用磁盘 KV 缓存存储机制，以避免对共享前缀请求重复进行预填充。对于 CSA/HCA 中的压缩 KV 条目和滑动窗口注意力（SWA）中的未压缩 KV 条目，我们分别设计了不同的存储管理方案。

对于 CSA 和 HCA，我们直接将所有压缩 KV 条目存储到磁盘。当请求命中已存储的前缀时，读取并复用对应前缀的压缩 KV 条目，直到最后一个完整压缩块。特别地，对于尾部不完整块中的前缀 token，仍需重新计算以恢复未压缩的 KV 条目，因为 CSA 和 HCA 中的未压缩 KV 条目不存储。

对于 SWA KV 条目，由于它们未经压缩且存在于每一层，其体积约为压缩 CSA 和 HCA KV 条目的 8 倍。为高效处理这些大量 SWA KV 条目，我们提出并实现了三种不同的磁盘 SWA KV 条目管理策略，每种策略在存储开销和计算冗余之间提供不同的权衡：

- **完整 SWA 缓存（Full SWA Caching）**。此策略存储所有 token 的完整 SWA KV 条目，确保零计算冗余。命中前缀时，只需读取该前缀内最后 n_{win} 个 token 的磁盘缓存即可重建 SWA KV 条目。尽管计算零冗余，但此策略对现代基于 SSD 的存储系统效率不高——每次命中请求只会访问存储的 SWA KV 缓存的一小子集，导致写多读少的不均衡访问模式。

- **周期性检查点（Periodic Checkpointing）**。此策略每 p 个 token 对最后 n_{win} 个 token 的 SWA KV 条目进行一次检查点（p 为可调参数）。命中前缀时，加载最近的检查点状态，然后重新计算剩余的尾部 token。通过调整 p，此策略可在存储和计算之间按需权衡。

- **零 SWA 缓存（Zero SWA Caching）**。此策略不存储任何 SWA KV 条目。命中前缀时，需要进行更多重计算以恢复 SWA KV 条目。具体而言，在每个注意力层中，每个 token 的 SWA KV 条目仅取决于上一层中最近 n_{win} 个 token 的 SWA KV 条目。因此，利用已缓存的 CSA 和 HCA KV 条目，重新计算最后 $n_{\text{win}} \cdot L$ 个 token 就足以为 L 层模型恢复最后 n_{win} 个 SWA KV 条目。

根据具体部署场景，我们选择最合适的策略以实现期望的存储与计算权衡。

4 预训练

4.1 数据构建

在 DeepSeek-V3 预训练数据的基础上，我们致力于构建多样性更强、质量更高、有效上下文更长的训练语料库，持续完善数据构建流水线。对于来自网页的数据，我们实施了过滤策略，以去除批量自动生成和模板化内容，从而降低模型崩溃 (Zhu et al., 2024) 的风险。数学和编程语料库仍是我们训练数据的核心组成部分，我们通过在中期训练阶段引入智能体数据来进一步提升 DeepSeek-V4 系列的代码能力。对于多语言数据，我们为 DeepSeek-V4 构建了更大规模的语料库，以提升其对不同文化长尾知识的覆盖。对于 DeepSeek-V4，我们特别强调长文档数据的整理，优先收录科学论文、技术报告以及其他反映独特学术价值的材料。综合以上所有内容，我们的预训练语料库包含超过 32T token，涵盖数学内容、代码、网页、长文档以及其他高质量类别。

对于预训练数据，我们基本沿用 DeepSeek-V3 的预处理策略。在词元化（tokenization）方面，在 DeepSeek-V3 分词器的基础上，我们引入了若干用于上下文构建的特殊 token，词汇表大小仍保持 128K。我们还继承了 DeepSeek-V3 的 token 切分 (DeepSeek-AI, 2024) 和填充中间（Fill-in-Middle，FIM）(DeepSeek-AI, 2024) 策略。受 Ding et al. (2024) 启发，我们将来自不同来源的文档打包到适当的序列中，以最小化样本截断。与 DeepSeek-V3 不同，我们在预训练期间采用了样本级别的注意力掩码。

4.2 预训练设置

4.2.1 模型设置

DeepSeek-V4-Flash。我们将 Transformer 层数设为 43，隐藏维度 d 设为 4096。前两层使用纯滑动窗口注意力，后续各层以交错方式使用 CSA 和 HCA。对于 CSA，压缩率 m 设为 4，索引查询头数 n_h^I 设为 64，索引头维度 c_I 设为 128，稀疏注意力选择的 KV 条目数（即注意力 top-k）设为 512。对于 HCA，压缩率 m' 设为 128。对于 CSA 和 HCA，查询头数 n_h 均设为 64，头维度 c 设为 512，查询压缩维度 d_c 设为 1024。输出投影组数 g 设为 8，每个中间注意力输出的维度 d_g 设为 1024。滑动窗口注意力附加分支的窗口大小 n_{win} 设为 128。所有 Transformer 块均采用 MoE 层，但前 3 个 MoE 层使用哈希路由策略。每个 MoE 层包含 1 个共享专家和 256 个路由专家，每个专家的中间隐藏维度为 2048。在路由专家中，每个 token 激活 6 个专家。多 token 预测深度设为 1。对于 mHC，扩展因子 n_{hc} 设为 4，Sinkhorn-Knopp 迭代次数 $t_{\max}$ 设为 20。在此配置下，DeepSeek-V4-Flash 共有 284B 参数，每个 token 激活 13B 参数。

DeepSeek-V4-Pro。我们将 Transformer 层数设为 61，隐藏维度 d 设为 7168。前两层使用 HCA，后续各层以交错方式使用 CSA 和 HCA。对于 CSA，压缩率 m 设为 4，索引查询头数 n_h^I 设为 64，索引头维度 c_I 设为 128，注意力 top-k 设为 1024。对于 HCA，压缩率 m' 设为 128。对于 CSA 和 HCA，查询头数 n_h 均设为 128，头维度 c 设为 512，查询压缩维度 d_c 设为 1536。输出投影组数 g 设为 16，每个中间注意力输出的维度 d_g 设为 1024。滑动窗口注意力附加分支的窗口大小 n_{win} 设为 128。所有 Transformer 块均采用 MoE 层，但前 3 个 MoE 层使用哈希路由策略。每个 MoE 层包含 1 个共享专家和 384 个路由专家，每个专家的中间隐藏维度为 3072。在路由专家中，每个 token 激活 6 个专家。多 token 预测深度设为 1。对于 mHC，扩展因子 n_{hc} 设为 4，Sinkhorn-Knopp 迭代次数 $t_{\max}$ 设为 20。在此配置下，DeepSeek-V4-Pro 共有 1.6T 参数，每个 token 激活 49B 参数。

4.2.2 训练设置

DeepSeek-V4-Flash。我们对大多数参数采用 Muon 优化器 (Jordan et al., 2024; Liu et al., 2025)，但对嵌入模块、预测头模块以及所有 RMSNorm 模块的权重使用 AdamW 优化器 (Loshchilov and Hutter, 2017)。AdamW 的超参数设为 $\beta_1 = 0.9$，$\beta_2 = 0.95$，$\varepsilon = 10^{-20}$，权重衰减为 0.1。Muon 的动量设为 0.95，权重衰减设为 0.1，每次更新矩阵的 RMS 缩放为 0.18，以复用 AdamW 学习率。我们在 32T token 上训练 DeepSeek-V4-Flash，并与 DeepSeek-V3 一样采用批次大小调度策略：批次大小（以 token 计）从较小值逐渐增大到 75.5M，然后在大部分训练过程中保持 75.5M。学习率在前 2000 步线性预热，在大部分训练中保持为 2.7×10^{-4}，在训练接近结束时

按余弦调度衰减至 2.7×10^{-5}。训练起始序列长度为 4K，逐步扩展至 16K、64K 和 1M。对于稀疏注意力设置，首先在前 1T token 使用稠密注意力预热模型，在序列长度 64K 时引入稀疏注意力并在其余训练中保持。引入稀疏注意力时，首先设置一个短阶段预热 CSA 中的闪电索引器，然后在大部分训练中以稀疏注意力训练模型。对于无辅助损失的负载均衡，偏置更新速度设为 0.001。对于均衡损失，损失权重设为 0.0001 以避免单一序列内极端不均衡。MTP 损失权重在大部分训练中设为 0.3，在开始学习率衰减时设为 0.1。

DeepSeek-V4-Pro。除特定超参数值外，DeepSeek-V4-Pro 的训练设置与 DeepSeek-V4-Flash 基本一致。对大多数参数采用 Muon 优化器，但对嵌入模块、预测头模块和所有 RMSNorm 模块权重使用 AdamW 优化器。AdamW 和 Muon 的超参数与 DeepSeek-V4-Flash 相同。在 33T token 上训练 DeepSeek-V4-Pro，同样采用批次大小调度策略，最大批次大小为 94.4M token。学习率调度策略与 DeepSeek-V4-Flash 基本相同，但峰值学习率设为 2.0×10^{-4}，结束学习率设为 2.0×10^{-5}。训练同样从 4K 序列长度开始，逐步扩展至 16K、64K 和 1M。与 DeepSeek-V4-Flash 相比，DeepSeek-V4-Pro 有更长的稠密注意力预热阶段，引入稀疏注意力的策略与 DeepSeek-V4-Flash 相同，采用两阶段训练方法。无辅助损失负载均衡的偏置更新速度设为 0.001，均衡损失权重设为 0.0001。MTP 损失权重在大部分训练中设为 0.3，在开始学习率衰减时设为 0.1。

4.2.3 缓解训练不稳定性

训练万亿参数 MoE 模型面临重大稳定性挑战，DeepSeek-V4 系列也不例外。我们在训练过程中遇到了显著的不稳定性挑战。简单的回滚虽然可以暂时恢复训练状态，但无法从根本上防止损失峰值的再次出现，因而不足以作为长期解决方案。通过实验，我们发现峰值的出现始终与 MoE 层中的异常值相关，而路由机制本身似乎加剧了这些异常值的产生。因此，我们从两个维度着手解决这一问题：打破路由引发的恶性循环，以及直接抑制异常值。幸运的是，我们发现了两种能有效维持训练稳定性的实用技术。尽管对其底层机制的全面理论理解目前仍是开放问题，我们公开分享这些技术，以促进社区的进一步探索。

预判路由（Anticipatory Routing）。我们发现，将主干网络和路由网络的同步更新解耦，可以显著提高训练稳定性。因此，在步骤 t，我们使用当前网络参数 θ_t 进行特征计算，但路由索引使用历史网络参数 $\theta_{t-\Delta t}$ 计算和应用。在实践中，为避免两次加载模型参数的开销，我们在步骤 $t - \Delta t$ 时提前获取步骤 t 的数据，”预判”地计算并缓存后续步骤 t 将使用的路由索引，这也是我们将此方法命名为预判路由的原因。我们还从基础设施层面对此进行了大量优化：首先，由于预计算路由索引仅需对数据进行一次前向传播，我们精心编排了流水线执行与专家并行（EP）通信的计算重叠，成功将预判路由的额外实际时间开销控制在约 20%；其次，我们引入了自动检测机制，仅在发生损失峰值时触发短暂回滚并激活预判路由，经过一段时间后系统恢复标准训练。最终，这种动态应用方式使我们能以几乎可忽略的总体额外训练开销规避损失峰值，且不影响模型性能。

SwiGLU 截断（SwiGLU Clamping）。在以往文献 (Bello et al., 2017; Riviere et al., 2024) 中，截断被明确用于约束数值范围以增强训练稳定性。在我们的实际训练中，我们通过实验发现，应用 SwiGLU 截断 (OpenAI, 2025) 能有效消除异常值，大幅有助于稳定训练过程，且不影响性能。在 DeepSeek-V4-Flash 和 DeepSeek-V4-Pro 的整个训练过程中，我们将 SwiGLU 的线性分量截断至 $[-10, 10]$ 范围，并将门控分量的上界限制为 10。

4.3 评估

4.3.1 评估基准

对于基础模型的评估，我们考虑了涵盖四个关键维度的基准测试：世界知识、语言理解与推理、代码与数学，以及长上下文处理。

世界知识基准包括：AGIEval (Zhong et al., 2023)、C-Eval (Huang et al., 2023)、CMMLU (Li et al., 2023)、MMLU (Hendrycks et al., 2020)、MMLU-Redux (Gema et al., 2024)、MMLU-Pro (Wang et al., 2024b)、MMMLU (OpenAI, 2024a)、MultiLoKo (Hupkes and Bogoychev, 2025)、Simple-QA verified (Haas et al., 2025)、SuperGPQA (Du et al., 2025)、FACTS Parametric (Cheng et al., 2025) 和 TriviaQA (Joshi et al., 2017)。

语言理解与推理基准包括：BigBench Hard (BBH) (Suzgun et al., 2022)、DROP (Dua et al., 2019)、HellaSwag (Zellers et al., 2019)、CLUEWSC (Xu et al., 2020) 和 WinoGrande (Sakaguchi et al., 2019)。

代码与数学基准包括：BigCodeBench (Zhuo et al., 2025)、HumanEval (Chen et al., 2021)、GSM8K (Cobbe et al., 2021)、MATH (Hendrycks et al., 2021)、MGSM (Shi et al., 2023) 和 CMath (Wei et al., 2023)。

长上下文基准包括：LongBench-V2 (Bai et al., 2025b)。

4.3.2 评估结果

表 1 提供了 DeepSeek-V3.2、DeepSeek-V4-Flash 和 DeepSeek-V4-Pro 基础模型的详细对比，所有模型均在统一内部框架下以严格一致的设置进行评估。

> **表 1 说明：** DeepSeek-V3.2-Base、DeepSeek-V4-Flash-Base 和 DeepSeek-V4-Pro-Base 的比较。所有模型在我们的内部框架中评估，使用相同的评估设置。分差不超过 0.3 的成绩视为同一水平。每行最高分加粗，第二高分加下划线。三个模型架构均为 MoE，激活参数分别为 37B/13B/49B，总参数分别为 671B/284B/1.6T。

将 DeepSeek-V4-Flash-Base 与 DeepSeek-V3.2-Base 对比，揭示了一个引人注目的效率故事：尽管激活参数和总参数数量均大幅减少，DeepSeek-V4-Flash-Base 在众多基准上的表现优于 DeepSeek-V3.2-Base。这一优势在世界知识任务和具有挑战性的长上下文场景中尤为明显。这些结果表明，DeepSeek-V4-Flash-Base 的架构改进、精炼的数据质量和训练优化，即便在更紧凑的参数预算下也能带来卓越的性能，有效超越了规模更大的 DeepSeek-V3.2-Base。

此外，DeepSeek-V4-Pro-Base 在能力上进一步实现了决定性的飞跃，在几乎所有方面均压倒性地领先于 DeepSeek-V3.2-Base 和 DeepSeek-V4-Flash-Base。在几乎所有类别上均有所提升，DeepSeek-V4-Pro-Base 在最具挑战性的基准上创下 DeepSeek 基础模型的新性能高点：在知识密集型评估中实现显著提升，在长上下文理解方面也取得重大进展；在大多数推理和代码基准上同样超越两个前代模型。这一全面提升确认 DeepSeek-V4-Pro-Base 是 DeepSeek 系列中最强大的基础模型，在知识、推理、代码和长上下文能力方面全面超越了其前代模型。

5 后训练

5.1 后训练流水线

预训练完成后，我们进行后训练阶段，以产生 DeepSeek-V4 系列的最终模型。虽然训练流水线在很大程度上沿用了 DeepSeek-V3.2 的流程，但做出了一项关键的方法论替换：将混合强化学习（RL）阶段完全替换为在线策略蒸馏（On-Policy Distillation，OPD）。

5.1.1 领域专家训练

领域专家的培养通过改编 DeepSeek-V3.2 的训练流水线实现。具体而言，每个模型均依次经历初始微调阶段以及由领域特定提示和奖励信号引导的强化学习（RL）阶段。在 RL 阶段，我们实施了组相对策略优化（Group Relative Policy Optimization，GRPO）算法，超参数与我们此前研究（DeepSeek-AI, 2025）保持高度一致。

推理努力程度（Reasoning Efforts）。众所周知，模型在推理任务上的表现从根本上取决于所投入的计算努力程度。因此，我们在不同的 RL 配置下训练了不同的专家模型，以培养针对不同推理能力优化的模型。如表 2 所示，DeepSeek-V4-Pro 和 DeepSeek-V4-Flash 均支持三种特定的推理努力模式。对于每种模式，我们在 RL 训练期间施加不同的长度惩罚和上下文窗口，从而产生不同的推理输出 token 长度。为整合这些不同的推理模式，我们利用以 `<think>` 和 `</think>` token 划定的专用响应格式。此外，对于"Think Max" 模式，我们在系统提示开头添加特定指令，以引导模型的推理过程（见表 3）。

表 2：三种推理模式的对比

- **Non-think（不思考）模式：**基于习惯或简单规则的快速直觉响应，适用于常规日常任务、紧急反应、低风险决策。响应格式：`</think>` 摘要。
- **Think High（高思考）模式：**有意识的逻辑分析，速度较慢但更准确，适用于复杂问题求解、规划、中风险决策。响应格式：`<think>` 思考内容 `</think>` 摘要。
- **Think Max（最大思考）模式：**将推理推向最大限度，缓慢但强大，适用于探索模型推理能力边界。响应格式：1. 系统提示开头的特殊指令；2. `<think>` 思考内容 `</think>` 摘要。

表 3：注入系统提示中用于"Think Max" 模式的指令

推理努力：绝对最大限度，不允许任何捷径。你必须在思考中非常彻底，全面分解问题以解决根本原因，对所有潜在路径、边界情况和对抗性场景严格测试你的逻辑。明确写出你的完整审议过程，记录每个中间步骤、考虑过的替代方案和被否定的假设，以确保绝对没有假设未经检验。

生成式奖励模型（Generative Reward Model）。通常，易验证任务可以有效地使用基于简单规则的验证器或测试用例进行优化。相比之下，难以验证的任务传统上依赖人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF），这需要大量人工标注来训练标量奖励模型。然而，在 DeepSeek-V4 系列的后训练阶段，我们放弃了这些传统的基于标量的奖励模型。相反，为处理难以验证的任务，我们精心策划了基于评分标准的 RL 数据，并采用生成式奖励模型（Generative Reward Model，GRM）来评估策略轨迹。关键在于，我们将 RL 优化直接应用于 GRM 本身：在此范式中，执行者网络原生地充当 GRM，实现模型评估（评判）能力与标准生成能力的联合优化。通过统一这两个角色，模型的内部推理能力天然地融入其评估过程，从而产生高度鲁棒的评分。此外，该方法仅需极少量多样化的人工标注即可实现卓越性能，因为模型利用自身逻辑对复杂任务进行泛化。

工具调用模式与特殊 Token（Tool-Call Schema and Special Token）。与我们之前的版本一致，我们使用专用的 `<think></think>` 标签来划定推理路径。在 DeepSeek-V4 系列中，我们引入了新的工具调用模式，采用特殊的 `|DSML|` token 并使用基于 XML 的格式进行工具调用（如表 4 所示）。我们的实验表明，XML 格式有效缓解了转义失败并减少了工具调用错误，为模型-工具交互提供了更加鲁棒的接口。

交错思考（Interleaved Thinking）。DeepSeek-V3.2 引入了一种上下文管理策略：在工具结果轮次中保留推理痕迹，但在新用户消息到来时丢弃。虽然有效，但这在复杂的智能体工作流中仍造成不必要的 token 浪费——每个新用户轮次会清空所有累积的推理内容，迫使模型从头重建其问题求解状态。利用 DeepSeek-V4 系列扩展的百万 token 上下文窗口，我们进一步完善了这一机制，以最大化交错思考在智能体环境中的效果：

- **工具调用场景（图 7(a)）：**所有推理内容在整个对话过程中完整保留。与 DeepSeek-V3.2 在每次新用户轮次时丢弃思考痕迹不同，DeepSeek-V4 系列跨所有轮次（包括跨越用户消息边界）保留完整的推理历史，使模型能在长程智能体任务中维持连贯的累积思维链。
- **一般对话场景（图 7(b)）：**保留原有策略：当新用户消息到来时，来自前一轮次的推理内容被丢弃，在推理持久化收益有限的场景下保持上下文简洁。

快速指令（Quick Instruction）。在聊天机器人场景中，一些辅助任务（例如确定是否触发网页搜索、意图识别等）必须在生成响应之前执行。传统上，这些任务由一个单独的小型模型处理，由于无法复用已有的 KV 缓存而需要冗余的预填充。为克服这一限制，我们引入了快速指令机制：直接在输入序列末尾附加一组专用特殊 token，每个 token 对应一个特定的辅助任务。通过直接复用已计算的 KV 缓存，此机制完全避免了冗余预填充，并允许某些任务（如生成搜索查询和确定权威性与领域）并行执行。因此，该方法显著降低了用户感知的首 token 时间（Time-To-First-Token，TTFT），并消除了维护和迭代额外小型模型的工程开销（支持的快速指令 token 汇总见表 5）。

5.1.2 在线策略蒸馏

在通过专业微调和强化学习训练出多个领域特定专家后，我们采用多教师在线策略蒸馏（On-Policy Distillation, OPD）作为将专家能力合并到最终模型的主要技术。OPD 已成为一种有效的后训练范式，可高效地将领域专家的知识和能力转移到单一统一模型中：通过让学生在自身生成的轨迹上学习教师模型的输出分布来实现。形式上，给定 N 个专家模型集合 $\{\pi_{E_1}, \pi_{E_2}, \ldots, \pi_{E_N}\}$，OPD 目标函数定义为：

$$\mathcal{L}_{\text{OPD}}(\theta) = \sum_{i=1}^{N} w_i \cdot D_{\text{KL}}(\pi_\theta \| \pi_{E_i}). \tag{29}$$

其中 w_i 为每个专家的分配权重，通常由专家的相对重要性决定。计算反向 KL 损失 $D_{\text{KL}}(\pi_\theta \| \pi_{E_i})$ 需要从学生 π_θ 中采样训练轨迹以保持在线策略学习。其底层逻辑确保统一策略 π_θ 选择性地向与当前任务上下文相关的专业专家学习（例如，对数学推理任务与数学专家对齐，对编程任务与代码专家对齐）。通过这一机制，来自物理上不同专家权重的知识通过 logit 层面的对齐被整合到统一的参数空间中，有效规避了传统权重合并或混合 RL 技术中常见的性能下降。在此阶段，我们采用十余个涵盖各领域的教师模型蒸馏出单一学生模型。

在处理上述 OPD 目标时，先前工作通常将全词汇量 KL 损失简化为每个 token 位置的 token 级 KL 估计，并通过将 $\text{sg} \log \frac{\pi_{E_i}(y_t|x, y_{<t})}{\pi_\theta(y_t|x, y_{<t})}$（sg 表示停止梯度操作）替换为策略损失计算中的每 token 优势估计来复用 RL 框架。虽然此方法资源高效，但会导致梯度估计方差高，并常常引起训练不稳定。因此，我们在 OPD 中采用全词汇量 logit 蒸馏：在计算反向 KL 损失时保留完整的 logit 分布，产生更稳定的梯度估计，并确保对教师知识的忠实蒸馏。下一小节将描述使大规模全词汇量 OPD 可行的工程工作。

5.2 RL 与 OPD 基础设施

我们的后训练基础设施建立在为 DeepSeek-V3.2 开发的可扩展框架之上，集成了第 3.5 节描述的相同分布式训练栈以及之前引入的用于高效自回归采样的 rollout 引擎。在此基础上，我们在本工作中引入了以下主要改进，使得涉及十余个不同教师模型的超长上下文 RL 和 OPD 合并任务能够高效执行，从而大幅加速模型发布的迭代周期。

5.2.1 FP4 量化集成

我们对 rollout 和所有仅推理的前向传播（包括教师模型和参考模型的前向传播）应用 FP4（MXFP4）量化，以降低内存流量并减少采样延迟。如第 3.4 节所述，在 rollout 和推理阶段直接使用原生 FP4 权重。在训练步骤中，FP4 量化通过无损的 FP4 到 FP8 反量化步骤进行模拟，允许无缝复用以 FP32 主权重的现有 FP8 混合精度框架，无需修改反向传播流水线。

5.2.2 全词汇量 OPD 的高效教师调度

我们的框架支持全词汇量在线策略蒸馏，教师数量实际上无上限，每个教师可能包含数万亿参数。为实现这一点，所有教师权重被卸载到集中式分布式存储，并在教师前向传播期间按需加载，采用类 ZeRO 的参数分片以缓解 I/O 和 DRAM 压力。此外，朴素地为所有教师实例化词汇量 $|V| > 100\text{K}$ 的 logit 是不可行的，即使卸载到磁盘也是如此。我们通过在前向传播期间仅在集中式缓冲区中缓存最后一层教师隐藏状态来解决这一问题：在训练时，这些缓存状态被检索并通过对应的预测头模块即时重建完整 logit。此设计引入了可忽略不计的重计算开销，同时完全规避了与显式 logit 实例化相关的内存负担。为降低教师预测头的 GPU 内存占用，我们在数据调度期间按教师索引排序训练样本，确保每个不同的教师头在每个小批次中仅加载一次，且任意时刻设备内存中至多有一个教师头。所有参数和隐藏状态的加载/卸载操作在后台异步进行，不阻塞关键路径上的计算。最后，教师与学生 logit 之间的精确 KL 散度使用专门的 TileLang 内核计算，加速了计算并减少了动态内存分配。

5.2.3 可抢占且容错的 Rollout 服务

为在实现高优先级任务快速硬件配置的同时最大化 GPU 资源利用率，我们的 GPU 集群采用全集群抢占式任务调度器，任何正在运行的任务均可在任意时间被抢占。此外，大规模 GPU 集群中硬件故障频发。为此，我们实现了用于 RL/OPD rollout 的可抢占且容错的大型语言模型生成服务。

具体而言，我们为每个生成请求实现 token 粒度的预写日志（Write-Ahead Log，WAL）：每当为请求生成新 token 时，立即将其追加到该请求的 WAL 中。在抢占期间，我们暂停推理引擎并保存未完成请求的 KV 缓存；恢复时，使用持久化的 WAL 和已保存的 KV 缓存继续解码。即使发生严重硬件错误，也可以使用 WAL 中持久化的 token 重新运行预填充阶段以重建 KV 缓存。

值得注意的是，从头重新生成未完成请求在数学上是不正确的，因为这会引入长度偏差：较短的响应更可能在中断中存活，从头重新生成会使模型在发生中断时更倾向于生成较短的序列。如果推理栈是批次无关且确定性的，也可以通过使用采样器中伪随机数生成器的一致种子重新生成来解决此正确性问题，但这种方法仍需重新运行解码阶段的额外代价，远不如我们的 token 粒度 WAL 方法高效。

5.2.4 面向百万 Token 上下文扩展的 RL 框架

我们引入了针对百万 token 序列上高效 RL 和 OPD 的定向优化。在 rollout 阶段，采用第 5.2.3 节中详述的可抢占且容错的 rollout 服务。在推理和训练阶段，将 rollout 数据格式分解为轻量级元数据和重型的每 token 字段：在数据调度期间，可加载整个 rollout 数据的元数据以执行全局洗牌和打包布局计算；重型每 token 字段通过共享内存数据加载器加载以消除节点内数据冗余，并在小批次粒度消耗后立即释放，大幅降低 CPU 和 GPU 内存压力。设备上小批次的数量根据工作负载动态确定，实现计算吞吐量和 I/O 重叠之间的高效权衡。

5.2.5 面向智能体 AI 的沙箱基础设施

为满足后训练和评估期间智能体 AI 多样化的执行需求，我们构建了生产级沙箱平台 DeepSeek Elastic Compute（DSec）。DSec 由三个 Rust 组件构成——API 网关（Apiserver）、单机代理（Edge）和集群监控器（Watcher）——通过自定义 RPC 协议互连，并在 3FS 分布式文件系统（DeepSeek-AI, 2025）上水平扩展。在生产中，单个 DSec 集群管理数十万个并发沙箱实例。

DSec 的设计受四个观察结果驱动：(1) 智能体工作负载高度异构，涵盖轻量级函数调用到具有多样 OS 和安全需求的完整软件工程流水线；(2) 环境镜像数量众多且体积大，但必须快速加载并支持迭代定制；(3) 高密度部署需要高效的 CPU 和内存利用率；(4) 沙箱生命周期必须与 GPU 训练计划协调，包括抢占和基于检查点的恢复。基于这些观察，我们逐一阐述 DSec 的四项核心设计。

统一接口下的四种执行底层（Four Execution Substrates Behind One Unified Interface）。DSec 暴露单一 Python SDK（libdsec），抽象了四种执行底层：Function Call 将无状态调用分发到预热容器池，消除冷启动开销；Container 完全兼容 Docker，并利用 EROFS（Gao et al., 2019）按需加载实现高效镜像组装；microVM 基于 Firecracker（Agache et al., 2020）构建，为安全敏感的高密度部署添加 VM 级别隔离；fullVM 基于 QEMU（Bellard, 2005）构建，支持任意客户操作系统。所有四种底层共享统一的 API 接口——命令执行、文件传输和 TTY 访问——切换只需更改一个参数。

通过分层存储实现快速镜像加载（Fast Image Loading via Layered Storage）。DSec 通过分层按需加载，在快速启动与大量且持续增长的环境镜像库之间取得平衡。对于容器，基础镜像和文件系统提交以 3FS 支持的只读 EROFS 层存储，直接挂载到 overlay lowerdirs 中；文件元数据在挂载时随时可在本地磁盘获取，数据块按需从 3FS 获取。对于 microVM，DSec 使用 overlaybd（Li et al., 2020）磁盘格式：只读基础层驻留在 3FS 上以供跨实例共享，写入到本地写时复制层。此类快照可链接，便于高效版本控制和毫秒级恢复。

大规模并发下的密度优化（Density Optimizations Under Massive Concurrency）。为容纳每集群数十万个沙箱，DSec 解决了两个资源瓶颈：一是缓解虚拟化环境中的重复页面缓存

占用，并应用内存回收以实现安全超额分配；二是缓解容器运行时中的自旋锁争用，降低每沙箱的 CPU 开销，显著提高每主机的打包密度。

轨迹日志与抢占安全恢复（Trajectory Logging and Preemption-Safe Resumption）。DSec 为每个沙箱维护全局有序的轨迹日志，持久记录每次命令调用及其结果。轨迹服务三个目的：(1) 客户端快进——当训练任务被抢占时，沙箱资源仍被保留；恢复后，DSec 重放之前已完成命令的缓存结果，加快任务恢复，同时防止非幂等操作的重新执行错误；(2) 细粒度来源追踪——每次状态变化的来源和对应结果均可追溯；(3) 确定性重放——可从轨迹忠实地重现任意历史会话。

5.3 标准基准评估

5.3.1 评估设置

知识与推理 (Knowledge and Reasoning)。知识与推理数据集包括：MMLU-Pro (Wang et al., 2024b)、GPQA (Rein et al., 2023)、Human Last Exam (Phan et al., 2025)、Simple-QA Verified (Haas et al., 2025)、Chinese-SimpleQA (He et al., 2024)、LiveCodeBench-v6 (Jain et al., 2024)、CodeForces（内部基准）、HMMT 2026 Feb、Apex (Balunović et al., 2025)、Apex Shortlist (Balunović et al., 2025)、IMOAnswerBench (Luong et al., 2025) 和 PutnamBench (Tsoukalas et al., 2024)。

对于代码任务，我们在 LiveCodeBench-v6 和内部 Codeforces 基准上评估 DeepSeek-V4 系列。对于 Codeforces，我们收集了 14 场 Codeforces Division 1 比赛，共 114 道题（2025 年 5 月至 11 月）。Elo 评分计算方式如下：对每场比赛的每道题生成 32 个候选解。对每道题独立地从这 32 个解中无放回采样 10 个，并以随机顺序排列形成提交序列。每次提交与领域专家构建的测试套件进行评判。已解决题目的得分遵循 OpenAI (2025) 的惩罚方案：模型获得在相同失败尝试次数下解决同一题目的人类参与者的中位数得分。这产生每个采样提交序列的总比赛得分，随后转换为比赛排名，再通过标准 Codeforces 评分系统转换为估计评分。比赛级期望评分定义为在所有可能的随机选择和排序下估计评分的期望值。模型的总评分是所有 14 场比赛的比赛级期望评分的平均值。

对于推理和知识任务，Non-think、High 和 Max 模式的温度均设为 1.0，上下文窗口分别设为 8K、128K 和 384K token。对于数学任务（HMMT、IMOAnswerBench、Apex 和 HLE），使用以下模板评估：”{question}
n 请逐步推理，并将最终答案放在
boxed{} 中。” 对于 DeepSeek-V4-Pro-Max 的数学任务，使用以下模板以引发更深度的推理。对于形式化数学任务，在智能体设置下于 Lean v4.28.0-rc1 (Moura and Ullrich, 2021) 中评估，可访问 Lean 编译器和语义策略搜索引擎，最多运行 500 次工具调用，使用最大推理努力程度。

百万 Token 上下文（1M-Token Context）。由于 DeepSeek-V4 系列支持百万 token 上下文，我们选择 OpenAI MRCR (OpenAI, 2024b) 和 CorpusQA (Lu et al., 2026) 作为基准，在长上下文场景下评估模型性能。我们重新评估了 Claude Opus 4.6 和 Gemini 3.1 Pro 在这些任务上的表现，以标准化所有模型的配置。由于其 API 未能响应大量查询，未评估 GPT-5.4。

智能体（Agent）。智能体数据集包括：Terminal Bench 2.0 (Merrill et al., 2026)、SWE-Verified (OpenAI, 2024e)、SWE Multilingual (Yang et al., 2025)、SWE-Pro (Deng et al., 2025)、BrowseComp (Wei et al., 2025)、MCPAtlas 公开评估集 (Bandi et al., 2026)、GDPval-AA (AA, 2025; Patwardhan et al., 2025) 和 Tool-Decathlon (Li et al., 2025)。

对于代码智能体任务，我们使用内部开发的评估框架评估 DeepSeek-V4 系列，提供最少工具集（bash 工具和文件编辑工具），最大交互步数设为 500，最大上下文长度设为 512K token。

5.3.2 评估结果

DeepSeek-V4-Pro-Max 与其他闭源/开源模型的对比见表 6（因篇幅关系，表格具体数值参见原文）。同时，我们评估了 DeepSeek-V4-Flash 和 DeepSeek-V4-Pro 的不同模式，结果见表 7。

知识 (Knowledge)。在世界通用知识评估中，DeepSeek-V4-Pro-Max——DeepSeek-V4-Pro 的最大推理努力模式——在开源大型语言模型中建立了新的最优水平。SimpleQA-Verified 的评估表明，DeepSeek-V4-Pro-Max 以 20 个绝对百分点的优势显著超越所有现有开源基准。尽管

如此，其表现仍落后于领先的专有模型 Gemini-3.1-Pro。在教育知识和推理领域，DeepSeek-V4-Pro-Max 在 MMLU-Pro、GPQA 和 HLE 基准上略微超越 Kimi 和 GLM，但仍落后于领先的专有模型。总体而言，DeepSeek-V4-Pro-Max 在增强开源模型世界知识能力方面树立了重要里程碑。

此外，DeepSeek-V4-Flash 和 DeepSeek-V4-Pro 在知识类任务上存在显著性能差距，这在预期之中——参数量越大，预训练期间知识保留越多。值得注意的是，两个模型在分配更高推理努力时，在知识基准上的结果均有所改善。

推理 (Reasoning)。DeepSeek-V4-Pro-Max 在推理基准上超越了所有先前的开源模型，并在许多指标上与最优秀的闭源模型持平；规模较小的 DeepSeek-V4-Flash-Max 同样在代码和数学推理任务上超越了此前最优开源模型 K2.6-Thinking。与此同时，DeepSeek-V4-Pro 和 DeepSeek-V4-Flash 在编程竞赛中表现出色：根据我们的评估，其性能与 GPT-5.4 相当，这是开源模型首次在此任务上与闭源模型持平。在 Codeforces 排行榜上，DeepSeek-V4-Pro-Max 目前在人类参与者中排名第 23 位。

DeepSeek-V4 在智能体和计算密集型设置下的形式化数学任务中均展现出强大的性能。在智能体设置下，它取得了最先进的结果（见图 8），超越了 Seed Prover (Chen et al., 2025) 等先前模型。在更计算密集型的流水线下，性能进一步提升，超越了包括 Aristotle (Achim et al., 2025) 在内的系统，并在该设置下与已知最佳结果相当。在 Putnam-2025 上，DeepSeek-V4 达到了完美的 120/120 分。

智能体（Agent）。 DeepSeek-V4 系列在评估中展现出强大的智能体性能。对于代码智能体任务，DeepSeek-V4-Pro 取得了与 K2.6 和 GLM-5.1 相当的结果，但所有这些开源模型仍落后于闭源对应模型。在其他智能体评估中也观察到类似趋势。值得注意的是，DeepSeek-V4-Pro 在 MCPAtlas 和 Toolathlon——两个包含广泛工具和 MCP 服务的评估测试集——上表现优异，表明我们的模型具有出色的泛化能力，并非仅在内部框架上表现良好。

百万 Token 上下文（1M-Token Context）。 DeepSeek-V4-Pro 在 MRCR 任务（衡量上下文内检索）上超越了 Gemini-3.1-Pro，但仍落后于 Claude Opus 4.6。如图 9 所示，在 128K 上下文窗口内检索性能保持高度稳定；超过 128K 后性能有所下降，但与专有和开源模型相比，模型在百万 token 处的检索能力仍相当强。与 MRCR 不同，CorpusQA 更接近真实场景，评估结果同样表明 DeepSeek-V4-Pro 优于 Gemini-3.1-Pro。

推理努力程度（Reasoning Effort）。如表 7 所示，在 RL 中使用更长上下文和更小长度惩罚的 Max 模式，在最具挑战性的任务上优于 High 模式。图 10 展示了 DeepSeek-V4-Pro、DeepSeek-V4-Flash 和 DeepSeek-V3.2 在代表性推理和智能体任务上的性能与成本对比。通过扩展推理时计算量，DeepSeek-V4 系列相较前代模型取得了显著改进。

5.4 真实任务性能

标准化基准通常难以捕捉多样化真实任务的复杂性，造成测试结果与实际用户体验之间的差距。为弥合这一差距，我们开发了优先考虑真实使用模式而非传统基准的专有内部指标，确保我们的优化能转化为切实的收益。我们的评估框架专门针对 DeepSeek API 和聊天机器人的主要使用场景，将模型性能与实际需求对齐。

5.4.1 中文写作

DeepSeek 的主要使用场景之一是中文写作。我们对功能性写作和创意写作进行了严格评估。表 12 展示了 DeepSeek-V4-Pro 与 Gemini-3.1-Pro 在功能性写作任务上的成对比较。这些任务由常见的日常写作查询组成，提示通常简洁直接。Gemini-3.1-Pro 被选为基准，因为它是我们评估中中文写作表现最好的外部模型。结果显示，DeepSeek-V4-Pro 以 62.7% 对 34.1% 的总体胜率超越基准，主要原因是 Gemini 在中文写作场景中偶尔允许其固有的风格偏好凌驾于用户的明确要求之上。

表 13 展示了创意写作对比，从两个维度评估：指令遵循和写作质量。与 Gemini-3.1-Pro 相比，DeepSeek-V4-Pro 在指令遵循上实现了 60.0% 的胜率，在写作质量上实现了 77.5% 的胜率，显示出在指令遵循方面的略微改进和在写作质量方面的显著提升。尽管 DeepSeek-V4-Pro 在总体用户案例分析中取得了更好的结果，但仅限于最具挑战性的提示（特别是涉及高复杂度约束

或多轮场景的提示）的评估显示，Claude Opus 4.5 仍保持着对 DeepSeek-V4-Pro 的性能优势，如表 14 所示：Claude Opus 4.5 实现了 52.0% 的胜率，而 DeepSeek-V4-Pro 为 45.9%。

5.4.2 搜索

搜索增强型问答是 DeepSeek 聊天机器人的核心能力。在 DeepSeek 网页端和应用端，"non-think" 模式采用检索增强搜索（Retrieval-Augmented Search，RAG），而"thinking" 模式则利用智能体搜索。

检索增强搜索（Retrieval Augmented Search）。我们对 DeepSeek-V4-Pro 和 DeepSeek-V3.2 在客观和主观问答类别上进行了成对评估。如表 11 所示，DeepSeek-V4-Pro 以较大优势超越 DeepSeek-V3.2，在两个类别上均保持一致优势。最显著的提升出现在单值搜索和规划策略任务上，表明 DeepSeek-V4-Pro 擅长定位精确的事实答案并从检索上下文中合成结构化计划。然而，DeepSeek-V3.2 在比较和推荐任务上仍相对有竞争力，表明 DeepSeek-V4-Pro 在需要对搜索结果进行平衡、多角度推理的场景中有进一步改进的空间。

智能体搜索（Agentic Search）。与标准 RAG 不同，智能体搜索赋予模型针对每个查询迭代调用搜索和获取工具的能力，显著提升了整体搜索性能。对于 DeepSeek-Chat 中的思考模式，我们优化了智能体搜索功能，以在预定义的" 思考预算" 内最大化响应准确性。如表 9 所示，智能体搜索在复杂任务上始终优于 RAG。此外，其成本保持高度高效，智能体搜索仅比标准 RAG 略贵（见表 10）。

5.4.3 白领任务

为严格评估模型在复杂企业生产力场景中的实用性，我们构建了包含 30 项高级中文专业任务的综合套件。这些工作流刻意涵盖高级认知需求，包括深度信息分析、全面文档生成和细致的文档编辑，横跨 13 个关键行业（如金融、教育、法律和科技）。评估在配备基础工具（包括 Bash 和网页搜索）的内部智能体框架中进行。

由于这些任务的开放性，自动化指标通常无法捕捉高质量响应的细微差别。因此，我们进行了人工评估，将 DeepSeek-V4-Pro-Max 与 Opus-4.6-Max 的性能进行对比。评注员在四个维度上盲评模型输出：(1) 任务完成度（Task Completion）：核心问题是否得到成功解决；(2) 指令遵循（Instruction Following）：对特定约束和指令的遵守程度；(3) 内容质量（Content Quality）：事实准确性、逻辑连贯性和专业语气；(4) 格式美观性（Formatting Aesthetics）：布局可读性和视觉呈现。

如图 11 所示，DeepSeek-V4-Pro-Max 在多样化的中文白领任务上超越了 Opus-4.6-Max，实现了令人印象深刻的 63% 不输率，并在分析、生成和编辑任务中展现出一致优势。图 12 所示的详细维度分数突显了模型在任务完成度和内容质量方面的主要优势：DeepSeek-V4-Pro-Max 通过频繁提供补充见解和自我验证步骤，主动预测隐性用户意图；它还擅长长文生成，提供深入连贯的叙述，而不是依赖 Opus-4.6-Max 频繁产生的过于简单的要点列表；此外，模型严格遵守正式专业惯例，如标准化的中文分层编号。然而，在指令遵循方面，它偶尔忽视特定的格式约束，略落后于 Opus。此外，模型在将大量文本输入压缩为简洁摘要方面能力较弱；其格式美观性在演示文稿幻灯片的整体视觉设计方面仍有较大改进空间。

5.4.4 代码智能体

为对我们的代码智能体能力进行基准测试，我们从真实的内部研发工作负载中精心策划任务：从 50 余名内部工程师处收集约 200 个具有挑战性的任务，涵盖功能开发、错误修复、重构和诊断，横跨 PyTorch、CUDA、Rust 和 C++ 等多种技术栈。每个任务附有原始代码仓库、对应的执行环境和人工标注的评分标准；经过严格的质量过滤后，保留 30 个任务作为评估集。如表 8 所示，DeepSeek-V4-Pro 显著优于 Claude Sonnet 4.5，并接近 Claude Opus 4.5 的水平。

在一项针对 DeepSeek 开发者和研究人员（$N = 85$）的调查中——他们均有在日常工作中使用 DeepSeek-V4-Pro 进行智能体编码的经验——被问及 DeepSeek-V4-Pro 是否准备好作为与其他前沿模型相比的默认和主要编码模型时，52% 表示是，39% 倾向于是，不到 9% 表示否。受访者认为 DeepSeek-V4-Pro 在大多数任务上能提供令人满意的结果，但指出了一些细微错误、对模糊提示的误解，以及偶尔的过度思考。

6 结论、局限性与未来方向

在本工作中，我们发布了 DeepSeek-V4 系列的预览版本，旨在构建下一代大型语言模型，突破超长上下文处理的效率瓶颈。通过融合 CSA 与 HCA 的混合注意力架构，DeepSeek-V4 系列在长序列处理效率上实现了飞跃。这些架构创新，辅以全面的基础设施优化，使模型能够原生高效地支持百万 token 上下文，并为未来的推理时扩展、长程任务以及在线学习等新兴范式奠定了必要的基础。评测结果表明，DeepSeek-V4-Pro 的最大推理模式 DeepSeek-V4-Pro-Max 重新定义了开源模型的最优水平：在知识基准上大幅超越此前的开源模型，在推理性能上接近前沿专有模型，并具备极具竞争力的智能体能力。与此同时，DeepSeek-V4-Flash-Max 在保持高度经济高效架构的同时，取得了与领先闭源模型相当的推理性能。我们相信，DeepSeek-V4 系列开创了开源模型百万 token 上下文的新纪元，并为实现更高效率、更大规模、更强智能铺平了道路。

在追求极致长上下文效率的过程中，DeepSeek-V4 系列采用了大胆的架构设计。为降低风险，我们保留了许多经初步验证的组件与技巧，这些组件虽然有效，但也使架构相对复杂。在未来的迭代中，我们将开展更加系统和原则性的研究，将架构精简至最本质的设计，使其在不牺牲性能的前提下更加优雅。此外，尽管预期路由（Anticipatory Routing）和 SwiGLU 截断（SwiGLU Clamping）已被证明能有效缓解训练不稳定性，但其背后的原理仍有待深入理解。我们将积极研究训练稳定性的基础性问题，并强化内部指标监控，以期建立更具原则性和可预测性的大规模稳定训练方法。

此外，除 MoE 和稀疏注意力架构之外，我们还将主动探索新维度的模型稀疏化方向——例如更稀疏的嵌入模块（Cheng et al., 2026）——以在不损害能力的前提下进一步提升计算和内存效率。我们还将持续研究低延迟架构与系统技术，使长上下文的部署和交互更加流畅。此外，我们认识到长程多轮智能体任务的重要性与实用价值，将持续在这一方向上迭代探索。我们也在致力于为模型引入多模态能力。最后，我们承诺不断优化数据整理与合成策略，在日益广泛的场景和任务中持续提升模型的智能水平、鲁棒性和实用性。

A 作者列表与致谢

A.1 作者列表

作者按名字首字母排序。标注 * 的人员已离开我们的团队。

研究与工程： Anyi Xu, Bangcai Lin, Bing Xue, Bingxuan Wang*, Bingzheng Xu, Bochao Wu, Bowei Zhang, Chaofan Lin, Chen Dong, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenhao Xu, Chenze Shao, Chong Ruan*, Conner Sun, Damai Dai, Daya Guo*, Dejian Yang, Deli Chen, Donghao Li, Erhang Li, Fangyun Lin, Fangzhou Yuan, Feiyu Xia, Fucong Dai, Guangbo Hao, Guanting Chen, Guoai Cao, Guolai Meng, Guowei Li, Han Yu, Han Zhang, Hanwei Xu, Hao Li, Haofen Liang, Haoling Zhang, Haoming Luo, Haoran Wei*, Haotian Yuan, Haowei Zhang*, Haowen Luo, Haoyu Chen, Haozhe Ji, Honghui Ding, Hongxuan Tang, Huanqi Cao, Huazuo Gao, Hui Qu, Hui Zeng, J. Yang, J.Q. Zhu, Jia Yu, Jialiang Huang, Jiasheng Ye, Jiashi Li, Jiaxin Xu, Jiewen Hu, Jin Yan, Jingchang Chen, Jingli Zhou, Jingting Xiang, Jingyang Yuan, Jingyuan Cheng, Jinhua Zhu, Jiping Yu, Joseph Sun, Jun Ran*, Junguang Jiang, Junjie Qiu, Junlong Li*, Junxiao Song, Kai Dong, Kaige Gao, Kang Guan, Kexing Zhou, Kezhao Huang*, Kuai Yu, Lean Wang, Lecong Zhang, Lei Wang, Li Zhang, Liang Zhao, Lihua Guo, Lingxiao Luo, Linwang Ma, Litong Wang, Liyu Cai, Liyue Zhang, Longhao Chen, M.S. Di, M.Y Xu, Max Mei, Mingchuan Zhang, Minghua Zhang, Minghui Tang, Mingxu Zhou, Panpan Huang, Peixin Cong, Peiyi Wang, Qiancheng Wang, Qihao Zhu, Qingyang Li, Qinyu Chen, Qiushi Du, Qiwei Jiang, Rui Tian, Ruifan Xu, Ruijie Lu, Ruiling Xu, Ruiqi Ge, Ruisong Zhang, Ruizhe Pan, Runji Wang, Runqian Chen, Runqiu Yin, Runxin Xu, Ruomeng Shen, Ruoyu Zhang, S.H. Liu, Shanghao Lu, Shangyan Zhou, Shanhuang Chen, Shaofei Cai, Shaoheng Nie, Shaoyuan Chen, Shengding Hu, Shengyu Liu, Shiqiang Hu, Shirong Ma, Shiyu Wang, Shuiping Yu, Shunfeng Zhou, Shuting Pan, Shuying Yu, Songyang Zhou, Tao Ni, Tao Yun, Tian Jin, Tian Pei, Tian Ye, Tianle Lin, Tianran Ji, Tianyi Cui, Tianyuan Yue, Tingting Yu, Tun Wang, W. Zhang, Wangding Zeng, Weilin Zhao, Wen Liu, Wenfeng Liang, Wenjie Pang, Wenjing Luo, Wenjing

Yao, Wenjun Gao, Wenkai Yang, Wenlve Huang, Wentao Zhang, Wenting Ma, Xi Gao, Xiang He, Xiangwen Wang, Xiao Bi, Xiaodong Liu, Xiaohan Wang, Xiaokang Chen, Xiaokang Zhang, Xiaotao Nie, Xin Cheng, Xin Liu, Xin Xie, Xingchao Liu, Xingchen Liu, Xingkai Yu, Xingyou Li, Xinyu Yang, Xu Chen, Xuanyu Wang, Xuecheng Su, Xuheng Lin, Xuwei Fu, Y.C. Yan, Y.Q. Wang*, Y.W. Ma, Yanfeng Luo, Yang Zhang, Yanhong Xu, Yanru Ma, Yanwen Huang, Yao Li, Yao Li, Yao Zhao, Yaofeng Sun, Yaohui Wang, Yi Qian, Yi Yu, Yichao Zhang, Yifan Ding, Yifan Shi, Yijia Wu, Yiliang Xiong, Ying He, Ying Zhou, Yingjia Luo, Yinmin Zhong, Yishi Piao, Yisong Wang, Yixiang Zhang, Yixiao Chen, Yixuan Tan, Yixuan Wei, Yiyang Ma, Yiyuan Liu, Yonglun Yang, Yongqiang Guo, Yongtong Wu, Yu Wu, Yuan Cheng, Yuan Ou, Yuanfan Xu, Yuanhao Li, Yuduan Wang, Yuhan Wu, Yuhao Meng, Yuheng Zou, YuKun Li, Yunfan Xiong, Yupeng Chen, Yuqian Cao, Yuqian Wang, Yushun Zhang, Yutong Lin, Yuxian Gu, Yuxiang Luo, Yuxiang You, Yuxuan Liu, Yuxuan Zhou, Yuyang Zhou, Yuzhen Huang, Z.F. Wu, Zehao Wang, Zehua Zhao, Zehui Ren, Zhangli Sha, Zhe Fu, Zhean Xu, Zhenda Xie, Zhengyan Zhang, Zhewen Hao, Zhibin Gou, Zhicheng Ma, Zhigang Yan, Zhihong Shao, Zhixian Huang, Zhixuan Chen, Zhiyu Wu, Zhizhou Ren, Zhuoshu Li, Zhuping Zhang, Zian Xu, Zihao Wang, Zihui Gu, Zijia Zhu, Zilin Li, Zipeng Zhang*, Ziwei Xie, Ziyi Gao, Zizheng Pan, Zongqing Yao.

商务与合规： Chenchen Ling, Chengyu Hou, Dongjie Ji, Fang Wei, Hengqing Zhang, Jia Luo, Jia Song, Jialu Cai, Jian Liang, Jiangting Zhou, Jieyu Yang, Jin Chen, Jingzi Zhou, Junmin Zheng, Leyi Xia, Linyan Zhu, Miaojun Wang, Mingming Li, Minmin Han, Ning Wang, Panpan Wang, Peng Zhang, Ruyi Chen, Shangmian Sun, Shaoqing Wu, W.L. Xiao, Wei An, Wenqing Hou, Xianzu Wang, Xiaowen Sun, Xiaoxiang Wang, Xinyu Zhang, Xueyin Chen, Yao Xu, Yi Shao, Yiling Ma, Ying Tang, Yuehan Yang, Yuer Xu, Yukun Zha, Yuping Lin, Yuting Yan, Zekai Zhang, Zhe Ju, Zheren Gao, Zhongyu Wu, Zihua Qu, Ziyi Wan.

A.2 致谢

感谢 Dolly Deng 及其他测试人员为 DeepSeek-V4 系列模型的能力评估提供的宝贵建议与反馈。

B 评测详情

Table 1: 表 9 DeepSeek-V4-Pro 智能体搜索（Agentic Search）与检索增强搜索（RAG）对比评估

难度类别	问题类型	#	智能体胜	RAG 胜	平局	智能体%	RAG%
简单	客观问答	196	110	43	43	56.1	21.9
	主观问答	321	198	56	67	61.7	17.4
困难	客观问答	168	102	33	33	60.7	19.6
	主观问答	184	126	27	31	68.5	14.7
总计		869	536	159	174	61.7	18.3

Table 2: 表 10 DeepSeek-V4-Pro 智能体搜索与检索增强搜索成本对比（均值）。智能体搜索中大多数工具调用为并行执行。

版本	工具调用次数	预填充（token 数）	输出（token 数）
V4 智能体搜索	16.2	13649	1526
V4 检索增强搜索	—	10453	1308

Table 3: 表 11　DeepSeek-V4-Pro 与 DeepSeek-V3.2 在搜索问答任务上的对比评估（内部综合评估）

类别	子类别	#	V4 胜	V3.2 胜	平局	V4%	V3.2%
客观问答	单值信息查找	95	36	10	49	37.9	10.5
	实体信息查找	99	24	7	68	24.2	7.1
	枚举型信息查找	95	19	8	68	20.0	8.4
	小计	289	79	25	185	27.3	8.7
主观问答	原因分析	100	28	5	67	28.0	5.0
	对比	96	28	20	48	29.2	20.8
	寻求建议	92	23	8	61	25.0	8.7
	推荐	95	26	19	50	27.4	20.0
	攻略计划	92	32	11	49	34.8	12.0
	评价看法	96	30	8	58	31.2	8.3
	趋势分析	96	23	3	70	24.0	3.1
	小计	667	190	74	403	28.5	11.1
总计		956	269	99	588	28.1	10.4

Table 4: 表 12　DeepSeek-V4-Pro 与 Gemini-3.1-Pro 在中文功能性写作上的对比分析（内部综合评估）

类别	子类别	#	DS 胜	Gem 胜	平局	DS%	Gem%
办公文本	报告	527	350	162	15	66.4	30.7
	方案策划	291	181	103	7	62.2	35.4
	教育培训	159	100	56	3	62.9	35.2
	邮件书信	146	107	37	2	73.3	25.3
	通知公告	72	43	24	5	59.7	33.3
	专业文本	63	34	27	2	54.0	42.9
	招聘求职	42	27	15	0	64.3	35.7
	技术文本	29	22	7	0	75.9	24.1
	介绍评价	20	15	5	0	75.0	25.0
	小计	1349	879	436	34	65.2	32.3
沟通回复	祝贺文本	267	156	101	10	58.4	37.8
	沟通回复	214	109	98	7	50.9	45.8
	心得感想	99	71	25	3	71.7	25.3
	介绍评价	51	27	22	2	52.9	43.1
	评论	17	12	4	1	70.6	23.5
	其他	11	7	4	0	63.6	36.4
	创意写作	4	2	1	1	50.0	25.0
	综合	3	2	1	0	66.7	33.3
	小计	666	386	256	24	58.0	38.4
生活文本	祝贺文本	101	54	41	6	53.5	40.6
	心得感想	100	71	26	3	71.0	26.0
	介绍评价	90	68	17	5	75.6	18.9
	评论	55	44	9	2	80.0	16.4
	其他	44	34	8	2	77.3	18.2
	小计	390	271	101	18	69.5	25.9
口头文本	发言稿	226	135	85	6	59.7	37.6
	口播文案	51	25	23	3	49.0	45.1
	话术	31	22	6	3	71.0	19.4
	对话文本	10	4	6	0	40.0	60.0
	祝贺文本	1	1	0	0	100.0	0.0
	小计	319	187	120	12	58.6	37.6
公文文本	事务文书	117	60	53	4	51.3	45.3
	个人文书	73	45	27	1	61.6	37.0
	行政公文	34	19	14	1	55.9	41.2
	发言稿	3	1	2	0	33.3	66.7
	申论写作	3	1	1	1	33.3	33.3
	小计	230	126	97	7	54.8	42.2
学术文本	学术论文	104	67	32	5	64.4	30.8
	课程作业	90	53	35	2	58.9	38.9
	学术辅助	15	11	3	1	73.3	20.0
	专业科普	7	6	1	0	85.7	14.3
	小计	216	137	71	8	63.4	32.9
总计		**3170**	**1986**	**1081**	**103**	**62.7**	**34.1**

Table 5: 表 13　DeepSeek-V4-Pro 与 Gemini-3.1-Pro 在中文创意写作上的对比分析（内部综合评估）

文体	#	指令遵循			写作质量		
		DS%	Gem%	Tie%	DS%	Gem%	Tie%
小说故事	836	60.6	38.8	0.6	80.8	18.9	0.4
泛小说故事	662	55.7	43.9	0.5	70.7	29.4	0.0
同人文	410	62.3	37.0	0.7	83.3	16.5	0.2
泛同人文	202	55.0	44.6	0.5	79.7	19.8	0.5
记叙文	171	67.3	31.6	1.2	82.5	17.5	0.0
泛散文	124	66.9	32.3	0.8	71.0	29.0	0.0
散文	112	66.1	33.9	0.0	82.1	17.9	0.0
文笔	112	72.3	27.7	0.0	76.8	23.2	0.0
古诗文	48	50.0	50.0	0.0	81.3	18.8	0.0
现代诗	43	53.5	46.5	0.0	74.4	25.6	0.0
歌词	30	26.7	73.3	0.0	53.3	46.7	0.0
赏析	27	74.1	25.9	0.0	66.7	33.3	0.0
泛议论文	24	62.5	37.5	0.0	70.8	29.2	0.0
泛记叙文	23	47.8	52.2	0.0	65.2	34.8	0.0
泛古文诗歌	9	55.6	44.4	0.0	55.6	44.4	0.0
创意写作	6	33.3	66.7	0.0	66.7	33.3	0.0
议论文	5	100.0	0.0	0.0	100.0	0.0	0.0
泛现代诗	2	50.0	50.0	0.0	100.0	0.0	0.0
总计	**2837**	**60.0**	**39.4**	**0.5**	**77.5**	**22.4**	**0.2**

Table 6: 表 14　DeepSeek-V4-Pro 与 Claude-Opus-4.5 在复杂指令跟随与多轮写作上的对比（内部综合评估）

类别	#	DS 胜	Opus 胜	平局	DS%	Opus%
复杂指令跟随	49	23	26	0	46.9	53.1
多轮写作	147	67	76	4	45.6	51.7
总计	196	90	102	4	45.9	52.0