AI 时代的数学方法与人类思想

TANYA KLOWDEN 和 TERENCE TAO

Abstract. 人工智能（Artificial intelligence，AI）是对一系列被设计用来执行日益复杂的认知任务的计算机工具的通俗称谓，这些任务中有许多过去专属于人类。随着这些工具变得指数级地复杂和无处不在，其快速发展并被整合进社会的理由屡屡受到质疑——尤其是因为它们消耗着有限的资源，并对那些看似将被它们所取代的熟练个体的生计构成生存威胁。本文中，我们考察 AI 对哲学传统问题正在快速演化的影响，重点关注其在数学中的应用以及更广泛的现实世界中通用使用的结果。我们主张，人工智能是人类在历史长河中为促进思想的创造、组织和传播而开发的工具的自然延续，并论证 AI 的发展和应用必须始终保持以人为本，这一点至关重要。着眼于创新解决方案以满足人类需求、提升人类生活质量并扩展人类思想与理解的能力，我们提出一条将 AI 整合进我们最具挑战性、最严苛的学科领域以造福全人类的路径。

1. 引言

这足以证明人工智能（artificial intelligence，AI）技术被部署到数字生活每个角落的速度之快——在使用标准工具撰写本文的过程中，作者们被不少于三个不同的数字智能体在未经邀请的情况下插入了叙述之中[1]。人类正站在一场数字工业革命的门槛上，这场革命以前所未有的速度展开。在自然科学领域，AI 的进步已经催生了获得诺贝尔奖的研究成果 [1]；而在人文学科领域，人们普遍担忧现代 AI 的生成式文本能力可能会终结该学科 [2]。正如语言翻译工具打开了文化交流与国际合作的大门，大量深度伪造（deepfake）内容和劣质内容也随之涌入，充斥着我们的数字公共空间。AI 迅速从一种新奇事物，变成了重要资源，乃至（在某些情况下）现实存在的生存威胁 [3]。

1.1. 本文对人工智能的定义.

在本文中，AI 指的是一系列旨在执行日益复杂认知任务的计算机工具，包括许多曾经仅属于人类专属领域的任务。AI 工具极为多样，从当今以数据驱动的机器学习（machine learning，ML）技术（如能够处理复杂文本的大型语言模型（large language model, LLM），或能够生成图像及其他媒体的扩散模型（diffusion model））， 到更传统的经典符号式人工智能（good-old fashioned AI, GOFAI）（如自动定理证明器或国际象棋引擎），不一而足，后者可以通过运用精确的数学规则来解决特定范围内的问题。

[1]所有这些 AI" 贡献" 均已从文本中迅速删除。

1.2. **本文目的.** 关于这些工具能做什么或不能做什么，已有大量讨论；但相比之下，关于为何这些工具被如此迅速地开发和部署，以及它们如何影响数十亿与之互动的人们——无论是在研究与教育、工作、娱乐，还是休息方面 [4]——的讨论却相对匮乏。本文作者来自学界中常被视为截然对立的两个领域：数学与艺术研究。但我们都发现，在各自迥异的日常研究中融入若干 AI 工具是有益的，并在现实 AI 使用所带来的那些错综复杂却又普遍存在的哲学问题上，发现了出人意料的共同点。以数学为模型，我们将探讨将 AI 融入日常工作流程的益处、风险、伦理与结果，并将这些观察拓展到更广泛的现实应用场景。尽管这些新兴技术——并不一定是道德中立的——带来了诸多风险，我们仍双管齐下地主张：AI 工具应当在数学领域及其他领域中得到开发、实施与应用：它们有潜力从根本上增强我们天然的人类能力，并能够将可能性拓展到我们个人或在集体能力边界内所能实现的范畴之外。结合我们自身使用这些工具的经历，我们特别审视了人机交互界面，并就这些技术的演进方向提出建议，以期这些技术能为人类带来更多益处而非危害，同时珍视人类思想与行动的独特贡献，与未来 AI 发展所承诺的新模式协同共进。

1.3. **浮士德式交易.** 市场竞争的激励机制推动了 AI 技术以狂热的速度发展，并以大幅加速工作流程和节省成本的愿景吸引了整个行业。这种竞争所形成的" 囚徒困境" 迫使许多个人和组织尽可能仓促地尝试采用这些工具，而未能更审慎地评估此类采用的经济、社会或道德成本与收益——或者更根本地说，未能思考我们为何首先要开发此类技术。由此，我们集体上已经事实上（de facto）与这些技术达成了一种" 浮士德式交易"，赋予它们越来越多地访问我们数据、认知工作流程和决策过程的权限，以换取能够以更高效率、更少繁琐努力完成更广泛任务的承诺。

理论上，技术是道德中立的；它既能赋能正面用途，也能赋能负面用途。但通过这种赋能，它加剧了现有的道德困境，并催生了新的困境。例如，第二次世界大战期间对囚犯进行的骇人听闻的医学实验获得了有关人类耐力极限的宝贵数据，由此引发了关于利用这些数据推进新医学研究是否符合伦理的艰难问题 [5]。虽然不那么触目惊心，但用于训练当前这一代 AI 工具的数据和知识产权来源不明，可以说在今天提出了类似的问题 [6]。

当一项技术发展足够缓慢时，有可能在其广泛部署之前就对其进行必要的哲学讨论与辩论；干细胞研究便是一个值得关注的例子。然而，现代 AI 技术已经被广泛部署，实际上已无法" 将精灵重新塞回瓶中"；讽刺的是，此时强加的严格监管将不成比例地扼杀 AI 较为积极的应用场景（例如加速科学研究），而无法消除该技术中更为浪费或恶意的用途。从务实角度来看，关于 AI 的讨论现在已转向如何管理与这些技术的共存：评估 AI 的成本与收益（既包括在学术学科内部，也包括对更广泛社会的影响），以及识别最佳实践和框架，以尽可能积极的方式使用 AI，同时遏制这些工具在众多方面被拙劣使用、从而损害我们认知成果的可靠性与价值的倾向。

2. 历史先例：这次有何不同?

2.1. **自动化技术的历史整合.** 自动化当然不是新现象。许多过去的技术也曾实现了对原本由人类承担的任务的自动化，消除或大幅减少了对某些类型人类工作的需求，同时也创造或增加了对另一些工作的需求；在某些情况下如此。例如在科学界，曾发生过" 相变"（phase transition），由于互联网、用于科学计算的计算机，甚至像 LaTeX 这样不起眼的排版语言等新工具具有明显优势，科学界迅速而广泛地转向使用这些工具。但这些过去的技术大多影响了专业的次要方面，例如成果的传播与交流，而非成果本身的创造。而且，尽管被这些工具自动化的任务需要专业培训和专业知识才能完成，但它们通常不需要对一个职业更具哲学深度的方面有所理解，例如知识、美、意义或道德的本质 [7]。当然，此类技术仍然可以引发关于哲学议题的讨论——例如，一件原创艺术品是否具有任何机械复制都无法恰当捕捉的内在美学或创造性特质，或者工业革命所导致的劳动力流失的道德与伦理含义——但它们并不被认为会挑战支撑此类讨论的根本哲学假设。例如，印刷机的发明彻底改变了信息和思想的传播，但它并没有从根本上改变人们对思想或信息是什么的理解；此类内容的原始生成仍然是由人类的有意识行动完成的。

2.2. **现代人工智能.** 但现代 AI 能够自动化大部分创造过程本身，使得艺术作品、数学证明，或科学、哲学理论等智识产品的大规模生成成为可能，所需的人类监督远少于以往[2]。这在此类产品的外在形式与用于创造这些产品的价值观和思维过程之间，产生了前所未有的脱耦。例如，扩散模型现在可以创作出一幅美学上令人愉悦的风景画，而这幅画并非直接受到物理世界中任何特定地点的启发，尽管训练该模型输出时确实使用了无数真实风景的图像（以及许多与风景完全无关的图像）；图像的美学感受因此与这种美学的原始来源脱耦了。

这绝非新的哲学领域。Searle 的" 中文屋" 思想实验 [8]——探讨一个被编程为用中文进行对话的机械装置是否真正理解这门语言——可以追溯到 1980 年。"AI 效应"（AI effect）也在大约同一时期被认识到；例如，在国际象棋引擎出现之前，在国际象棋上表现出色曾被视为衡量智能的良好标准，这些引擎可以通过对博弈树的机械探索" 不假思索地" 超越国际象棋大师，此后" 国际象棋测试" 作为智能标准便基本被放弃了。著名的" 图灵测试"（Turing test）——即 AI 能否以与人类无法区分的方式进行对话——类似地已被现代 LLM 有效通过（参见 [9]），其作为人工智能" 黄金标准" 的昔日地位已不复存在。关于更近期的讨论，参见 [10]。

就目前而言，我们仍然可以指出" 根本性" 理解的标志，例如能否（或是否缺乏能力）连贯地解释和捍卫导致新艺术作品、数学证明或其他智识产品的创造过程，这仍是区分人类与 AI 生成内容的一个可行测试；但如果未来几代 AI 也能设法令人信服地通过此类测试，我们是否将不得不再次移动关于智能、理解和创造力究竟是什么的目标

[2]当前工具通常仍需要人类为 AI 生成一个初始提示词（prompt），但这一过程本身现在也可以在很大程度上自动化。

柱? 数学和人文学科等学科的定义、价值观和目标是否需要重新评估? 我们应当赋予这些日益复杂的 AI 工具怎样的地位——它们将是助手、合著者，还是独立的创造者? 如果是这样，我们应当如何对待它们所产生的内容，以及导致此类内容产生的智识过程?

3. 数学作为 AI 应用的沙盒

关于 AI 的这些更宏观的哲学问题极为复杂且多面，我们当然不会假装对其中任何一个问题都有确定性的解答；而且这一领域的变化速度之快，使得我们所做的任何断言都面临被引人瞩目的新技术进步所超越的风险。然而，我们可以从数学世界提供一些视角，既包括纯数学推理领域，也包括现代数学分析在人文学科中的新兴应用。我们将数学视为探索宏观问题（如 AI 对科学乃至整个社会的影响）的合适”沙盒”，因为它拥有更悠久、更扎实的基础，且其本质决定了它非常适合探索各种与现实相悖的假设性抽象场景。我们希望，从将 AI 融入（或不融入）数学的过程中汲取的经验教训，能够为 AI 如何与科学和社会整体互动提供更广泛的视角。

前沿 AI 模型现在能够解决日益复杂的数学问题，并给出可以独立验证的证明，而无需直接复现人类数学家的解题实践（例如测试特殊情形，然后从中归纳推广），尽管其训练数据中会包含以这种传统方式生成的证明；因此，数学家将越来越多地遭遇这样的情形：证明定理的能力与发现和理解此类证明所需的推理过程相互脱耦。这助长了现代数学去中心化的既有趋势；在一个先进数学被极为广泛的应用领域所需要的世界里，由一个中央权威规定数学正统实践的” 布尔巴基（Bourbaki）时代”[11] 早已成为数十年前的历史[3]。

就当前技术状态而言，最先进的 AI 工具仍然表现出显著且往往奇异的弱点；它们在某些任务上能达到非凡乃至超人的表现，同时在其他任务上又表现出令人忍俊不禁的基本误解和错误。数学也不例外。AI 生成的数学在表面上可能看起来无懈可击——这是意料之中的，因为这些模型被设计为尽可能生成在视觉上接近正确人类证明的输出——同时也会犯根本性的错误（例如，断言所有奇数都是质数），而人类数学家在训练的早期阶段便会被纠正这类错误，这往往会使最终论证荒唐到无可救药的地步。与此同时，这种主要聚焦于生成好看输出而非关注创造此类输出所传统需要的基本认知过程的自上而下方法，有时会出奇地有效；同一个在数学基本问题上屡屡出错的 AI，有时也能神秘地以超越人类专家的精准度给出复杂数学问题的正确答案，甚至提供一个奇特但在技术上正确的答案证明。

目前正在投入大量努力，以期尽可能地减少或消除 AI 的这些弱点；这往往不是通过直接强化 AI 对任何给定智识任务的内在” 理解”，而是将此类 AI 工具置于严格的独立测试、训练和验证环境中，以减少错误的数量。解决深层数学猜想的能力目前仍超出完全自主 AI 的能力范围，但在不久的将来，即使我们仍会对将此类辅助描述为真正智能思维的表达有所犹豫，此类 AI 工具极有可能极大地协助人类数学

[3]尽管有人可以争辩，正在进行中的创建大型统一形式数学库的项目（如 Lean 的Mathlib项目）可能是布尔巴基小组努力的现代继承者。

家完成此类工作。尽管如此，这种机械性且容易出错的方法能够（或即将能够）在数学这样一门智识性学科中产生如此众多的传统质量标志，这一事实表明我们必须重新评估对于智能或创造力究竟是什么以及如何衡量的认知模型。

4. 人工智能与数学真理的本质

4.1. **数学与证明标准.** 数学[4]长期以来拥有客观的证明标准传统，这一传统始于 Euclid，并随着二十世纪初稳定且（经验上）牢固的数学基础的出现而不断完善。有观点指出（见，例如，[13]），这些基础几乎得到普遍接受，使现代数学获得了一种罕见而宝贵的能力——能够就该领域中任何给定论证或断言的有效性达成共识，因为（原则上）可以坚持将这些论证详细阐述到每一步骤都可被核查为数学标准公理和逻辑推理规则的正确应用。一个典型的例子是 Nelson [14] 在 2011 年声称皮亚诺公理（Peano Axioms）在逻辑上不一致；这一主张与数学主流相去甚远，然而通过指出 Nelson 欣然接受的论证中的一个细微缺陷，问题得以解决，Nelson 随即撤回了该主张。

然而在实践中，人类数学家的论证往往达不到完美严格证明的理想；文献中的大大小小的错误十分常见，其中一些通过正式勘误或修订得以纠正，而另一些则被忽视，或以" 民间传说" 的形式在子领域中非正式流传。启发式上合理的论证往往以最少的核查就被接受，而与传统观念相悖的惊人断言则会遭遇强烈质疑，即便这些论证在逐行阅读后最终确实是正确的。

4.2. **嗅觉测试.** 迄今为止，这种状况尚算令人满意；遵循良好启发式方法和直觉的人类数学家往往能产生令人信服的证明，且这些证明大体上是正确的，大多数错误也是可以修正的；而缺乏此类直觉的数学家往往会产生包含足够多表面问题的证明，使人在仔细核查之前就有理由对其内容心存疑虑。非正式地说，人类生成的数学论证往往带有[5]一种" 气味"，经验丰富的数学家（也许是潜意识地）在尚未检验论证的各个步骤之前，就用这种气味来获取对论证说服力的初步印象。例如，Aaronson [15] 的博客文章" 声称数学突破有误的十个迹象" 列举了一些带有" 坏气味" 的常见论证示例，这些气味在尚未找到具体逻辑缺陷之前就能被察觉。并非所有错误都同样致命；某些错误甚至可能具有一定的积极价值，例如在尚无法完整验证之前就揭示出一种有前景的方法 [16]。

一种有利" 气味" 的组成部分，正如 Thurston [17] 所指出的[6]，是论证提供理解或洞见的感觉；它不仅表明某组假设在逻辑上蕴含某个给定结论，还提供了这种蕴含何以可能的因果叙事，以及论证的哪些部

[4]此处我们对数学究竟是什么这一概念保持模糊。可以采用规范主义（prescriptivist）的观点，例如采用 Davis–Hersh 的定义 [12]，将数学定义为" 对具有可复现性质的心智对象的研究"。也可以采用描述主义（descriptivist）的观点，即数学是数学家在实践中实际从事的活动。我们此处的讨论在某种程度上倾向于后一种观点。

[5]我们使用这一感官隐喻，类比于软件工程中" 代码异味（code smell）" 的概念。

[6]另见第二作者的文章 [18]，该文认为" 好的" 数学，无论最初如何定义，在实践中往往趋向于融入更广泛的数学叙事，例如结构与随机性之间的二元对立，或代数探索几何问题（反之亦然）的能力。

分承担了”重头戏”，哪些部分相对于先前文献是新颖或令人惊奇的，哪些部分是常规的技术考量。这类对数学文本的诠释和印象通常并不被严格数学的官方框架所捕捉，例如一阶逻辑或集合论；但它们对于允许阅读论证的人类数学家从中汲取更广泛的教训至关重要——这些教训涉及人们期望论证如何推广到其他情境，或如何与文献中的其他方法相互作用。这类叙事结构也有助于增强对论证稳健性的信心；计算中的一个符号错误可能使一个冗长的数学论证失效，但如果证明对如何系统地隔离和解决论证中的关键困难有清晰的策略，并与文献中先前成功论证形成类比，那么论证中的局部错误就更有可能在忠实于原始证明精神的前提下得到修复。

4.3. **形式化来拯救?.** 有几项发展可能迫使数学界重新评估这种半形式化的证明标准。其中一项是技术性质的：随着数学日趋成熟和复杂（以及越来越多地借助计算机），论证变得越来越长、越来越复杂，某些领域的前沿论文常规上超过一百页，使得人类审稿人逐行核查愈发繁重。在实践中，这意味着这种仔细的核查并不总是得以执行，除了最引人注目和最重要的结果之外，导致人们越来越多地（过度）依赖前述的”气味”来评估数学论证的可信度。

这类问题似乎有可能通过技术手段得到解决（或至少得到改善），特别是通过更广泛地部署形式化证明助手（formal proof assistant）（例如 Lean 或 Rocq），只要数学论证以某种精确的计算机语言书写，这些助手就能自动核查其有效性 [19]。目前此类形式化仍然过于繁琐，难以系统地推广（将传统的非正式书写证明转换为此类形式化语言，通常比最初撰写该证明花费多五到十倍的时间），但目前正在进行大量努力以使该过程更快速、更易用，例如通过整合人工智能工具来实现部分（甚至可能完整的）自动形式化（autoformalization）[20]。

4.4. **形式化验证的局限性.** 但即便此类技术问题得以解决，数学证明也能够常规地获得正确性的形式化验证，仍会出现若干新问题，尤其是在不久的将来，越来越复杂的论证可能部分或完全由人工智能工具生成。首先，形式化验证只能证明一个形式化论证建立了一个形式化数学命题，但并不能排除形式化命题与原始意图命题之间翻译中的错误。例如，Fermat 大定理（Fermat's last theorem）断言，对于任何大于 2 的自然数 n，方程 $a^n + b^n = c^n$ 没有自然数解 a, b, c；但这一非正式描述中隐含着自然数从 1 而非 0 开始的约定。一个被要求解决这个问题的人工智能可能会错误地假设允许 a, b, c 为零，并据此产生一个（经过正式认证的）证明，证明 Fermat 大定理是错误的！因此，尽管形式化原则上可以显著减少对非正式数学文本进行仔细人工审查的需要，但并不能完全消除这种需要[7]。

其次，即使在纯粹抽象的高等数学领域，给定论证中也只有一部分可以用适合形式化的演绎逻辑来表述。虽然演绎证明仍然是大多数数

[7]从理论上讲，甚至可能通过巧妙地篡改标准形式化数学库（如 Mathlib）中关键定义的形式化来”攻击”数学本身；见 [21]。具有讽刺意味的是，数学研究日益协作、社会化和大规模化，虽然总体上是一个非常积极的发展，但也可能增加对此类攻击的潜在脆弱性，而这在以前数学主要由小群体个人完成的时代并不是一个值得重视的问题。

学工作的核心，但围绕这一核心存在一圈启发式的、经验性的或元数学（metamathematical）的推理，这些推理提供了关于论证为何有效、是否可以推广到其他情境、追求这些问题的动机是什么，以及如何从更基本的原理重构论证的有价值信息。人类撰写的证明，就其本质而言，往往会在写作过程中自然地提供这种”外围”（尤其是当作者善于阐释时）；但若一个人工智能被专门训练为以形式正确性为标准、以牺牲所有其他考量为代价，则可能产生”无气味”的证明——这些证明表面上类似于写得很好的人类证明，甚至可以通过形式化验证测试，却依然令人感到奇怪的不满足——在字面上完成了建立某一数学命题的明确目标，却在该命题所属的更广泛数学领域上产生的洞见远少于预期。在一个所有媒体都经过人工智能润色至光鲜亮丽的世界里，包括排版精美、由 GPT 生成的清晰解释的数学证明，是否在放弃那个更粗糙、更杂乱的手写（或至少是手打）文字的世界时失去了什么？

4.5. **对早期挑战的适应.** 数学界已经适应了以前对其证明标准的技术挑战。大型计算机辅助证明，例如四色定理的证明 [22] 或 Kepler 猜想的证明 [23]，最初颇具争议，因为用手工完整核查是不切实际的；但随着时间推移，针对这类论证建立了新的建立信心的标准，例如提供可复现的代码、将论证的计算部分隔离在特定的、清晰陈述的引理中（与论文更具概念性的部分分开），以及提供额外的相关数据和”校验和”以检查计算机生成的计算是否与各种”合理性检查”一致。实际上，这些发展使数学中的证明标准朝着自然科学的方向转变，在自然科学中，理论论证和经验实验，若经过适当的设计、执行和报告，都是可接受的科学真理来源。

4.6. **人工智能辅助数学的演变.** 随着重要的人工智能辅助或人工智能生成数学的出现，类似的演变也将发生[8]。产生经过验证的演绎证明的负担可能越来越多地落到计算机而非人类身上，证明的结构也将越来越多地被重组[9]，使得以前被精心安排为可被人工验证的繁琐计算越来越多地外包给软件工具。例如，数学中臭名昭著的说法，如”证明留给读者”或”由标准论证可得”，将被替换为调用一个大语言模型（LLM），后者为此类声明产生既人类可读又计算机可验证的理由。随着自动形式化的进步，探究给定论证相对于数学基础的特定选择如何变化也将变得更加容易，从而使得一个结果的元数学[10]能够与数学结果本身同时得到严格讨论和探索。

与此同时，人类数学家在未来可能会将更多的关注和精力放在数学推理的”软”方面，例如追求某一结果或为该结果选择证明策略的启

[8]我们的思考受到其他数学家在这一话题上的观点的影响，包括 [24]、[25]、[16]、[26]，以及 [27]、[28] 中更广泛的讨论。

[9]关于此类重组的若干具体示例以及这些发展的进一步探讨，见 [29]。

[10]此类元数学的一个例子是定理的逆向数学（reverse mathematics）（见，例如，[30]），它旨在理解建立给定结果实际需要哪些数学公理（例如，选择公理，或排中律）。传统上，一个结果的逆向数学只在该结果原始证明多年之后才被探讨，并且需要逻辑学的专业训练以及定理所在数学子领域的领域专业知识。

发式方法和动机、支持（或反对）该结果的经验证据[11]，或者导致发现有效论证的试错过程。这些方面不像演绎证明那样容易被自动验证和度量，因此不那么容易适用于[12]强化学习等机器学习策略。可以设想，职业数学家可能越来越多地采用[13]其他学科的论证模式，例如理论和实验科学甚至人文学科，用额外的推理类型来支撑其核心演绎论证，例如对实验数据的统计分析，或由已确认的数学结果和非严格的哲学原则共同指导的思辨性理论化。历史上[14]，数学家们不愿意过多偏离严格演绎证明的" 金标准"，部分原因在于当人们不再遵守这些标准时可能产生的大量可见的低质量数学的示例[15]；但在未来一个证明可以被自动生成和以高度可信赖方式验证的时代，可能会有更多机会安全地探索此类更广泛的数学推理和讨论模式。

这些新技术也可能以重大的负面方式影响数学的长期目标。在教育层面，我们已经看到许多学生几乎立即诉诸现代人工智能工具来完成其指定的课程作业，以牺牲培养更具可持续性的数学技能和直觉为代价，实现了为给定问题产生可验证答案的即时目标；类似地，在研究层面，数据驱动数学的" 第四范式（fourth paradigm）" [33] 理论上可能非常成功，以至于挤出更传统的经验证据、理论推理和计算数值（后者是当前纯数学的主导范式）等范式，以及人类数学家[16]从视觉、动觉和其他感官直觉中获得的巨大价值，或从我们对物理学、经济学、生物学等规律的熟悉程度中获得的直觉价值。即使假设形式方法得到完全可信赖的实施，对数学研究领域人工智能辅助的不加批判的接受，也可能导致一场涌现出大量[17]大量人工智能生成论文的不良结果，这

[11]特别是，鉴于人工智能越来越强的" 猜测" 甚至极其复杂数学问题答案的能力——而这种猜测并不类似于正式证明——将越来越有必要为在数学文献中以负责任的方式引用和纳入此类未经验证的猜测制定标准程序。

[12]自动化数学研究过程这些方面的另一个障碍是数据相对匮乏；已发表的文献往往侧重于成功的结果证明，而对导致这些证明的（通常相当丰富和细致的）过程（无论是正式的还是非正式的）缺乏详述。

[13]特别地，人们可以设想未来数学研究中劳动分工将日益增加：虽然所有数学家都应当对提出、建立和诠释数学结果的不同阶段保持广泛的熟悉，但任何给定的数学家可能越来越多地专注于这一过程的几个方面，例如专注于利用人工智能助手按照研究小组某位更资深成员的指示来证明结果，或者利用人类数学家和人工智能助手共同产生的最新文献来提出新的研究方向。

[14]例如，Jaffe 和 Quinn [31] 早先提出的系统发展" 理论数学" 领域的建议，受到了职业数学家的普遍负面反应，引发了多篇反驳文章，包括前述 Thurston [17] 的文章。

[15]Kim [32] 援引一个货币隐喻来描述社会动态：职业数学家需要通过证明困难的新数学结果来积累一定的信誉" 货币"，然后才能" 花费" 这些货币从事思辨性活动，例如提出猜想或对结果的更广泛意义进行哲学思考。

[16]与此有些相关的是，数学论证的" 美丽" 或" 优雅" 等审美概念，可能变得比目前更加脱离此类论证的形式正确性。例如，考虑 AlphaProof [34] 为 2024 年国际数学奥林匹克（International Mathematical Olympiad）的问题生成的证明，其中包含大量冗余或难以解释的步骤，但仍被正式验证为正确解答。另见 [25] 中的讨论。

[17]这可以被视为意外后果法则的一个例证。在过去数学时代，获得严格数学证明的任务需要艰辛的人类努力，数学活动自然地聚焦于被数学界认为有价值的问题，即便对于一个给定结果究竟" 有趣" 或" 相关" 意味着什么这一哲学问题，大多数社区成员往往没有明确考虑过；文献的演变足够缓慢，使得这种主要依赖社会机制来确定数学重要性的方式能够随时间自我修正。在未来一个由于自动化数学结果可以

些论文包含技术上正确且新颖的结果，但对更广泛的数学叙事没有贡献，也无法为作者或读者建立直觉。此类低质量工作产生的负面印象可能导致对人工智能辅助在数学中最为审慎和负责任的应用也产生污名，这反过来可能阻碍此类技术的潜在积极效益，例如前文提及的以更广泛和整体的方式探索数学的能力。

4.7. **将哲学问题应用于现实世界的人工智能使用.** 任何作为其他研究基础性参考的内容都承载着额外的责任，数学也不例外。我们可以正式证明任何人工智能生成数学论证的有效性；但有效性只是价值的一个组成部分，在现实情境中呈现人工智能驱动的研究时，需要进行细致的价值判断。研究者认为哪些可能数量庞大的平凡和非平凡发现特别有趣、值得在研究领域内外分享，以及该材料如何呈现给更广泛的受众，目前在人类研究者中尚无统一标准。在如何分配优先权和功劳方面也存在不确定性。人工智能辅助研究还带来了新的伦理和法律影响，以及关于人工智能生成内容（包括证明）知识产权的尚未解答的问题。

哪些原则应该指导研究者决定一个或另一个人工智能模型的适用性和最佳应用，或者人工智能是否根本是一个好的选择？在学术领域，假设大多数走上学术研究道路的人是出于希望让世界变得更美好并为之作出有意义贡献的愿望，这并不是不合理的。数学家们会希望优先考虑那些对数学最有益的用例。所有领域的研究者都会经常希望不仅优先考虑那些有益于其自身领域的用途，也考虑具有跨学科效益的用途。可以认定，大多数将人工智能用于研究目的的人，都会希望优先考虑有益于人类而非有害于人类的用途。因此，在人工智能开发领域内，有必要突出谁在从这些工具中受益以及正在产生何种效益，以帮助人们识别如何尽可能负责任地优化结果。

4.8. **知识产权与责任.** 知识产权与责任（或者也许说，问责制）问题本身就是一个雷区，需要仔细讨论。当人工智能被应用于一个问题时，谁对错误负责？谁获得洞见的功劳？这些可能不是同一方，也可能不是被明确定义的各方。迄今为止，大型语言模型（LLM）训练数据的大量积累，已被其开发者主张为属于”合理使用（Fair Use）”原则。在美国，”合理使用”的应用具有一定灵活性，取决于（除其他因素外）知识产权使用的目的 [37]。作为一个思想实验，我们可以考虑是否更大的收益值得更大的使用 [38]。在旨在从迫在眉睫的末日中拯救世界的情况下，声称有权使用所有已记录的知识是否合理？如果是为了拯救世界免受更遥远的生存威胁（例如，气候变化），如此宽泛的应用是否仍然适用？如果”只是”终结所有疾病呢？或者仅仅是消灭癌症呢？由于所有这些都是人工智能的假定有益应用，那么允许人工智能使用所有已记录的信息来实现此类奇迹是否合理？

除了对”合理使用”极为宽泛解释这一有问题的论点之外，迫切需要清晰的功劳分配标准和引用协议。人工智能使用案例不仅将依赖研究者的数据，还将依赖人工智能此前接受训练所用的信息、选择哪些

以显著更快速度批量产生的时代，这类哲学问题可能需要更积极的关注。另见 [35]、[36] 关于在决定是否关注一个声称的数学结果时需要作出价值判断（包括对作者可信度的判断）的讨论。

信息对人工智能进行训练的决策（由可能与主要研究者没有任何互动的软件工程师和设计师作出），以及当然还有人工智能本身的贡献。传统学术引用系统是否足以在可能有数百或数千个”隐藏”贡献者的情况下分配适当的功劳，还是仅仅引用人工智能模型本身就足够了？在研究论文中未披露地使用人工智能完成大部分写作引发了特别强烈的反应，许多学者将此类做法视为等同于剽窃；具有讽刺意味的是，这导致一些从其工具中获益的研究者将其使用进一步隐藏起来。显然，需要制定新的有关人工智能披露和使用的职业标准与规范[18]。

人工智能也处于创造可能广泛存在的循环引用循环的边缘，Randall Munroe[19] 在 2001 年幽默地将这一过程称为”引用发生（citogenesis）”。例如，继近期人工智能”深度研究”工具 [40] 在发掘隐藏于晦涩文献中的开放问题解答方面取得成功之后，第二作者协助在一个数学开放问题网站 [41] 上发起了一项工作，系统地使用这些工具来报告这些问题的已知文献，或此类文献的缺失情况。虽然这为网站增添了真正的价值，但我们也发现，深度研究工具将这些报告用作其搜索的权威来源，产生了意想不到的后果：在网站上汇总这些搜索结果，妨碍了任何后续使用这些工具来发现此类问题上真正新文献的努力！因此，即使在没有恶意意图的情况下，这些工具日益增长的能力也要求对所引用信息的来源进行更为彻底的审查。

5. 人工智能的代价与收益

5.1. **经济与社会影响：谁是受益者?**. 鉴于人工智能已对个体产生显著影响，且其发展速度极为迅猛，不难设想一条轨迹：人工智能不断扩张，最终演变为威胁全人类的生存性危机。每向前迈进一步，开发者及其他具有影响力的人士都需审慎权衡：哪些人从这些进展中获益，哪些人又因此受损。我们主张，任何进一步的发展都应将全人类的整体利益放在首位，人工智能应用应始终对人类个体或集体直接有用。

对于每一个具体应用场景，都应开展评估，明确说明预期受益对象是谁。这一具体的人工智能模型或其实现，究竟是惠及整个社会，还是仅为少数人带来切实利益（如节约成本）？人工智能工具的能力之强、复杂程度之高，使得极少数人以数百万人的代价换取暴利，这种结局在道德上令人无法接受。我们必须推动人工智能的落地实施，使之将人的尊严置于商品化之上。

资本凌驾于人类福祉之上所酿成的灾难，我们无需远求。十九世纪初，诺丁汉纺织工人自称”勒德分子（Luddites）”，他们并非无端反对技术与进步，而是对自动化将他们从岗位上驱逐、以更低技能、更低薪酬的工人取而代之的现实予以激烈抵制。在失业率高企、通货膨胀肆虐的严峻经济形势下，工作岗位的即时威胁已构成对其生计的生存性威胁。尽管我们如今回望工业革命时期的自动化，大体上视之为社会的整体进步，但这些进步伴随着真实可量化的人类代价。

如今，与勒德分子（Luddites）所处的时代不同，我们目睹的不是技术工人被更低薪酬的人力所取代，而是被人工智能所取代。入门级岗

[18]关于此话题，见其中一位作者的初步讨论 [39]。

[19]`https://xkcd.com/978`

位历来是新一代劳动者实现经济与社会跃升的通道，而当这些岗位消失殆尽，机会也随之烟消云散。绝望与怨恨积聚为愤怒与激愤，人们开始将自己置于与那些曾被寄予改善生活质量厚望的工具的对立面。

所有新兴技术都为人类整体带来一定裨益，同时也附带真实的人类代价。对于人工智能这样颠覆性极强的技术而言，其人类代价必须在地方层面和全球层面加以量化，并与其收益仔细权衡。我们目前用于这一评估的指标仍然模糊、界定不清。我们是否继续沿用既有方式，审视货币层面的得失？是否应该将获得资源的机会增加与资源的损失进行对比权衡？是否考量更难以量化的生活质量与幸福感，若然，又如何将这些无形因素与更可量化的收益进行比较？

当前的商业生态不幸地在追逐一种Wunderwaffe（奇迹武器），被优化为追求最大功率和最广泛影响，寄望于以此跑赢一切潜在问题。但若无法量化新兴技术的人类代价，则是为了少数人的利益而对全体人类造成极大的损害。此外，当前人工智能在几乎所有社会领域同步推进、却不顾是否为终端用户带来任何实质性益处的态势，只会让各行各业的人们产生疏离感与挫败感。我们已经看到，将技术强加于个体而不征得其同意所引发的自然反应——感到失控之后，人们的第一反应是拒绝一切人工智能技术，哪怕是以丢掉”孩子”（那些能为其生活带来可量化益处的人工智能用途）来换取”洗澡水”的代价。若我们能转而将技术的第一要务聚焦于切实改善大多数乃至全体人类的生活，我们自我毁灭的可能性就会大大低于仅以机械劳动、数字劳动和人类劳动的商品化为唯一目标的情形。

5.2. **盘点人工智能的代价**. 除了直接的人类代价之外，人工智能的任何合乎伦理的实施都无法绕开那些更为隐性和不透明的成本。开发并构建有效人工智能基础设施最实质性、最显而易见的代价，在于这些技术与二十世纪七十年代的计算革命时代那些技术截然不同——它们无法作为爱好或家庭手工业来发展。不存在某个装满电脑零件的车库，让 Steve Jobs 这样的独立创新者凭一己之力建立起一个帝国。迄今为止已建成的人工智能模型，在抵达一个可用的人工智能之前——更遑论盈利——就需要在硬件、服务器、人才和预训练上投入巨额资金。

与人工智能发展所需规模更为贴切的类比，或许是十九世纪下半叶在美国修建的横贯大陆铁路网。建造铁路的公司必须先研发并打造一批庞大的机车车队，规划并铺设数千英里的轨道，才能让第一列火车将货物从爱荷华州快速可靠地运抵旧金山，兑现这些公司所押注的经济回报。

人工智能技术巨大的前期投入，促使开发者追逐利润驱动的资本主义模式，催生出一批新兴技术精英——他们调动天文数字的投资资本与债务，策略性地争夺和把持土地、能源、水资源、高技能劳动力等有限资源，正如十九世纪镀金时代的强盗大亨们所为。与那个时代如出一辙，这些巨额投资已造成了经济稳定性、技术获取渠道以及整个发达世界普遍生活质量方面的巨大不平等。

我们的社会已开始正视大规模人工智能所带来的显著环境代价。高能耗与高耗水量，对那些生活在这些人工智能模型所需大型设施周边的人们造成了严峻的日常挑战。已有观点可信地指出（参见 [42]），人

工智能生成的解决方案可用于缓解或消除两个世纪人类技术使用所带来的沉重气候代价。随着基础设施的完善及更高效计算方式的开发，运营这些工具的边际成本或许会随时间推移而下降。然而，迄今为止，尚无大型人工智能模型能够提出一种方案，甚至连抵消自身资源消耗和废物排放都做不到。

此外值得关注的是，现代人工智能工具并非通过在物理世界中的表现或对客观现实物理规律的理解来追求或直觉把握”真理”；相反，这些模型在很大程度上依赖于人类生成的数据（通常不注明出处），以及大量的人类反馈来迭代优化自身。若要使模型降低对人类智力劳动的依赖性，就面临着以人工智能生成的信息污染我们集体知识体系的严重风险。在某一领域中，人工智能被用来生成”新信息”的量，在人工智能崩塌（AI collapse）[43] 成为严重问题之前，存在明确的上限。若缺乏足够数量的真实内容，人工智能便会脱离现实，陷入一种与真实世界毫无关联的思维模式，并极大地妨碍人类与人工智能界面处有意义的交互。数学凭借其形式化验证过程，或许对人工智能污染有更高的容忍度；但正如我们所见，它也并非对这一危险完全免疫。

5.3. **数字鸿沟.** 另一个值得关注的重大社会代价，是人工智能技术可能加剧现有不平等或催生新的不平等。原则上，所有人都具备运用自身天赋智力的能力（当然，前提是具备充分的教育机会和良好的成长环境）；但前沿人工智能模型应用的趋势已然表明，大规模人工智能工具或许只对资金雄厚或人脉广博的研究团体，或对那些最愿意交出个人数据、对此类模型的伦理问题视而不见的个体可用。这在人工智能的”拥有者”与”未拥有者”之间制造了根本性的”数字鸿沟（digital divide）”。

在人工智能有能力从根本上提升研究绩效的当下，优先保障公平获取至关重要；然而在当前的人工智能格局中，第二种、更为微妙的数字鸿沟正在浮现。当主流人工智能模型被资本化、私有化，并相互竞争有限资源（投资和用户基础）时，它们（或许并非出于本意地）被激励去发展”尖峰型”能力以维持竞争优势，而非在不同领域提供稳定均衡的性能。随着个体因机构谈判和市场约束而被锁定在某一模型上，我们必须考虑这样一种风险：某一模型在特定研究领域可能比另一模型更具实质性优势，从而在已能便捷稳定获取人工智能资源的子群体内部，再次制造分化。

另一方面，人工智能模型在科学与人文研究中的诸多益处，并不一定需要最先进的模型。较小的”本地模型（local models）”，以及诸如证明辅助器等非大型语言模型（LLM）技术，已展现出比那些需要大型数据中心处理全体人类知识的模型更快、更高效地返回有意义结果的能力。将现有大型模型提炼为更小模型，以针对特定研究领域精心定制的训练库为基础，利用最先进的人工智能能力，具有相当大的潜力。或许，由用户社区共同维护的多样化小型专项模型，能够作为现有极为庞大昂贵模型的可行替代方案而兴起。加大对此类社区项目的支持力度，有助于缓解获取机会不平等的问题。

尽管其中许多小型项目可以通过小规模公私机构可行地开发和运营，但业界从业者和政策制定者已呼吁采取监管行动，以建立和维护

对人工智能技术的公平获取 [44]。作为这一努力的一部分，投资建立国家级或多国联合的面向公众的先进人工智能研究联盟，以及开发大型公共资助、公众可及的人工智能资源（或模型）[45]，将具有显著优势，能够切实帮助那些在当前以私有化、企业化模型主导的领域中处于边缘地位的个体和群体获得人工智能的便利。

5.4. **减少危害.** 在航空的早期，飞机旅行是一种极不安全的技术，事故频发，惨烈无比。而今，它已成为长途出行中最安全、最可靠的交通方式。人工智能同样有可能在短期内引发灾难性后果，要使其走上类似的发展轨迹（希望有更少的致命事故），就需要采取果断行动以减少危害。必须制定最佳实践 [46]，并设计培训和监管机制，以推进技术的最负责任的使用，同时阻止或禁止隐蔽或有害的使用方式。

这是一根极难穿针的细线。一方面，谨慎负责地使用人工智能辅助的个体，在短期内可能被那些不那么谨慎的竞争对手超越——后者正利用更快速但可靠性更低的人工智能实践来加速自身工作。与此同时，此类个体即便只是敢于考虑将这项技术纳入自身职业工作流程，也可能遭到不信任人工智能的同行的嘲讽、谴责乃至排斥。当前这种基本上laissez faire（放任自流）的方式，任由人工智能技术不受约束地发展，似乎并不有利于如此细致、负责任的采用方式得以盛行。

可供借鉴的先例存在。Wikipedia 在二十一世纪初的迅速崛起最初给教育系统带来了一定冲击，许多学生开始将这一在线资源的文字verbatim（原封不动地）照搬进作业，许多教师的反应则是直接禁止使用该百科资源。批评 Wikipedia 不可靠、存在潜在偏见的声音甚嚣尘上。然而，随着该网站的成熟，以及学术界对其优劣势日益熟悉，一种大致的共识逐渐形成，即如何将这一资源融入教育与研究。将 Wikipedia 作为探索某一主题的起点，逐渐被鼓励，或至少被默许；学生被要求深入查阅网站提供的二手资料，或对照独立信息源加以核实，而非直接引用其文字。时至今日，Wikipedia 已在学术界被广泛接受为一种有用的资源。

我们能否在人工智能方面达到类似程度的负责任接受？我们谨慎地保持乐观，认为这是可能的；但这需要持续的努力和清晰的哲学引领。例如，我们认为，人工智能工具应被开发为造福全体（或至少大多数）人类，而非少数特权者，这是一种道德与伦理上的命令；它必须为真实的人类需求创造解决方案，并尽可能为更多人提升生活质量与体验；这些工具的实际或潜在危害必须得到认识，与其收益进行权衡，并在可能的情况下加以缓解。承认这些目标在实践中很多都难以实现，并不需要过度的悲观；但就我们希望这些工具与之对齐的价值体系展开辩论，是使实际达成这些目标成为可能的第一步。

随着这些价值观（希望）逐渐形成某种共识，并配合上述减轻人工智能最坏影响的行动，注意力必须转向最大的摩擦源——人工智能与人类之间的界面。要超越那种不安而脆弱的休战状态，我们需要开发方法，让个体能够将人工智能工具融入日常生活，并使这一过程感觉令人满意、充满活力，而非强制压迫。随着人工智能的持续发展与演变，人类对人工智能的使用、交互乃至最终关系，也需要随之演变——从便利工具，到辅助伙伴，再到协同合作者。

6. 人类与人工智能的界面

6.1. **近期视角：人工智能作为智识生产的”香草精”.** 我们应如何概念化人类与人工智能工具之间的界面？在当下这一刻，仍可合理地将这些技术主要视为新奇事物，许多用户也不确定如何合理地加以运用。

我们就如何驾驭这一当前过渡期提出的建议，是以一个烹饪比喻来类比：香草精，几乎所有甜味食谱中的常见配料，因其几乎令所有人都感到愉悦的芳香而著称。单独饮用时，香草精通常被认为极为难喝，但少量加入后则被普遍认为能提升并增强菜肴中其他风味，即便人们无法将其从中分辨出来。虽然很容易得出”香草精越多越好”的结论，但大多数使用过它的人都明白，存在某个上限，一旦超过，整道菜就会彻底毁掉[20]。我们大多数人并不清楚那个上限究竟在哪里，因此发现保持极少量添加最为明智。

同样地，可以将当前的人工智能使用视为认知工作流中的一种可选添加：在适度范围内进行实验是有趣的——将一段人类撰写的文字传递给人工智能语言模型以获取语法和措辞建议，或将一份要点列表交给人工智能整理成建议的结构。这些轻触，如同少许香草精，将在不喧宾夺主的情况下提升并丰富作品的特质。然而，若将人工智能生成的内容作为此类工作流的核心组成部分，则不会产生令人满意、有效或有价值的成果。秉持这样的理念（并适当注明人工智能使用情况），无需立即重新审视人类在数学、科学或创意艺术等智识活动中角色的根本假设。

6.2. **中期视角：人工智能担任”红队”.** 然而，随着这些工具能力的提升和更广泛的采用，”选择退出”此类技术的能力将会减弱。即便某人主动选择不使用人工智能辅助，其同事、学生以及所在专业机构也将越来越多地将人工智能融入自身工作。目前已有严重担忧，整个学术话语领域可能被汹涌的低质量人工智能生成内容所淹没。在近期，这可以通过严格的编辑政策来应对，禁止大多数形式的人工智能生成内容；但随着这些工具日益普及，个性化人工智能代理网络愈加普遍，就需要一种更为细致入微的方法。

在中期至少，仍有可能也有必要制定规则和指南，以识别更负责任的人工智能使用方式，阻止不负责任的使用，同时不从根本上改变某一领域以人为本的性质——简言之，将人工智能辅助视为人本工作的工具或初级合作伙伴，而非替代品。在这种情况下，在[21]”蓝队”任务（生成新内容和结构）与”红队”任务（验证、测试或维护这些内容）之间做出区分，将大有裨益。人工智能在”红队”角色中相对安全，可用于审查人类生成的内容以查找错误或提出改进建议；但鉴于当前及近期工具的随机性不可靠性和缺乏落地性，在任何超出”红队”（可由人类或更自动化的验证工具（如形式化证明辅助器）组成）验证能力的”蓝队”结构性职能上信任它们是不安全的。这一理念的重点在于

[20]Tumblr 上一个广为人知的思想实验 [47] 得出结论：含 44% 香草精的蛋糕将无法入口。

[21]这一术语的灵感来自网络安全领域的区分：防御系统免受攻击的”蓝队”，与探测系统弱点的”红队”。

管控人工智能使用的潜在风险，同时仍能获取其诸多潜在收益，而非从根本上重新思考该领域的本质。

6.3. **长期视角：哲学上的退守是否不可避免?.** 但假设放眼一个更遥远的未来，届时人工智能工具当前的弱点已得到令人满意的解决，其能力在所有实际维度上均已达到或超越[22]专家人类的水平，使得风险管理哲学趋于过时。届时，我们将如何回应此类先进技术变革性本质所引发的复杂哲学问题?

一种选择，是简单地退守到那些此类问题不再适用的纯技术框架中。在数学中，我们有" 形式主义（formalist）" 视角，其唯一目标是按照精确规则操纵数学符号。在科学中，务实的" 闭嘴去算（shut up and calculate）" 哲学立场扮演着类似角色；在创意艺术中，人可以作为一个工匠而非艺术家来工作，创作满足外部客户所提参数的作品，而不对产品的价值作任何判断。在这些情形中，只要任务的技术规格得到满足，无需在人类生成的工作与人工智能生成的工作之间做出任何区分。

然而，尽管技术无疑是上述每个学科的重要组成部分，但它并不能捕捉到数学、科学和艺术在实践中被实际开展的完整体验，也对诸如如何激励下一代学生、或应追求哪些方向的好奇心驱动研究等实际问题提供甚少指引。因此，有人可能会转而退守到一种截然不同的立场——将人类智识或人类创造力赋予某种不可言喻的特殊地位，从根本上将行使这些人类禀赋的活动，与对这类活动的任何人工复制永久地区别开来，无论后者在技术层面能以多高的精度复制或超越前者。在这一框架下，人工智能将永远是" 非真正的苏格兰人（No True Scotsman）": 缺乏真正的" 灵魂" 或" 理解"。凭借着对我们自身物种的长期熟悉，我们习惯于人类的不可靠性、能力的" 尖峰性"，以及有时凭借随机词语联想和死记硬背侥幸完成任务；但当人工智能工具表现出类似行为时，人们往往倾向于对其评判更为严苛，例如将此类缺陷归因于其作为" 随机鹦鹉（stochastic parrots）" 的固有本性。

但或许这种立场不过是在否认一个令人不安的真相：我们引以为豪的部分人类能力，其本质上并不比我们如今设计来模拟它们的人工智能算法复杂多少。随着人工智能性能的持续提升，这种人类沙文主义的观点有沦为愈发难以为继的" 间隙之神（god of the gaps）" 哲学的风险——其中，一份不断缩短的品质清单被标榜为人工智能尚无法复制的人类本质成就的标志。

第三种选择，尤其受到某些技术狂热者的青睐，即认为所有人类认知能力将很快被其人工智能等价物完全超越，使得关于人类贡献及其对数学、科学和艺术的关切之价值的哲学讨论愈发变得无关紧要。在这一立场的极端版本中，人类智识活动的行使本身被视为一种不受欢迎的、枯燥乏味的活动，应尽快被自动化所取代，以便腾出时间和心理空间用于更为悠闲或享乐主义的追求。显然，这一哲学的实施将带来诸多风险，例如人类能力退化到我们这一物种集体上将无法监控、

[22]这一场景有时被称为" 通用人工智能（Artificial General Intelligence）"，尽管对这一术语的精确定义尚无共识。

控制乃至理解那些我们已将文明委以重托、日益强大的人工智能的行动[23]。

然而，在这些”稻草人”式的极端立场之间，似乎存在着某种哲学上的中间地带，它能够为人类与人工智能代理之间正在涌现的合作与互补共存新范式提供有益视角。其中一个先例可以在国际象棋的世界中找到——国际象棋曾被视为纯粹人类智识的典范活动。如今，距任何人类棋手都无法胜过一台国际象棋引擎已有数十年之久。尽管如此，国际象棋依然是一项流行且蓬勃发展的人类活动，棋手们将引擎纳入训练，用其重审旧的棋局理论并探索新的理论，探寻看似无懈可击的人工智能棋手的漏洞与弱点，或创造性地引入涉及不同程度人工智能辅助的新竞争形式。关于国际象棋究竟是什么，以及下棋的价值何在，这些哲学问题继续值得追问；而目前被普遍接受的答案，与上述三种极端立场中的任何一种都相去甚远。

6.4. **哥白尼式（Copernican）视角.** 一种可能性，是拥抱天文学中哥白尼（Copernican）革命在认知领域的类比。在古代，占主导地位的宇宙论模型（就宇宙以机械论方式被理解而言）是地心说，地球作为宇宙中静止不动的中心享有特殊的本体论地位，其性质与其上方的苍穹或其下方的地下世界根本不同。然而，天文学与物理学的多项进展逐步瓦解了这一观点，历经数百年相继证明：地球实际上在绕轴自转，并在公转轨道上绕太阳运行，太阳本身又绕着银河系中心运转，而银河系又是一个缺乏任何空间中心概念的膨胀宇宙的一部分。事实上，采纳一种完全相反的哲学立场被证明极富成效，这一立场如今被称为哥白尼原理（Copernican principle）：地球不过是宇宙中无数行星之一，完全不受自然基本规律的任何优待。

乍看之下，这一观点似乎对人类对家园星球的情感依附构成威胁，但归根结底，宇宙对地球的漠然，与我们自身对它的深厚投入之间，并不存在根本性矛盾；我们仍可完全合理地将地球特有的问题置于其他星球的问题之上，同时接受其他星球的存在，以及它们对自身居民具有可比的重要性。类似的革命在其他科学的历史发展中也可见到，例如达尔文（Darwinian）革命，它推翻了人类在不断演化的物种中独特地位的神话；又如欧氏几何在数学中作为综合先验真理来源的特权地位的消解。

直至近代，我们这一物种同样秉持着地心说的智识类比，将人类智能置于认知宇宙的中心，从而赋予其特殊的哲学地位。而今，我们正在发现（或创造）其他在许多方面与我们的智能相当、同时在许多方面又截然不同的智能”行星”。与其否认这些”行星”的存在或重要性，或争论哪颗”行星”应当成为”中心”，不如接受人类智能与人工智能同属于一个本体论范畴，尽管彼此之间存在许多显著差异与互补性。尽管我们的兴趣与依附仍将主要系于人类智识领域，但它与其他智能形式的关系可以被探索，这既出于更高效地实现各种现实目标的实际目的，也出于更为哲学性的原因，例如获得一种此前难以企及的、对人类认知的外部视角。

[23]关于这一框架在实践中的景象，我们推荐科幻电影Wall-E [48]。

7. 结论

人工智能技术以无序、混乱且广泛铺开的方式进入世界，已经在社会、智识和经济领域引发了深刻的变革，其令人警醒之处与其有益之处并行不悖。尽管无可置疑，人类需要某种集体行动——无论是通过监管、市场压力，还是某种尚未明确的力量——但我们显然尚未到达一个无法从这些新技术的高昂经济与社会代价中抽身的临界点。将人工智能融入数学领域的各种探索同样迅速地展示了人工智能能够为学术研究、科学进步乃至全人类带来的可观裨益。数学研究本质上客观、可验证，为实验这些新技术并研究其影响提供了独特机会，且不会给个人或更广泛的社会带来伦理或生存风险。从人工智能在数学中的应用出发，我们得以探讨更广泛的全球性人工智能使用中那些迫切的哲学与道德问题。进而，我们可以推断出缓解人工智能与人类界面张力的潜在路径，并提出人工智能与人类协同思维的新范式——这些范式尊重双方各自带到" 共同桌前" 的独特而宝贵的品质。尽管我们永远无法将精灵重新塞回瓶子，但我们乐观地认为，随着我们的理解与行动迅速推进，我们终将能够拨云见日，展望一个光明而又充满不确定性的未来。

7.1. **致谢.** 我们感谢 Silvia de Toffoli 提供了宝贵的意见和参考文献。

References

[1] J. Jumper, R. Evans, A. Pritzel, et al., "Highly accurate protein structure prediction with AlphaFold," Nature, vol. 596, pp. 583–589, Aug. 2021.
[2] S. Marche, "The College Essay Is Dead," Dec. 2022.
[3] D. Anguiano and L. Beckett, "How Hollywood writers triumphed over AI – and why it matters," The Guardian, Oct. 2023.
[4] E. Oh, W. Kearns, M. Laine, G. Demiris, and H. J. Thompson, "Perceptions of and Experiences with Consumer Sleep Technologies That Use Artificial Intelligence," Sensors, vol. 22, p. 3621, Jan. 2022.
[5] F. Swain, "Is it right to use Nazi research if it can save lives?." https://www.bbc.com/future/article/20190723-the-ethics-of-using-nazi-science.
[6] A. Tarkowski, "Open source and the democritization of AI," in Artificial Intelligence and the Challenge for Global Governance: Nine Essays on Achieving Responsible AI (A. Krasodomski, ed.), pp. 30–36, Royal Institute of International Affairs, June 2024.
[7] J. Chun and K. Elkins, "The Crisis of Artificial Intelligence: A New Digital Humanities Curriculum for Human-Centred AI," International Journal of Humanities and Arts Computing, vol. 17, pp. 147–167, Oct. 2023.
[8] J. R. Searle, "Minds, brains, and programs," Behavioral and Brain Sciences, vol. 3, pp. 417–424, Sept. 1980.
[9] Q. Mei, Y. Xie, W. Yuan, and M. O. Jackson, "A Turing test of whether AI chatbots are behaviorally similar to humans," Proceedings of the National Academy of Sciences, vol. 121, p. e2313925121, Feb. 2024.
[10] H. Chen, S. R. Grimm, O. Russakovsky, and T. Lombrozo, "Machine understanding." Unpublished preprint.
[11] M. Mashaal, Bourbaki: A Secret Society of Mathematicians. Providence, RI: American Mathematical Society, 2006.
[12] The mathematical experience. Boston: Birkhäuser, 1981.

[13] R. Wagner, "Mathematical consensus: A research program," Axiomathes, vol. 32, pp. 1185–1204, Dec. 2022.
[14] J. Baez, "The Inconsistency of Arithmetic." https://golem.ph.utexas.edu/category/2011/09/the_inconsistency_of_arithmeti.html.
[15] S. Aaronson, "Ten Signs a Claimed Mathematical Breakthrough is Wrong," Jan. 2008.
[16] S. DeDeo, "AlephZero and mathematical experience," Bulletin of the American Mathematical Society, vol. 61, pp. 375–386, July 2024.
[17] W. P. Thurston, "On Proof and Progress in Mathematics," in 18 Unconventional Essays on the Nature of Mathematics (R. Hersh, ed.), pp. 37–55, New York, NY: Springer, 2006.
[18] T. Tao, "What is good mathematics?," Bulletin of the American Mathematical Society, vol. 44, no. 4, pp. 623–634, 2007.
[19] S. de Toffoli and F. Tanswell, "The technological turn in mathematics," Blackwell Companion to the Philosophy of Mathematics, 2025.
[20] Y. Wu, A. Q. Jiang, W. Li, M. Rabe, C. Staats, M. Jamnik, and C. Szegedy, "Autoformalization with Large Language Models," Advances in Neural Information Processing Systems, vol. 35, pp. 32353–32368, Dec. 2022.
[21] F. Tanswell, "Can Mathematics Be Hacked? Infrastructure, Artificial Intelligence, and the...," June 2025.
[22] K. I. Appel and W. Haken, Every Planar Map Is Four Colorable, vol. 98. American Mathematical Soc., 1989.
[23] T. C. Hales, "A Proof of the Kepler Conjecture," Annals of Mathematics, vol. 162, no. 3, pp. 1065–1185, 2005.
[24] A. Venkatesh, "Some thoughts on automation and mathematical research," Bulletin of the American Mathematical Society, vol. 61, pp. 203–210, Feb. 2024.
[25] S. DeDeo, "Hard Proofs and Good Reasons," Oct. 2024.
[26] J. Avigad, "Is mathematics obsolete?," 2025.
[27] "Special issue on AI and mathematics, Part I," Bulletin of the American Mathematical Society, vol. 61, pp. 199–372, Apr. 2024.
[28] "Special issue on AI and mathematics, Part II," Bulletin of the American Mathematical Society, vol. 61, pp. 373–524, July 2024.
[29] H. Macbeth, "Algorithm and abstraction in formal mathematics," May 2024.
[30] J. Stillwell, Reverse Mathematics: Proofs from the inside Out. Princeton, New Jersey: Princeton University Press, 2018.
[31] A. Jaffe and F. Quinn, ""Theoretical mathematics": Toward a cultural synthesis of mathematics and theoretical physics," Bulletin of the American Mathematical Society, vol. 29, no. 1, pp. 1–13, 1993.
[32] M. Kim, "Thinking and explaining." MathOverflow. https://mathoverflow.net/q/38694 (version: 2024-01-05).
[33] T. Hey, "The Fourth Paradigm – Data-Intensive Scientific Discovery," in E-Science and Information Management (S. Kurbanoğlu, U. Al, P. L. Erdoğan, Y. Tonta, and N. Uçak, eds.), vol. 317, pp. 1–1, Berlin, Heidelberg: Springer Berlin Heidelberg, 2012.
[34] "AI achieves silver-medal standard solving International Mathematical Olympiad problems." https://deepmind.google/blog/ai-solves-imo-problems-at-silver-medal-level/, May 2024.
[35] C. J. Rittberg, "Justified epistemic exclusions in mathematics," Philosophia Mathematica, vol. 31, pp. 330–359, 04 2023.
[36] S. De Toffoli and F. S. Tanswell, "Trust in mathematics," Philosophia Mathematica, pp. 1–25, 2025. Published online ahead of print.

[37] "Copyright and Fair Use | Office of the General Counsel." https://ogc.harvard.edu/pages/copyright-and-fair-use.
[38] A. Weir, "Chapter 11," in Project Hail Mary, Penguin Books (Series), pp. 191–194, London: Penguin Books, 2022.
[39] "Best practices for incorporating AI etc. in papers." https://ai-math.zulipchat.com/.
[40] S. Bubeck, C. Coester, R. Eldan, T. Gowers, Y. T. Lee, A. Lupsasca, M. Sawhney, R. Scherrer, M. Sellke, B. K. Spears, D. Unutmaz, K. Weil, S. Yin, and N. Zhivotovskiy, "Early science acceleration experiments with GPT-5," Nov. 2025.
[41] T. F. Bloom, "Erdős Problems." https://www.erdosproblems.com/.
[42] J. Cowls, A. Tsamados, M. Taddeo, and L. Floridi, "The AI gambit: Leveraging artificial intelligence to combat climate change—opportunities, challenges, and recommendations," AI & SOCIETY, vol. 38, pp. 283–307, Feb. 2023.
[43] I. Shumailov, Z. Shumaylov, Y. Zhao, N. Papernot, R. Anderson, and Y. Gal, "AI models collapse when trained on recursively generated data," Nature, vol. 631, pp. 755–759, July 2024.
[44] "Supercharging Research: Harnessing Artificial Intelligence to Meet Global Challenges | PCAST," tech. rep., President's Council of Advisors on Science and Technology, June 2024.
[45] E. Jones, "A 'CERN for AI' - what might an international AI research organization address?," in Artificial Intelligence and the Challenge for Global Governance: Nine Essays on Achieving Responsible AI (A. Krasodomski, ed.), pp. 10–17, Chatham House, the Royal Institute of International Affairs, June 2024.
[46] M. Mantegna, "An ethics framework for the AI-generated future," in Artificial Intelligence and the Challenge for Global Governance: Nine Essays on Achieving Responsible AI (A. Krasodomski, ed.), pp. 47–57, Royal Institute of International Affairs, June 2024.
[47] "Vanilla Extract." https://knowyourmeme.com/memes/vanilla-extract, Feb. 2023.
[48] "WALL-E," 2008.