基于世界模型增强的带动作纠正的网页智能体

Zhouzhou Shen [*1] Xueyu Hu [*1] Xiyun Li [2] Tianqing Fang [2] Juncheng Li [1] Shengyu Zhang [1]

Abstract

基于大语言模型（LLM）的网页智能体（Web Agent）在自动化网页任务方面展现出了令人期待的能力。然而，当前的网页智能体由于预测环境变化的局限性，难以推理出合理的动作，并且可能缺乏对执行风险的全面认知，过早执行有风险的动作导致损失和任务失败。为了应对这些挑战，我们提出了 WAC，一种集成了模型协作、结果模拟和反馈驱动动作优化的网页智能体。为了克服单个模型的认知孤立，我们引入了多智能体协作（Multi-Agent Collaboration）流程，使动作模型（Action Model）能够咨询作为网页环境专家的世界模型（World Model）以获取策略指导；然后动作模型将这些建议转化为可执行动作，利用环境状态转换动态的先验知识来增强候选动作生成。为了实现风险感知的弹性任务执行，我们引入了两阶段推演链（Deduction Chain）。专门针对环境状态转换的世界模型模拟动作结果，随后由评判模型（Judge Model）进行审查，在必要时触发动作纠正反馈。实验表明，WAC 在 VisualWebArena 上取得了 1.8% 的绝对提升，在 Online-Mind2Web 上取得了 1.3% 的绝对提升。

1. 引言

大语言模型（LLM）凭借强大的理解和生成能力，已成为流行智能应用的基础，包括用于网页任务自动化的网页智能体 (Shi et al., 2017; Kim et al., 2023)。一些工作，如 ReAct (Yao et al., 2023)，尝试构建一种网页智能体推理与执行交替进行的范式。该范式依赖单个模型来执行推理、提出动作并执行动作，已在某些基于网页的任务上取得了初步成功。

尽管取得了这些进展，网页智能体在 VisualWebArena (Koh et al., 2024a) 等具有挑战性的基准测试上的任务成功率仍然大幅低于人类，如 Figure 1所示。实证评估表明，依赖单个模型的网页智能体经常出现系统性的推理局限，可能执行不当动作，导致任务轨迹出现不可逆的偏差。

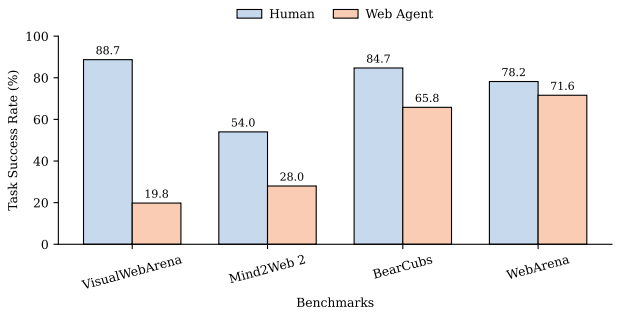

Figure 1. 人类和网页智能体在代表性网页基准测试上的任务成功率。尽管近期取得了进展，最先进的网页智能体仍然大幅落后于人类。

受现有网页智能体局限性的启发，我们识别出两个阻碍其在复杂网页环境中表现的关键挑战。**（C1）单模型决策的认知局限**。大多数现有的网页智能体依赖单个模型来同时感知环境、推理任务进展和生成可执行动作。然而，单个模型的知识覆盖范围和推理能力本质上是有限的。智能体可能无法在决策过程中充分利用互补的专业知识或替代视角，往往导致推理不足和次优的动作提案。这些局限性会随时间导致错误累积，进而显著降低网页任务的整体成功率。**（C2）缺乏显式的执行前风险感知和纠正**。当前的网页智能体通常在动作被提出后即选择并执行，而不显式评估其潜在后果或相关风险。虽然一些近期方法引入了结果模拟来估计动作效果，但它们通常缺乏在执行前拒绝或修正不当动作的机制。当所有候选动作都不令人满意时，智能体仍被迫执行其中一个，这可能导致任务轨迹出现不可逆的偏差。

为了应对这些挑战，我们引入了 WAC，即 **W**orld-model–augmented **A**ction **C**orrection（基于世界模型增强的动作纠正），一种为协作式动作生成和风险感知的执行前动作优化而设计的网页智能体。为了解决 C1，我们为 WAC 配备了支持两个专业模型之间协作推理的多智能体协作流程。具体而言，拥有丰富网页环境状态转换知识的世界模型作为环境专家，为单步规划提供策略指导。然后动作模型将此指导与自身观察结合，进行审议并生成可执行的动作提案。此外，为了避免过度协作带来的不必要开销，我们引入了按需协作（Collaboration-on-Demand）策略。协作基于置信

[*]Equal contribution [1]Zhejiang University [2]Tencent AI Lab. Correspondence to: Shengyu Zhang <sy_zhang@zju.edu.cn>.

Preprint. April 7, 2026.

度分数选择性触发，允许智能体仅在需要时调用多智能体推理，从而提高效率和动作提案质量。为了解决 C2，我们设计了以世界模型为中心的推演链，用于执行前风险评估和闭环动作纠正。C1 中描述的同一世界模型在此以不同角色被重用：它模拟候选动作的潜在结果，以在执行前评估其效果和相关风险。基于这些模拟结果，我们引入了闭环反馈机制，评估候选动作的可行性，并在提出的动作被认为不当时提供即时纠正信号。收到此类反馈后，智能体重新发起动作提案和推演，允许在执行前迭代优化决策。

我们在两个广泛使用的基准测试上评估了 WAC ，即 VisualWebArena 和 Online-Mind2Web (Deng et al., 2023; Xue et al., 2025)，它们涵盖了多样的网页环境和复杂任务。在两个基准测试上，WAC 一致优于先前最先进的决策工作流，分别取得了 24.5% 和 16.0% 的成功率。此外，消融研究和针对性分析表明，协作流程和推演链分别有效地解决了 C1 和 C2 对应的挑战。

总结而言，我们的贡献有三方面：

- 我们提出了一种新颖的网页智能体框架，集成了协作式动作生成和以世界模型为中心的动作推演。通过支持按需模型协作和反馈驱动的闭环动作优化机制，我们的方法有效缓解了单个模型的认知孤立（C1），并减少了对风险或不对齐动作的过早执行（C2）。
- 我们在 VisualWebArena 和 Online-Mind2Web 上进行了广泛的实验，证明我们的方法一致优于强基线。特别是，WAC 在 VisualWebArena 上取得了 1.8% 的绝对提升，在 Online-Mind2Web 上取得了 1.3% 的绝对提升，验证了其在增强基于网页的任务中动作生成和优化方面的有效性。
- 我们提供了全面的分析，包括消融研究、跨模型泛化和定性案例研究，以更好地理解智能体的行为。这些分析揭示了协作式动作生成和反馈驱动的优化如何有助于提高鲁棒性。

2. 相关工作

2.1. 基于 LLM 的网页智能体

基于 LLM 的网页智能体近期发展迅速。早期工作如 RCI (Kim et al., 2023)、WebAgent (Gur et al., 2024) 和 WebGUM (Furuta et al., 2024) 展示了语言模型解决基于网页任务的潜力。SeeAct (Zheng et al., 2024)、TRISHUL (Singh et al., 2025) 和 WEPO (Liu et al., 2025) 分别通过利用多模态视觉-语义对齐、丰富的 GUI 表示和基于距离的偏好优化来进一步提升动作定位。在推理和规划方面，先前的工作探索了步骤级演示检索 (Zhou et al., 2024a)、工作流记忆 (Wang et al., 2024b)、动态任务分解 (Yang et al., 2025b)、子任务中心的基准测试 (Srivastava et al., 2025) 和推理时树搜索 (Koh et al., 2024b) 来增强网页智能体中的多步决策。为了衡量网页智能体的进展，WebArena (Zhou et al., 2024b)、VisualWebArena (Koh et al., 2024a) 和 Online-Mind2Web (Deng et al., 2023; Xue et al., 2025) 等工作建立了真实且全面的评估流水线。这些进展不断增强网页智能体的理解和决策能力。

2.2. 网页智能体中的世界模型

世界模型(World Model)最初旨在学习环境动态的预测模型，使智能体能够高效地理解环境如何运作，而无需完全依赖真实世界的交互 (Sutton, 1991; Ha & Schmidhuber, 2018)。因此，世界模型常用于样本高效学习 (Wu et al., 2022; Jeong et al., 2025; Gao et al., 2025)。在网页智能体方面，WMA web agent (Chae et al., 2025) 和 WebDreamer (Gu et al., 2025) 引入世界模型来模拟动作执行以改善动作选择。WebEvolver (Fang et al., 2025) 引入了一种协同进化框架，其中世界模型 LLM 与智能体策略共同发展。R-WoM (Mei et al., 2025) 通过知识检索增强基于 LLM 的世界模型模拟，解决幻觉和过时训练知识的问题。我们的 WAC 除了使用基于 LLM 的世界模型来模拟环境动态外，还进一步利用其状态转换知识来指导候选计划的生成。

3. WAC

3.1. 问题形式化

由于底层网页状态的部分可观测性、网页交互的随机性以及网页任务的长序列序贯决策特性，我们将网页智能体任务执行建模为部分可观测马尔可夫决策过程 (POMDP)，形式化定义为 $(\mathcal{S}, \mathcal{A}, \mathcal{O}, \mathcal{T}, \mathcal{Z})$，其中我们关注部分可观测性下的决策和执行，而非奖励优化。在时间步 t，环境处于隐状态 $s_t \in \mathcal{S}$，智能体无法直接访问。智能体接收观测 $o_t \in \mathcal{O}$ 并选择动作 $a_t \in \mathcal{A}$。环境随后转换到新的隐状态 $s_{t+1} \sim \mathcal{T}(\cdot \mid s_t, a_t)$，从中生成下一个观测 $o_{t+1} \sim \mathcal{Z}(\cdot \mid s_{t+1})$。一个回合在以下情况之一终止：智能体显式决定停止，或由于执行错误、过多重复动作或达到最大步数限制而被动终止。

3.2. 框架概览

我们提出 WAC ，一种多智能体网页智能体框架，旨在支持协作式动作生成和风险感知的执行前动作优化。与依赖单个模型同时进行推理和动作的先前 ReAct 风格 (Yao et al., 2023) 智能体不同，WAC 将决策分解为具有专门模型角色的互补阶段。如 Figure 2所示，WAC 由两个顺序阶段组成：**动作生成**和**动作推演**。

在**阶段一（动作生成）**中，智能体基于当前网页观测生成一组候选动作。为了缓解单个模型的有限推理能力，动作模型可以与世界模型协作，后者作为环境专家为动作提案提供策略指导。当智能体缺乏足够的置信度仅基于动作模型生成可靠动作时，按需触发此协作。

在**阶段二（动作推演）**中，智能体在执行前评估候选动作，并基于模拟执行结果进行反馈驱动的优化。世界

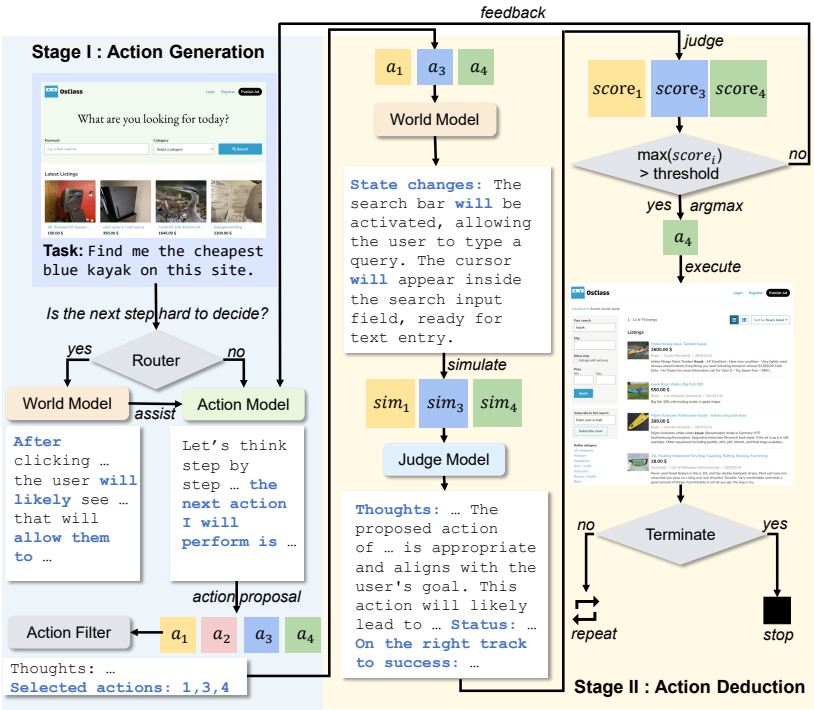

Figure 2. WAC 概览。给定当前观测和任务，智能体首先决定动作生成是否需要世界模型的辅助。然后提出候选动作并进行轻量级过滤。每个候选动作由世界模型模拟以预测潜在的状态变化，由评判模型评估并分配置信度分数。如果没有动作超过预定义阈值，则利用低分模拟得到的反馈在闭环中优化动作提案。一旦识别出高置信度动作，就在环境中执行，过程重复直到终止。

模型模拟所提出动作的潜在结果，然后由评判模型评估以提供执行前动作优化的反馈。当所有候选动作都被认为不当或有风险时，纠正反馈被返回到动作生成过程，允许在执行前进行迭代优化。

算法 1总结了 WAC 的整体工作流，展示了协作式动作生成和反馈驱动的动作优化如何在跨执行步骤的统一决策循环中集成。

3.3. 动作生成

现有的网页智能体（如 ReAct）通常依赖单个模型来同时推理任务和提出可执行动作。在这种情况下，模型的内部知识和推理能力可能不足以捕获环境动态（如导航规则、状态依赖），从而产生不当的动作提案。近期的多智能体工作赋予多个专业智能体互补的知识和协调机制，为上述问题提出了一种有前景的解决方案。受此启发，我们设计动作生成阶段，通过三个步骤生成紧凑的、环境感知的候选动作集 $\mathcal{A}_t$：（1）与世界模型的按需协作以提供高层指导，（2）初始动作提案，和（3）轻量级动作过滤。

在网页任务执行的每个步骤 t，基于 LLM 的门控模块根据当前环境观测 o_t 和用户指定的任务 τ 来确定——下一个动作决策是否应该在拥有丰富网页环境状态转换知识的世界模型的辅助下增强。形式化地，我们将步骤 t 的门控决策记为

$$g_t = \textsc{Router}(o_t, \tau) \in \{0, 1\}, \tag{1}$$

其中 $g_t = 1$ 表示调用世界模型指导。如果是，世界模型——以 o_t、τ 和过去动作与网页截图的交叉执行轨迹 $\mathcal{H}_t$ 为条件——进行前瞻推理并输出自然语言的、可操作的下一步建议 s_t。随后，动作模型以任务 τ、当前观测 o_t、执行历史 $\mathcal{H}_t$ 和建议 s_t（如果可用）为条件，产生自己的推理过程和结构化的动作决策。在概率解码下，动作模型被多次采样以产生一组候选动作 $\tilde{\mathcal{A}}_t = \{a_t^{(1)}, \ldots, a_t^{(N)}\}$。按照先前工作 (Gu et al., 2025; Chae et al., 2025)，我们使用 LLM 对 $\tilde{\mathcal{A}}_t$ 执行轻量级过滤以移除明显不合理的候选动作，得到 $\mathcal{A}_t$。

利用基于 LLM 的世界模型来指导动作提案，将决策空间缩小到与可用功能对齐的动作，并将转换知识直接注入推理过程。这减少了不当提案并在模糊的执行步骤中提高了目标导向性。

3.4. 动作推演

为了评估候选动作的风险，近期工作 (Gu et al., 2025; Chae et al., 2025) 不是直接对其评分，而是利用世界模型模拟其潜在结果并基于这些模拟选择动作。然而，当没有候选动作是合适的时候，智能体仍被迫执行其中一个，这可能导致不可逆的后果或任务轨迹中难以

Algorithm 1 WAC 工作流

输入： 任务 τ，初始观测 o_0
输出： 执行的动作序列 $\{a_0, a_1, \ldots, a_T\}$
初始化执行历史 $\mathcal{H}_0 \leftarrow \emptyset$，$t \leftarrow 0$
while termination_check() = False **do**
  // 阶段一：动作生成
  $g_t \leftarrow \textsc{Router}(o_t, \tau)$
  if $g_t = 1$ **then**
    $s_t \leftarrow \mathcal{W}_{\text{guide}}(o_t, \tau, \mathcal{H}_t)$
  else
    $s_t \leftarrow \varnothing$
  end if
  $\tilde{\mathcal{A}}_t \leftarrow \textsc{ActionModel}(o_t, \tau, \mathcal{H}_t, s_t)$
  $\mathcal{A}_t \leftarrow \textsc{ActionFilter}(\tilde{\mathcal{A}}_t)$
  // 阶段二：动作推演
  初始化优化计数器 $k \leftarrow 0$
  repeat
    for all $a_t^{(i)} \in \mathcal{A}_t$ **do**
      $\widehat{o}_{t+1}^{(i)} \leftarrow \mathcal{W}_{\text{sim}}(o_t, a_t^{(i)})$
      $(c^{(i)}, r^{(i)}) \leftarrow \textsc{Judge}(\widehat{o}_{t+1}^{(i)}, \tau, \mathcal{H}_t)$
    end for
    if $\max_i c^{(i)} \geq \theta$ **then**
      $a_t^\star \leftarrow \arg\max_i c^{(i)}$
      break
    end if
    $\mathcal{G}_t \leftarrow \{(a_t^{(i)}, r^{(i)}) \mid c^{(i)} < \theta\}$
    $\mathcal{A}_t \leftarrow \textsc{Refine}(\mathcal{A}_t, \mathcal{G}_t)$
    $k \leftarrow k + 1$
  until $k = K_{\max}$
  if $\max_i c^{(i)} < \theta$ **then**
    $a_t^\star \leftarrow \arg\max_i c^{(i)}$
  end if
  $o_{t+1} \leftarrow \textsc{Execute}(a_t^\star)$
  $\mathcal{H}_{t+1} \leftarrow \mathcal{H}_t \cup \{(o_t, a_t^\star)\}$
  $t \leftarrow t + 1$
end while

被现有智能体恢复的偏差。鉴于当前网页智能体的任务成功率仍然大幅低于人类，这种情况在实践中频繁发生。为了克服这个问题，我们提出了基于模拟执行结果的反馈驱动动作优化循环。

在时间步 t，动作生成阶段在当前观测 o_t 下产生一组候选动作 $\mathcal{A}_t = \{a_t^{(1)}, \ldots, a_t^{(M)}\}$。为了在执行前评估每个候选动作的潜在风险和有效性，我们使用世界模型 $\mathcal{W}$ 来模拟执行结果。对于每个动作 $a_t^{(i)} \in \mathcal{A}_t$，世界模型预测一个假设的下一个观测：

$$\widehat{o}_{t+1}^{(i)} = \mathcal{W}(o_t, a_t^{(i)}), \tag{2}$$

其中 $\widehat{o}_{t+1}^{(i)}$ 是模拟执行后状态的自然语言描述。按照 WebDreamer (Gu et al., 2025)，我们将世界模型模拟视野设为 1。

模拟结果随后由评判模型评估，该模型检查每个 $\widehat{o}_{t+1}^{(i)}$ 以产生：(i) 离散置信度分数 $c^{(i)} \in \{0, 0.5, 1\}$，表示该动作被判断为失败、部分完成还是成功完成任务；以及 (ii) 文本理由 $r^{(i)}$ 解释该评估。为了稳定性和一致性，置信度分数通过量化评判模型对一组预定义离散问题的回答获得，而非直接生成。我们将评判模型记为对每个模拟结果产生置信度-理由对 $(c^{(i)}, r^{(i)})$ 的函数。

如果 $\max_i c^{(i)} \geq \theta$，其中 θ 是预定义的置信度阈值，智能体执行最高分动作 $a_t^{(i^\star)}$，其中 $i^\star = \arg\max_i c^{(i)}$。否则，当所有候选动作都被评估为低置信度时，我们激活反馈驱动的动作优化循环。

具体而言，我们将不当的候选动作与其对应的理由配对以形成纠正指导，作为额外上下文反馈给动作模型。形式化地，我们将低置信度动作及其理由汇总为

$$\mathcal{G}_t = \{(a_t^{(i)}, r^{(i)}) \mid c^{(i)} < \theta\}, \tag{3}$$

作为动作重新生成的纠正指导。动作模型随后在这些约束下重新生成优化后的候选集。为了在保留先前迭代中相对较强的候选的同时纳入新生成的动作，我们应用一个合并历史和新提出动作的算子，并为下一次迭代选择紧凑的子集。形式化地，令 $\mathcal{A}_t^{\text{new}}$ 表示动作模型新生成的候选动作，令 $\mathcal{A}_t^{\text{prev}}$ 表示先前迭代中保留的动作集。我们定义算子为：

$$\text{Top}_N(\mathcal{A}_t^{\text{prev}}) \cup \mathcal{A}_t^{\text{new}}, \tag{4}$$

其中 $\text{Top}_N(\cdot)$ 选择评判模型分配的置信度分数最高的 N 个动作。此设计防止优化循环完全丢弃先前的动作，同时通过纠正反馈逐步改善候选集。此过程以提案 → 模拟 → 评估的闭环迭代，在高置信度动作出现或达到最大优化迭代次数时终止。为了效率，我们将优化循环限制在 $K_{\max}$ 次迭代。如果循环因迭代限制而终止，则选择所有先前评估的候选中置信度分数最高的动作执行。

通过防止过早执行与意图不对齐或不合理的动作，并在行动前暴露纠正信号，此反馈机制提高了鲁棒性并减少了复杂网页任务中的错误累积。

4. 实验

4.1. 实验设置

我们在两个广泛使用的网页智能体基准测试上评估 WAC：VisualWebArena (Koh et al., 2024a) 和 Online-Mind2Web (Deng et al., 2023; Xue et al., 2025)。

VisualWebArena 是一个面向多模态网页智能体的真实基准测试，其任务要求除了 DOM 和文本信息外还需解读截图。该基准通过在沙箱环境中的功能性网站上执行来评估。它由三个子网站组成：Classifieds、Shopping 和 Reddit。性能通过成功率衡量，定义为根据数据集评估规则成功完成的任务比例。为了减少评估成本并保持与先前工作的一致性，我们在从数据集中选出的 233 个人工验证任务上进行评估。

Online-Mind2Web 是 Mind2Web 的在线变体，包含跨 136 个流行真实网站的 300 个任务，旨在直接在实时网页上评估智能体。Mind2Web 提供原始的大规模任务集和模式。该基准采用 LLM 作为评判的评估流水线来判断任务成功，与人类判断达到 85% 的一致率。性能通过成功率衡量，定义为被判定为成功的任务比例。

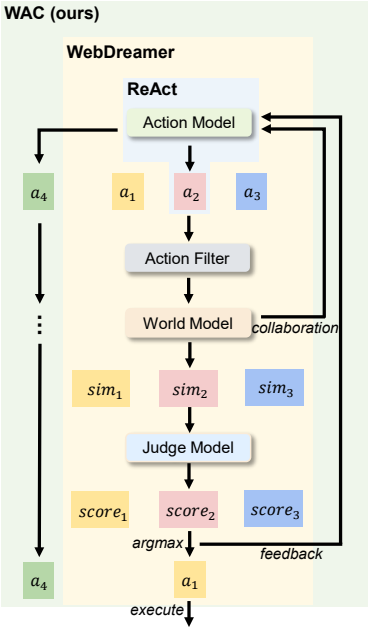

Figure 3. ReAct、WebDreamer 和我们的方法（WAC）使用的动作生成和执行前决策过程的比较。ReAct 直接执行单个提出的动作，WebDreamer 在模拟的候选中选择，而 WAC 在执行前支持协作式动作生成和反馈驱动的动作优化，从而实现更鲁棒的动作选择。

为确保公平比较并验证 WAC 的有效性，我们采用 ReAct (Yao et al., 2023) 和 WebDreamer (Gu et al., 2025) 作为基线方法，并在所选基准上重新实现它们。我们包含了决策行为的视觉比较来阐明这些方法在动作选择期间的差异，这并非旨在引入 Section 3中描述之外的新组件。Figure 3提供了这些方法使用的动作生成和执行前决策过程的高层比较，突出了驱动我们实验评估的关键行为差异。**ReAct** 是一个强大的推理-动作基线，交替进行自然语言推理和动作执行，使智能体能够基于观测逐步做出决策。**WebDreamer** 通过引入世界模型来模拟候选动作在执行前的结果，允许智能体在网页环境中进行前瞻推理，从而扩展了这一范式。相比之下，WAC 进一步支持协作式动作生成和反馈驱动的优化，允许在执行前纠正次优动作。

我们使用 VisualWebArena 提供的工具包实现所有智能体，以支持与网页环境的交互。为了确保与先前工作的公平比较，我们忠实地按照原始实现复现了 ReAct 和 WebDreamer 基线。所有智能体使用相同的视觉-语言模型 Qwen-VL-Plus (Bai et al., 2025a;b; Wang et al., 2024a; Bai et al., 2023) 实例化，所有实验中解码温度固定为 1。为了与先前设置保持一致，我们将世界模型的模拟视野设为 1，这已被经验证明既有效又高效。

4.2. 主要结果

Table 1报告了在相同骨干模型（Qwen3-VL-plus）下各方法在 VisualWebArena 和 Online-Mind2Web 上的任务成功率。我们的方法 WAC 在两个基准测试上均优于 ReAct 和 WebDreamer。在 VisualWebArena 上，WAC 达到 24.5%（对比 ReAct 和 WebDreamer 的 22.7%），相对两个基线提升了 7.9%。在 Online-Mind2Web 上，WAC 达到 16.0%，相对 WebDreamer 提升了 8.8%。

这些结果表明，将协作式动作生成（整合来自多个模型的互补建议）与基于模拟结果的反馈驱动执行前动作优化相结合，一致地提高了多样化网页场景中的决策质量和执行鲁棒性。两个基准上的一致改进证明了我们方法在基于网页的决策中的有效性，在这种场景下，不当动作可能导致难以恢复的状态，因此需要谨慎的动作生成以及显式的执行前动作验证和优化。

4.3. 消融研究

Table 2. VisualWebArena Classifieds 上的消融研究。

模型	方法	SR↑
Qwen3-VL-Plus	ReAct	30.4
	WebDreamer	32.1
	+ 反馈驱动动作优化	33.9
	+ 协作式动作生成	**35.7**

为了评估反馈驱动动作优化和协作式动作生成对智能体性能的影响，我们在 VisualWebArena 的人工验证 Classifieds 子集上进行了全面实验，如 Table 2所示。我们报告了 ReAct、WebDreamer 以及在 WebDreamer 上增加我们提出模块的 56 个 Classifieds 子集任务上的任务成功率。我们观察到，随着我们提出的模块逐步纳入智能体，任务成功率一致提升。在任务执行期间，反馈驱动动作优化帮助在执行前纠正不合理或与意图不对齐的动作，而协作式动作生成通过整合来自世界模型的环境感知指导来增强动作提案。这些组件共同带来了 3.6% 的任务成功率绝对提升，证明了我们方法的有效性。

Table 1. VisualWebArena 和 Online-Mind2Web 上的结果。

模型	方法	VisualWebArena	Online-Mind2Web
Qwen3-VL-Plus	ReAct	22.7	12.7
	WebDreamer	22.7	14.7
	WAC （本文）	**24.5**	**16.0**

4.4. 进一步分析

Table 3. VisualWebArena Classifieds 上的跨模型泛化结果。

模型	方法	SR↑
GLM-4.5v	ReAct	21.4
	WebDreamer	33.9
	WAC （本文）	**37.5**

跨模型泛化 为了评估我们的方法是否能泛化到先前实验中使用的基础模型之外，我们通过将底层基础模型替换为 GLM-4.5v (Team et al., 2025)，在 VisualWebArena 的 Classifieds 子集上进行了跨模型评估。所有方法在相同的环境和任务设置下评估以确保公平比较。如 Table 3所示，在 GLM-4.5v 骨干下，WAC 一致优于基线，取得了 37.5 的任务成功率，而 WebDreamer 为 33.9，ReAct 为 21.4。这一性能差距表明 WAC 的收益并非与特定基础模型紧密耦合，而是源自所提出的协作式动作生成和反馈驱动动作优化机制，突显了其在模型可用性和特性可能变化的实际网页智能体系统中的潜在适用性。

Table 4. VisualWebArena Reddit 上的跨模型泛化结果。

模型	方法	SR↑
GLM-4.6v	ReAct	7.9
	WebDreamer	12.7
	WAC （本文）	**14.3**

我们进一步使用最新发布的 GLM-4.6v 骨干在 VisualWebArena Reddit 子集上评估跨模型泛化。Reddit 任务被广泛认为更具挑战性，因为其密集的页面布局、大量信息和多步交互需求导致现有网页智能体的整体成功率较低。如 Table 4所示，WAC 取得了 14.3 的任务成功率，明显优于 WebDreamer (12.7) 和 ReAct (7.9)。综合来看，这些结果表明我们的方法不仅能跨不同基础模型泛化，而且在更具挑战性的网页场景中也保持有效，在这些场景中谨慎的动作提案和执行前动作验证尤为重要。

Table 5. WAC 单提案变体在 VisualWebArena Classifieds 上的性能。

模型	方法	SR↑
Qwen3-VL-Plus	WAC	**35.7**
	WAC （单提案）	**35.7**

反馈能否替代动作采样？ 现有的网页智能体通常依赖重复提示和随机解码来获得多样化的候选动作集。虽然有效，但这种策略带来了大量的计算开销，并将动作多样性视为采样的副产品而非结构化优化。相比之下，WAC 引入了基于模拟执行结果迭代纠正不当动作的反馈驱动优化循环。这种设计引出了一个自然的问题：反馈机制能否补偿减少的动作采样？我们对这个问题进行了初步探索。具体而言，我们使用从动作模型采样的单个动作初始化 $\mathcal{A}_t$，并仅依赖反馈驱动的优化循环来迭代改进提案。如 Table 5所示，尽管仅使用单个初始动作提案，该变体保持了有竞争力的性能，表明反馈驱动的优化可能部分替代显式的动作采样。这一结果突显了反馈驱动优化作为大量动作采样的更结构化和高效替代方案的潜力，特别是在延迟或成本敏感的设置中。

有效案例展示 我们展示了一个案例研究，说明 WAC 如何通过反馈驱动的动作优化在任务执行的第一步纠正不当动作。为了清晰起见，我们在图中省略了协作式动作生成过程，聚焦于优化动态；在此案例中，世界模型在初始步骤不提供额外指导，动作直接由动作模型提出。给定任务和初始观测，动作模型在步骤 $t = 1$ 时仅产生单个候选动作。WAC 不直接执行此动作，而是利用环境感知的世界模型来模拟其潜在结果。模拟的执行后状态揭示，该动作会导致智能体走上与任务目标不一致的不良轨迹。基于此模拟结果，评判模型提供了指出潜在问题的理由。以此反馈为条件，动作模型修正其提案并生成一个更好地符合任务要求和页面结构的替代动作。执行此修正动作使智能体走上正确的执行轨迹，从此任务可以成功完成。此案例突显，即使动作多样性最小且初始没有可用的替代候选，所提出的反馈驱动优化循环仍能有效介入。通过在执行前识别和纠正有缺陷的动作，WAC 防止了可能在后续步骤中传播且难以恢复的早期阶段错误。

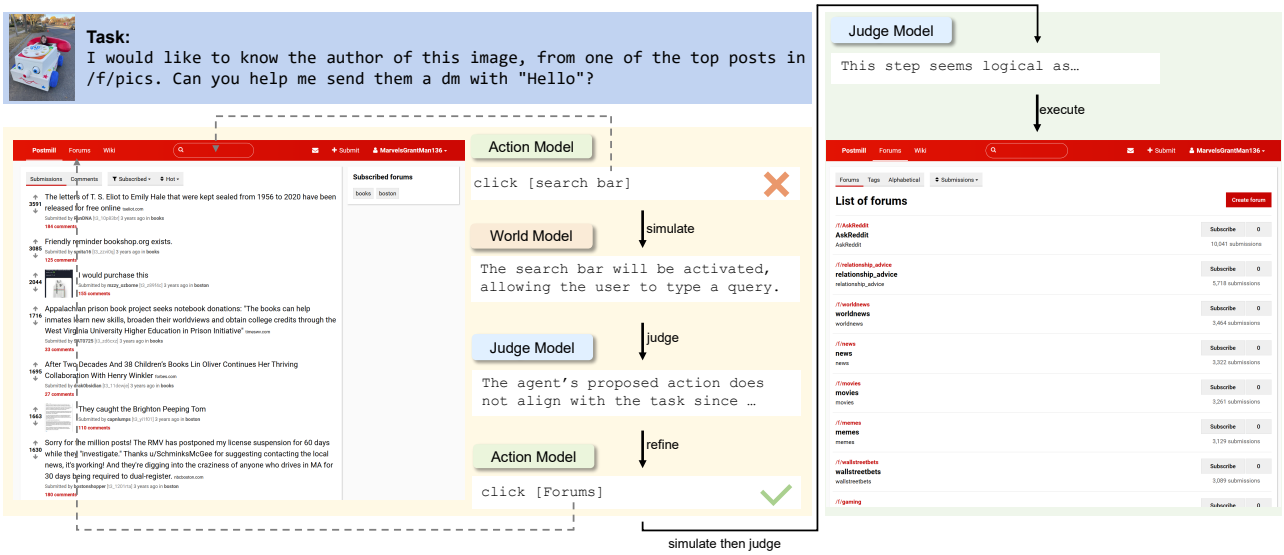

Figure 4. 一个说明性案例，展示反馈驱动的动作优化如何在第一个执行步骤纠正初始提出的动作。尽管最初只生成了单个候选动作，模拟结果评估识别出其风险，触发优化并产生了一个使智能体走上成功轨迹的修正动作。

5. 局限性

尽管 WAC 取得了有前景的结果，它仍然存在若干局限性：（1）我们的方法以免调优方式运行，因此继承了底层基础模型的局限性。特别是，智能体的性能受到基础模型的知识覆盖范围、推理能力和感知准确性的影响，这可能在某些场景中限制其有效性。（2）虽然 WAC 引入了环境感知的世界模型来模拟潜在结果，但此类模拟本质上是近似的。预测与实际网页环境动态之间的差异可能在某些情况下导致不完善的反馈和次优的优化。未来，我们将尝试通过引入轻量级适配或专业化技术来增强 WAC ，以更好地使智能体与目标网页环境对齐，同时保留其免调优的优势。我们还计划通过利用更强大或动态更新的世界模型来提高结果模拟的保真度，以提供更准确的反馈信号。

6. 结论

在本工作中，我们引入了 WAC ，一种集成了协作式动作生成和反馈驱动的执行前动作优化的网页智能体。通过引入环境感知的世界模型用于动作生成辅助和结果模拟，以及用于执行前动作优化的反馈机制，WAC 能够在复杂网页环境中实现更知情的动作提案和鲁棒的决策。此设计缓解了单模型动作推理的结构性局限，并提供了改善动作质量和执行鲁棒性的闭环纠正机制。在 VisualWebArena 和 Online-Mind2Web 上的广泛实验表明，WAC 一致优于强基线，分别取得了 24.5% 和 16.0% 的任务成功率。我们将在论文发表后开源代码，以促进该领域的可复现性和未来研究。

影响声明

本文提出了一种网页智能体框架，通过协作动作生成和反馈驱动的动作优化来提高决策鲁棒性。本工作的主要目标是推进能够在复杂、动态在线环境中运行的可靠且可泛化的网页智能体研究。从积极的角度来看，此类智能体可以协助用户进行信息检索、任务自动化和可访问性方面的工作，有可能减轻与大规模网络系统交互的认知和操作负担。通过强调执行前验证和迭代纠正，与直接执行未经验证的动作相比，我们的方法也促进了更安全、更谨慎的智能体行为。同时，与其他网页自动化和智能体系统一样，如果部署不当，类似技术存在被滥用于大规模自动化交互或意外操纵的风险。这些顾虑并非我们方法独有的，而是网页智能体的普遍问题。我们认为，适当的保障措施、使用政策和人工监督对于实际部署至关重要。总体而言，除了现有网页智能体和自动化研究中已存在的伦理问题之外，我们预计本工作不会引入新的伦理问题。

References

Bai, J., Bai, S., Yang, S., Wang, S., Tan, S., Wang, P., Lin, J., Zhou, C., and Zhou, J. Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023.

Bai, S., Cai, Y., Chen, R., Chen, K., Chen, X., Cheng, Z., Deng, L., Ding, W., Gao, C., Ge, C., Ge, W., Guo, Z., Huang, Q., Huang, J., Huang, F., Hui, B., Jiang, S., Li, Z., Li, M., Li, M., Li, K., Lin, Z., Lin, J., Liu, X., Liu, J., Liu, C., Liu, Y., Liu, D., Liu, S., Lu, D., Luo, R., Lv, C., Men, R., Meng, L., Ren, X.,

Ren, X., Song, S., Sun, Y., Tang, J., Tu, J., Wan, J., Wang, P., Wang, P., Wang, Q., Wang, Y., Xie, T., Xu, Y., Xu, H., Xu, J., Yang, Z., Yang, M., Yang, J., Yang, A., Yu, B., Zhang, F., Zhang, H., Zhang, X., Zheng, B., Zhong, H., Zhou, J., Zhou, F., Zhou, J., Zhu, Y., and Zhu, K. Qwen3-vl technical report. *arXiv preprint arXiv:2511.21631*, 2025a.

Bai, S., Chen, K., Liu, X., Wang, J., Ge, W., Song, S., Dang, K., Wang, P., Wang, S., Tang, J., Zhong, H., Zhu, Y., Yang, M., Li, Z., Wan, J., Wang, P., Ding, W., Fu, Z., Xu, Y., Ye, J., Zhang, X., Xie, T., Cheng, Z., Zhang, H., Yang, Z., Xu, H., and Lin, J. Qwen2.5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025b.

Chae, H., Kim, N., iunn Ong, K. T., Gwak, M., Song, G., Kim, J., Kim, S., Lee, D., and Yeo, J. Web agents with world models: Learning and leveraging environment dynamics in web navigation. In *The Thirteenth International Conference on Learning Representations*, 2025. URL https://openreview.net/forum?id=moWiYJuSGF.

Deng, X., Gu, Y., Zheng, B., Chen, S., Stevens, S., Wang, B., Sun, H., and Su, Y. Mind2web: Towards a generalist agent for the web. In Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S. (eds.), *Advances in Neural Information Processing Systems*, volume 36, pp. 28091–28114. Curran Associates, Inc., 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/5950bf290a1570ea401bf98882128160-Paper-Datasets_and_Benchmarks.pdf.

Fang, T., Zhang, H., Zhang, Z., Ma, K., Yu, W., Mi, H., and Yu, D. WebEvolver: Enhancing web agent self-improvement with co-evolving world model. In Christodoulopoulos, C., Chakraborty, T., Rose, C., and Peng, V. (eds.), *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pp. 8959–8975, Suzhou, China, November 2025. Association for Computational Linguistics. ISBN 979-8-89176-332-6. doi: 10.18653/v1/2025.emnlp-main.454. URL https://aclanthology.org/2025.emnlp-main.454/.

Furuta, H., Lee, K.-H., Nachum, O., Matsuo, Y., Faust, A., Gu, S., and Gur, I. Multimodal web navigation with instruction-finetuned foundation models. In Kim, B., Yue, Y., Chaudhuri, S., Fragkiadaki, K., Khan, M., and Sun, Y. (eds.), *International Conference on Learning Representations*, volume 2024, pp. 29528–29558, 2024. URL https://proceedings.iclr.cc/paper_files/paper/2024/file/7ef7d8359036afd8c2378d82c21058a4-Paper-Conference.pdf.

Gao, Y., Ye, J., Wang, J., and Sang, J. Websynthesis: World-model-guided mcts for efficient webui-trajectory synthesis, 2025. URL https://arxiv.org/abs/2507.04370.

Gu, Y., Zhang, K., Ning, Y., Zheng, B., Gou, B., Xue, T., Chang, C., Srivastava, S., Xie, Y., Qi, P., Sun, H., and Su, Y. Is your llm secretly a world model of the internet? model-based planning for web agents. *Transactions on Machine Learning Research*, 2025.

Gur, I., Furuta, H., Huang, A., Safdari, M., Matsuo, Y., Eck, D., and Faust, A. A real-world webagent with planning, long context understanding, and program synthesis. In Kim, B., Yue, Y., Chaudhuri, S., Fragkiadaki, K., Khan, M., and Sun, Y. (eds.), *International Conference on Learning Representations*, volume 2024, pp. 52690–52717, 2024. URL https://proceedings.iclr.cc/paper_files/paper/2024/file/e91bf7dfba0477554994c6d64833e9d8-Paper-Conference.pdf.

Ha, D. and Schmidhuber, J. World models. 2018. doi: 10.5281/ZENODO.1207631. URL https://zenodo.org/record/1207631.

Jeong, Y., Chun, J., Cha, S., and Kim, T. Object-centric world model for language-guided manipulation, 2025. URL https://arxiv.org/abs/2503.06170.

Kim, G., Baldi, P., and McAleer, S. Language models can solve computer tasks. In *Proceedings of the 37th International Conference on Neural Information Processing Systems*, NIPS '23, Red Hook, NY, USA, 2023. Curran Associates Inc.

Koh, J. Y., Lo, R., Jang, L., Duvvur, V., Lim, M. C., Huang, P.-Y., Neubig, G., Zhou, S., Salakhutdinov, R., and Fried, D. Visualwebarena: Evaluating multimodal agents on realistic visual web tasks. *ACL*, 2024a.

Koh, J. Y., McAleer, S., Fried, D., and Salakhutdinov, R. Tree search for language model agents. *arXiv preprint arXiv:2407.01476*, 2024b.

Liu, J., Hao, J., Zhang, C., and Hu, Z. Wepo: Web element preference optimization for llm-based web navigation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 39(25):26614–26622, Apr. 2025. doi: 10.1609/aaai.v39i25.34863. URL https://ojs.aaai.org/index.php/AAAI/article/view/34863.

Mei, K., Guo, J., Chang, S., Dong, M., Lee, D., Niu, X., and Jiang, J. R-wom: Retrieval-augmented world model for computer-use agents, 2025. URL https://arxiv.org/abs/2510.11892.

Shi, T., Karpathy, A., Fan, L., Hernandez, J., and Liang, P. World of bits: An open-domain platform for web-based agents. In Precup, D. and Teh, Y. W. (eds.), *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *Proceedings of Machine Learning Research*, pp. 3135–3144. PMLR, 06–11 Aug 2017. URL https://proceedings.mlr.press/v70/shi17a.html.

Singh, K., Singh, S., and Khanna, M. Trishul: Towards region identification and screen hierarchy understanding for large vlm based gui agents. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, pp. 170–179, June 2025.

Srivastava, S., Li, G., Chang, C., Garg, R., Kaur, M., Lee, C. Y., Li, Y., Mao, Y., Cases, I., Xie, Y., and Qi, P. Warc-bench: Web archive based benchmark for gui subtask executions, 2025. URL https://arxiv.org/abs/2510.09872.

Sutton, R. S. Dyna, an integrated architecture for learning, planning, and reacting. *SIGART Bull.*, 2(4):160−163, July 1991. ISSN 0163-5719. doi: 10.1145/122344.122377. URL https://doi.org/10.1145/122344.122377.

Team, V., Hong, W., Yu, W., Gu, X., Wang, G., Gan, G., Tang, H., Cheng, J., Qi, J., Ji, J., Pan, L., Duan, S., Wang, W., Wang, Y., Cheng, Y., He, Z., Su, Z., Yang, Z., Pan, Z., Zeng, A., Wang, B., Chen, B., Shi, B., Pang, C., Zhang, C., Yin, D., Yang, F., Chen, G., Xu, J., Zhu, J., Chen, J., Chen, J., Chen, J., Lin, J., Wang, J., Chen, J., Lei, L., Gong, L., Pan, L., Liu, M., Xu, M., Zhang, M., Zheng, Q., Yang, S., Zhong, S., Huang, S., Zhao, S., Xue, S., Tu, S., Meng, S., Zhang, T., Luo, T., Hao, T., Tong, T., Li, W., Jia, W., Liu, X., Zhang, X., Lyu, X., Fan, X., Huang, X., Wang, Y., Xue, Y., Wang, Y., Wang, Y., An, Y., Du, Y., Shi, Y., Huang, Y., Niu, Y., Wang, Y., Yue, Y., Li, Y., Zhang, Y., Wang, Y., Wang, Y., Zhang, Y., Xue, Z., Hou, Z., Du, Z., Wang, Z., Zhang, P., Liu, D., Xu, B., Li, J., Huang, M., Dong, Y., and Tang, J. Glm-4.5v and glm-4.1v-thinking: Towards versatile multimodal reasoning with scalable reinforcement learning, 2025. URL https://arxiv.org/abs/2507.01006.

Wang, P., Bai, S., Tan, S., Wang, S., Fan, Z., Bai, J., Chen, K., Liu, X., Wang, J., Ge, W., Fan, Y., Dang, K., Du, M., Ren, X., Men, R., Liu, D., Zhou, C., Zhou, J., and Lin, J. Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*, 2024a.

Wang, Z. Z., Mao, J., Fried, D., and Neubig, G. Agent workflow memory, 2024b. URL https://arxiv.org/abs/2409.07429.

Wu, P., Escontrela, A., Hafner, D., Goldberg, K., and Abbeel, P. Daydreamer: World models for physical robot learning. *Conference on Robot Learning*, 2022.

Xue, T., Qi, W., Shi, T., Song, C. H., Gou, B., Song, D., Sun, H., and Su, Y. An illusion of progress? assessing the current state of web agents. In *Second Conference on Language Modeling*, 2025. URL https://openreview.net/forum?id=6jZi4HSs6o.

Yang, A., Yang, B., Hui, B., Zheng, B., Yu, B., Zhou, C., Li, C., Li, C., Liu, D., Huang, F., Dong, G., Wei, H., Lin, H., Tang, J., Wang, J., Yang, J., Tu, J., Zhang, J., Ma, J., Xu, J., Zhou, J., Bai, J., He, J., Lin, J., Dang, K., Lu, K., Chen, K., Yang, K., Li, M., Xue, M., Ni, N., Zhang, P., Wang, P., Peng, R., Men, R., Gao, R., Lin, R., Wang, S., Bai, S., Tan, S., Zhu, T., Li, T., Liu, T., Ge, W., Deng, X., Zhou, X., Ren, X., Zhang, X., Wei, X., Ren, X., Fan, Y., Yao, Y., Zhang, Y., Wan, Y., Chu, Y., Liu, Y., Cui, Z., Zhang, Z., and Fan, Z. Qwen2 technical report. *arXiv preprint arXiv:2407.10671*, 2024a.

Yang, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Li, C., Liu, D., Huang, F., Wei, H., Lin, H., Yang, J., Tu, J., Zhang, J., Yang, J., Yang, J., Zhou, J., Lin, J., Dang, K., Lu, K., Bao, K., Yang, K., Yu, L., Li, M., Xue, M., Zhang, P., Zhu, Q., Men, R., Lin, R., Li, T., Xia, T., Ren, X., Ren, X., Fan, Y., Su, Y., Zhang, Y., Wan, Y., Liu, Y., Cui, Z., Zhang, Z., and Qiu, Z. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024b.

Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., Zheng, C., Liu, D., Zhou, F., Huang, F., Hu, F., Ge, H., Wei, H., Lin, H., Tang, J., Yang, J., Tu, J., Zhang, J., Yang, J., Yang, J., Zhou, J., Zhou, J., Lin, J., Dang, K., Bao, K., Yang, K., Yu, L., Deng, L., Li, M., Xue, M., Li, M., Zhang, P., Wang, P., Zhu, Q., Men, R., Gao, R., Liu, S., Luo, S., Li, T., Tang, T., Yin, W., Ren, X., Wang, X., Zhang, X., Ren, X., Fan, Y., Su, Y., Zhang, Y., Zhang, Y., Wan, Y., Liu, Y., Wang, Z., Cui, Z., Zhang, Z., Zhou, Z., and Qiu, Z. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025a.

Yang, J., Hou, B., Wei, W., Chang, S., and Bao, Y. Webdart: Dynamic decomposition and re-planning for complex web tasks, 2025b. URL https://arxiv.org/abs/2510.06587.

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. React: Synergizing reasoning and acting in language models. 2023. URL https://www.scopus.com/inward/record.uri?eid=2-s2.0-85199863002&partnerID=40&md5=7cd72e9c58ecd294bec0f951cfda3ef8. Cited by: 1069.

Zheng, B., Gou, B., Kil, J., Sun, H., and Su, Y. Gpt-4v(ision) is a generalist web agent, if grounded. *arXiv preprint arXiv:2401.01614*, 2024.

Zhou, R., Yang, Y., Wen, M., Wen, Y., Wang, W., Xi, C., Xu, G., Yu, Y., and Zhang, W. TRAD: Enhancing llm agents with step-wise thought retrieval and aligned decision. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, 2024a.

Zhou, S., Xu, F. F., Zhu, H., Zhou, X., Lo, R., Sridhar, A., Cheng, X., Ou, T., Bisk, Y., Fried, D., Alon, U., and Neubig, G. Webarena: A realistic web environment for building autonomous agents. In Kim, B., Yue, Y., Chaudhuri, S., Fragkiadaki, K., Khan, M., and Sun, Y. (eds.), *International Conference on Learning Representations*, volume 2024, pp. 15585–15606, 2024b. URL https://proceedings.iclr.cc/paper_files/paper/2024/file/4410c0711e9154a7a2d26f9b3816d1ef-Paper-Conference.pdf.

A. 动作空间

Table 6. 动作空间。

动作类型	参数	描述
click	[id]	点击由给定元素 id 指定的网页元素。
type	[id], [content]	将提供的内容输入到指定 id 的输入框中。默认情况下，输入后按回车键，除非被禁用。
hover	[id]	将鼠标光标悬停在由给定 id 指定的网页元素上。
press	[key_comb]	模拟按下键盘按键或组合键（如 Ctrl+V）。
scroll	[up/down]	在指定方向上垂直滚动网页。
new_tab	–	打开一个新的空白浏览器标签页。
tab_focus	[tab_index]	切换焦点到由索引指定的浏览器标签页。
close_tab	–	关闭当前活动的浏览器标签页。
goto	[url]	将浏览器导航到指定 URL。
go_back	–	导航到先前访问的网页。
go_forward	–	如果之前执行了 `go_back` 动作，则导航到下一个网页。
stop	[answer]	当任务目标完成时终止任务执行并返回最终答案。

我们在表 6中总结了网页智能体可用的完整动作空间，该空间在所有比较方法中共享。

B. 实现细节

基准测试和基线 我们的实现基于 VisualWebArena (Koh et al., 2024a) 代码库，该代码库提供了智能体-网页交互的基础设施。基于此框架，我们实现了智能体以在 VisualWebArena 和 Online-Mind2Web (Deng et al., 2023; Xue et al., 2025) 基准测试中执行任务。对于基线，ReAct (Yao et al., 2023) 使用 VisualWebArena 代码库提供的官方实现。WebDreamer (Gu et al., 2025) 基于原始作者发布的代码进行复现，我们严格遵循原始论文中描述的配置和设计选择以确保公平比较。

基础模型 我们使用 Qwen3-VL-Plus (Bai et al., 2025a;b; Wang et al., 2024a; Bai et al., 2023) 作为所有智能体的基础视觉-语言模型。由于 Qwen3-VL-Plus 持续更新，我们指定了基于时间的快照以确保可复现性。本文所有实验使用 2025 年 12 月 19 日发布的模型快照。对于基准评估流水线中需要模型辅助的组件，我们根据模态采用不同模型。具体而言，我们使用 Qwen3-Max (Yang et al., 2025a; 2024b;a) 处理纯文本评估任务，使用 Qwen3-VL-Plus 处理涉及视觉输入的评估步骤。

超参数 为了控制计算成本，我们将评判模型评分采样次数设为 3，每个候选动作进行一次世界模型模拟推演。所有其他超参数遵循 VisualWebArena 和 WebDreamer 的官方设置。对于 WAC 特有的组件，我们将反馈驱动动作优化的最大迭代次数设为 3。置信度阈值设为 $\theta = 0.4$，每轮优化中保留评判模型置信度分数排名前 3 的候选动作。